

Introducción a la Ciencia de Datos

Maestría en Ciencias
de la Computación

Dr. Irvin Hussein López Nava

1.2 Datos

¿Qué son los Datos?

A woman with dark hair, wearing an orange sweater, is shown in profile, looking upwards and to the left. She is holding a tablet in her left hand and reaching out with her right hand towards a glowing digital globe. The background is a complex digital interface with various data visualizations, including line graphs, bar charts, and circular progress indicators. The overall color scheme is blue and orange.

Definiciones

ChatGPT

Son hechos, cifras u observaciones sin procesar que pueden ser recolectados, almacenados y analizados. Constituyen la base de la información y el conocimiento, a menudo en forma de números, texto, imágenes u otros formatos.

<https://chat.openai.com/>

Wikipedia

Son una representación simbólica (numérica, alfabética, algorítmica, espacial, etc.) de un atributo o variable cuantitativa o cualitativa. Los datos describen hechos empíricos, sucesos y entidades.

<https://es.wikipedia.org/wiki/Dato>

Cambridge dic.

Información, especialmente hechos o cifras, recopilada para ser examinada, considerada y utilizada como ayuda para la toma de decisiones, o información en formato electrónico que puede ser almacenada y utilizada por un ordenador.

<https://dictionary.cambridge.org/dictionary/english/data>



MÉTODO CUANTITATIVO



MÉTODO CUALITATIVO



Tipos de datos

Cuantitativos

Se trata de números, información referente de una determinada “**cantidad**”.

Por ejemplo, al medir la altura o el peso de una persona, o el tiempo que lleva ir de un lugar a otro.


Cualitativos

Relativos a las “**cualidades**”, este tipo de información está relacionada con los adjetivos.

Por ejemplo, al describir experiencias de compra es posible utilizar los términos: rápido, práctico, agradable, caro o inútil.



Escalas de medición



Dataset: weather.numeric




Day	Outlook	Temperature	Humidity	Wind	Play
1	sunny	85	85	weak	FALSE
2	sunny	80	90	strong	FALSE
3	overcast	83	86	weak	TRUE
4	rain	70	96	weak	TRUE
5	rain	68	80	weak	TRUE
6	rain	65	70	strong	FALSE
7	overcast	64	65	strong	TRUE
8	sunny	72	95	weak	FALSE
9	sunny	69	70	weak	TRUE
10	rain	75	80	weak	TRUE
11	sunny	75	70	strong	TRUE
12	overcast	72	90	strong	TRUE
13	overcast	81	75	weak	TRUE
14	rain	71	91	strong	FALSE




Instancias y atributos

Day	Outlook	Temperature	Humidity	Wind	Play
1	sunny	85	85	weak	FALSE
2	sunny	80	90	strong	FALSE
3	overcast	83	86	weak	TRUE
4	rain	70	96	weak	TRUE
5	rain	68	80	weak	TRUE
6	rain	65	70	strong	FALSE
7	overcast	64	65	strong	TRUE
8	sunny	72	95	weak	FALSE
9	sunny	69	70	weak	TRUE
10	rain	75	80	weak	TRUE
11	sunny	75	70	strong	TRUE
12	overcast	72	90	strong	TRUE
13	overcast	81	75	weak	TRUE
14	rain	71	91	strong	FALSE

¿Qué tipo de dato es cada columna?

Columna	Naturaleza	Escala	Notas	dtype
<i>Day</i>	Cuantitativa	Identificador	No es una variable de análisis; no graficar	<code>int64</code>
<i>Outlook</i>	Cualitativa	Nominal	3 categorías sin orden	<code>object</code>
<i>Temperature</i>	Cuantitativa	Intervalo	°F; 0 °F no es "sin temperatura"	<code>int64</code>
<i>Humidity</i>	Cuantitativa	Razón	Porcentaje; 0% sí es ausencia	<code>int64</code>
<i>Wind</i>	Cualitativa	Ordinal (binaria)	weak < strong	<code>object</code>
<i>Play</i>	Cualitativa	Nominal (binaria)	Variable objetivo	<code>bool</code>





Tipos de datos (CS)

- En computación, un **tipo de datos** es una colección o agrupación de **valores de datos**, normalmente especificados por un conjunto de valores posibles, un conjunto de **operaciones** permitidas sobre estos valores, y/o una representación de estos valores como tipos de máquina.
- La mayoría de los lenguajes de programación admiten tipos de datos básicos de números enteros (de distintos tamaños), números de coma flotante (que se aproximan a los números reales), caracteres y booleanos.

Tipos de datos (CS)

- Diferentes lenguajes pueden utilizar diferentes tipos de datos o tipos similares con diferente semántica.
 - En Python, ***int*** representa un entero de precisión arbitraria que tiene las operaciones numéricas tradicionales como suma, resta y multiplicación.
 - En Java, el tipo ***int*** representa el conjunto de enteros de 32 bits cuyo valor oscila entre -2.147.483.648 y 2.147.483.647, con operaciones aritméticas que se desbordan.

Tipos de datos de máquina

- Todos los datos de las computadoras basados en la electrónica digital se representan como **bits** (0 y 1) en el nivel más bajo. La unidad de datos direccionable más pequeña suele ser un grupo de bits llamado **byte** (8 bits). La unidad procesada por instrucciones de código máquina se denomina **palabra** (a partir de 2011: 32 o 64 bits).
- Se utilizan principalmente en programación de sistemas o en lenguajes de programación de bajo nivel (ensamblador).

```
10100001 10111100 10010011 00000100
00001000 00000011 00000101 11000000
10010011 00000100 00001000 10100011
11000000 10010100 00000100 00001000
```

It means: $z = x + y;$

Tipo booleano

- El tipo booleano representa los valores **verdadero** y **falso**. Aunque sólo son posibles dos valores, a menudo se representan como una palabra y no como un solo bit.
- Muchos lenguajes de programación no tienen un tipo booleano explícito, sino que utilizan un tipo entero e interpretan 0 como **FALSE** y otros valores como **TRUE**.

True



False




Tipos numéricos

- Todos los lenguajes de programación proporcionan **uno o más tipos de datos enteros**.
- Pueden proporcionar una pequeña cantidad de subtipos predefinidos restringidos a ciertos rangos; o permitir a los usuarios definir libremente subrangos.
- Los tipos de datos de **punto flotante** representan ciertos valores fraccionarios (números racionales, matemáticamente).

```
byte b = 1;  
short s = 200;  
int i = 3000;  
long l = 10000;  
float f = 10.0f;  
double d = 10.1d;
```

Tipos de texto y cadenas


- Los **caracteres** pueden ser una letra de algún alfabeto, un dígito, un espacio en blanco, un signo de puntuación, etc. Se extraen de un conjunto predefinido como ASCII.
- Las **cadenas** son una secuencia de caracteres que se utilizan para almacenar palabras o texto sin formato.
- Los tipos de caracteres y cadenas pueden tener diferentes subtipos según su codificación.
 - El ASCII original de 7 bits era limitado y fue reemplazado por conjuntos de 8, 16 y 32 bits, para codificar alfabetos no latinos (como el hebreo y el chino) y otros símbolos.



Caracteres	0	1	2	3	4	5	6	7
0 0 0 0 0 0 0	NUL	DLE	SP	0	@	P	^	p
0 0 0 0 0 0 1	SOH	DC1	!	1	A	Q	a	q
0 0 0 0 0 1 0	STX	DC2	"	2	B	R	b	r
0 0 0 0 0 1 1	ETX	DC3	#	3	C	S	c	s
0 0 0 0 1 0 0	EOT	DC4	\$	4	D	T	d	t
0 0 0 0 1 0 1	ENQ	NAK	%	5	E	U	e	u
0 0 0 0 1 1 0	ACK	SYN	&	6	F	V	f	v
0 0 0 0 1 1 1	BEL	ETB	'	7	G	W	g	w
1 0 0 0 0 0 0	BS	CAN	(	8	H	X	h	x
1 0 0 0 0 0 1	HT	EM	)	9	I	Y	i	y
1 0 0 0 0 1 0	LF	SUB	*	:	J	Z	j	z
1 0 0 0 0 1 1	VT	ESC	+	;	K	[	k	{
1 0 0 0 1 0 0	FF	FS	,	<	L	\	l	{
1 0 0 0 1 0 1	CR	GS	=	=	M	]	m	}
1 0 0 0 1 1 0	SO	RS	.	>	N	^	n	~
1 0 0 0 1 1 1	SI	US	/	?	O	_	o	DEL


Estructuras de datos

- Son útiles para almacenar y recuperar conjuntos de datos.
- Una **matriz** (vector, lista, secuencia) almacena una cantidad de elementos y proporciona acceso a sus elementos individuales.
- Normalmente, se requiere que los elementos de una matriz sean del mismo tipo.
- Pueden ser de longitud fija o dinámica.
- Los índices de una matriz pueden ser números enteros.




Estructuras de datos



- Un **objeto** contiene campos de datos (variables), y también ofrece una cantidad de subrutinas para acceder a ellos o modificarlos, llamadas métodos.
- Las **listas enlazadas** (simples o dobles), se pueden utilizar para implementar estructuras especializadas, como: pilas, colas, árboles y grafos.



Datos en Datos



it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fair	1
humor	1
have	1
great	1
...	...



The slide features a light blue background with several dark blue squares scattered around the edges. The word "Python" is centered in a large, bold, dark blue font.

Python

Python es el **lenguaje** de la Ciencia de Datos


- Especialmente cierto si las tareas de ciencia de datos implican mucho **procesamiento** de datos y/o aprendizaje automático.
- Menos cierto si las tareas son más "puramente **estadísticas**" (entonces R es más estándar)

El crecimiento y la popularidad de Python coinciden con el auge del aprendizaje automático.

Python 3 es uno de los lenguajes de programación de más rápido crecimiento. Es un lenguaje más fácil y eficiente que Python 2, o incluso que C#, R o Java. Python 3 es un lenguaje más limpio con una sintaxis más sencilla.

Python growth

PYPL Popularity of Programming Language







Python growth

Worldwide, Aug 2026 :

Rank	Change	Language	Share	1-year trend
1		Python	50.44 %	+20.2 %
2		Java	12.8 %	-2.0 %
3		C/C++	8.57 %	-1.2 %
4	↑	R	4.18 %	-1.3 %
5	↓	JavaScript	3.52 %	-3.4 %
6	↑↑↑↑↑↑↑↑	Objective-C	3.01 %	+0.9 %
7		PHP	2.06 %	-1.4 %
8	↑	Rust	1.86 %	-1.0 %
9	↓↓↓↓	C#	1.74 %	-3.0 %
10	↓↓↓	Swift	1.68 %	-1.2 %
11	↓	TypeScript	1.52 %	-0.9 %
12	↓	Ada	1.5 %	-0.7 %
13		Matlab	0.99 %	-0.5 %

Python 3
The standard type hierarchy

None
(class `NoneType`)




Callable
< Functions, Methods, Classes >

Modules

Tipos de datos de Python

Name	Type	Description
Integers	int	Whole numbers, such as: 3 300 200
Floating point	float	Numbers with a decimal point: 2.3 4.6 100.0
Strings	str	Ordered sequence of characters: "hello" 'Sammy' "2000" "楽しい"
Lists	list	Ordered sequence of objects: [10,"hello",200.3]
Dictionaries	dict	Unordered Key:Value pairs: {"mykey" : "value" , "name" : "Frankie"}
Tuples	tup	Ordered immutable sequence of objects: (10,"hello",200.3)
Sets	set	Unordered collection of unique objects: {"a","b"}
Booleans	bool	Logical value indicating True or False

Tipos de datos de Python




Herramientas

Jupyter

Todas las prácticas del curso (e incluso los ejemplos) se distribuyen como **Notebooks** de **Jupyter**.

Estos **Notebooks** son entornos basados en navegadores web para escribir, intercalar y documentar código; todo ello contenido en "celdas".



- **Jupyter** es un proyecto que engloba herramientas, incluidas las aplicaciones web **Jupyter Notebook** y **JupyterLab**, para la creación y edición de **Notebooks**.
- **JupyterLab** está diseñado para ser más extensible que **Jupyter Notebook**, permitiendo a los desarrolladores crear extensiones personalizadas que añadan nuevas funcionalidades o modifiquen el comportamiento existente.

File Edit View Run Kernel Tabs Settings Help

+

Filter files by name

/ notebooks /

Name	Last Modified
audio	a day ago
images	a day ago
Cpp.ipynb	a day ago
Data.ipynb	a day ago
Fasta.ipynb	a day ago
Julia.ipynb	a day ago
Lorenz.ip...	a day ago
lorenz.py	a day ago
R.ipynb	a day ago

Launcher

README.md

Lorenz.ipynb

Terminal 1

Console 1

Data.ipynb

Code

Python 3 (ipykernel)

The Lorenz Differential Equations

Before we start, we import some preliminary libraries. We will also import (below) the accompanying `lorenz.py` file, which contains the actual solver and plotting routine.

```
[1]: %matplotlib inline
from ipywidgets import interactive, fixed
```

We explore the Lorenz system of differential equations:

$$\dot{x} = \sigma(y - x)$$

Output View

sigma 10.00
beta 2.67
rho 28.00

lorenz.py


```

1 from matplotlib import pyplot as plt
2 from mpl_toolkits.mplot3d import Axes3D
3 import numpy as np
4 from scipy import integrate
5
6 def solve_lorenz(sigma=10.0, beta=8./3, rho=28.0):
7     """Plot a solution to the Lorenz differential
8     equations."""
9
10    max_time = 4.0
11    N = 30
12
13    fig = plt.figure()
14    ax = fig.add_axes([0, 0, 1, 1], projection='3d')
15    ax.axis('off')

```

Simple 1 3 Python Ln 1, Col 1 Spaces: 4 lorenz.py

(Continued in live notebook)



Github

Create a new repository

A repository contains all project files, including the revision history. Already have a project repository elsewhere? [Import a repository.](#)

Required fields are marked with an asterisk ().*

Owner *



husseinlopez

Repository name *

icd2026

✅ icd2026 is available.

Great repository names are short and memorable. Need inspiration? How about **improved-sniffle** ?

Description (optional)

book/

classes/

practices/

project/

Repositorios de datos

kaggle




UC Irvine
Machine Learning
Repository



Microsoft

Extra Libro



- 02.00-Introduction-to-NumPy.ipynb
- 02.01-Understanding-Data-Types.ipynb
- 02.02-The-Basics-Of-NumPy-Arrays.ipynb
- 02.03-Computation-on-arrays-ufuncs.ipynb
- 02.04-Computation-on-arrays-aggregates.ipynb
- 02.05-Computation-on-arrays-broadcasting.ipynb
- 02.06-Boolean-Arrays-and-Masks.ipynb
- 02.07-Fancy-Indexing.ipynb
- 02.08-Sorting.ipynb
- 02.09-Structured-Data-NumPy.ipynb

