

Introducción a la Ciencia de Datos

Maestría en Ciencias
de la Computación

Dr. Irvin Hussein López Nava



Lectura 1: Pasado, presente y futuro de la Ciencia ...

Fecha de entrega: 23:00



Publicado: 1 sept

3

Entregadas

12

Asignadas

Preparar un reporte de una cuartilla en el que se analice a detalle el presente del área, partiendo de 3 tópicos abordados en el video adjunto (perspectiva de hace 10 años - pasado). Finalizar el análisis con una proyección a futuro (a 10 años). Complementar con fuentes de información adicionales, y citarlas apropiadamente.

The Future of Data Sc...

Vídeo de YouTube • 25 mi...



[Ver instrucciones](#)

[Revisar trabajo](#)

Lectura 1: para discutir

01

La curva de costo

Del genoma de 3,000 millones de dólares a 1,000 en una década. ¿Cuál es hoy la curva equivalente y qué se volvió caro?

02

Lo que no vieron

Julio de 2015: antes de AlphaGo y de los transformers, con AlexNet ya en la mesa. ¿Por qué no pesó?

03

Quién hace ciencia de datos

¿Una figura nueva o un experto de dominio con herramientas nuevas? La pregunta se reabrió.

04


El dato como riesgo

De cifrado y control de acceso a consentimiento, procedencia y regulación.

05

De la promesa a la práctica

Mucha medicina personalizada en el panel. ¿Qué separa una *demo* de un sistema desplegado?



De dónde venimos

- En la sesión 2 vimos que **el tipo** con el que se almacena una columna **no** dice cómo se midió.
- **Pandas** leyó *Day* y *Temperature* igual.
- Una es un identificador; la otra, una medición en escala de razón.

columna	dtype leído	escala real
Day	int64	identificador
Temperature	int64	razón
Humidity	int64	razón
Outlook	object	nominal
Play	object	nominal

Hoy cerramos esa distancia: convertir, consolidar, reorganizar y unir.

1.3 Representación

Let's keep talking

(and listening)

about data...



Data is the new oil?


Cuando el matemático británico **Clive Humby** lo declaró en 2006, quería decir que los datos, como el petróleo, no son útiles en estado bruto. Hay que refinarlos, procesarlos y convertirlos en algo útil; su **valor** reside en su **potencial**.



Sin embargo, ha perdido gran parte de su significado: los datos como algo intrínsecamente valioso, algo que simplemente se extrae, se acumula y se usa o se abusa de él.

Data are dessert?

**Data are the result
of deliberate human
intervention**



**Data are varied
within domains**

**Data are varied
across domains**




Data are dessert?

Data are the result
of deliberate human
intervention

01





Data are dessert?



02



Data are varied
across domains

Data are dessert?



03

Data are varied within domains



What is data?

What we actually have...





Sea Turtle Searching For Deep Data, 2010 | Credit photo: Copyright © artist [Steven Rodriguez](#)



Chaos, 2009 | Credit photo: Copyright © artist [Nick Genay](#)



Across the universe | Credit photo: Copyright © artist [Jack Gault](#)



The Raja Prakash 2010 | Credit photo: artist Copyright © Jeev Prakash



Plastic Ocean, 2016 | Credit photo: Copyright © artist [Tan Zi Xi](#)



Credit photo: Copyright © artist [Robert Bradford](#)

El objetivo: hacer que valgan!!



Gestión de datos

(era el segundo nombre para esta sesión)

Los datos (+ las personas que los recopilan) son variados.

→ Siempre es necesaria cierta preparación.


Esto es *antes* de ir al análisis de los datos mediante

- Entendimiento del contexto
- Estudio del tipo de datos
- Exploración inicial de los datos
- Conversión de los datos
- Limpieza de los datos
- ...



¿Quién documenta los datos?


Un diccionario de datos dice **qué** es cada columna. Un ***datasheet*** dice de dónde vienen, quién los recolectó, con qué propósito, y para qué usos ***no*** son apropiados.



En este curso: [datos/README.md](#) del repositorio es la versión mínima de un *datasheet*.

Primeros pasos

- Una vez que se tiene un *dataset*, se requiere:
 - Entender qué son las variables.
 - Gestionar los tipos de columnas (atributos).
 - Manejar los datos incompletos.
 - Unir, reorganizar y ordenar.
 - Los datos no siempre llegan como "X".



A diagram illustrating a dataset matrix X . The matrix is represented by a light gray rectangle. The word "samples" is written vertically to the left of the rectangle, and the word "attributes" is written horizontally above the rectangle. Inside the rectangle, the expression $X \in \mathbb{R}^{n \times p}$ is displayed.

Significado de los datos

DATA


employee_id	first_name	last_name	nin	dept_id
44	Simon	Martinez	HH 45 09 73 D	1
45	Thomas	Goldstein	SA 75 35 42 B	2
46	Eugene	Comelsen	NE 22 63 82	2
47	Andrew	Petculescu	XY 29 87 61 A	1
48	Ruth	Stadick	MA 12 89 36 A	15
49	Barry	Scardelis	AT 20 73 18	2
50	Sidney	Hunter	HW 12 94 21 C	6
51	Jeffrey	Evans	LX 13 26 39 B	6
52	Doris	Bemdt	YA 49 88 11 A	3
53	Diane	Eaton	BE 08 74 68 A	1

DATA DICTIONARY (METADATA)

Column	Data Type	Description
employee_id	int	Primary key of a table
first_name	nvarchar(50)	Employee first name
last_name	nvarchar(50)	Employee last name
nin	nvarchar(15)	National Identification Number
position	nvarchar(50)	Current position title, e.g. Secretary
dept_id	int	Employee department. Ref: Departments
gender	char(1)	M = Male, F = Female, Null = unknown
employment_start_date	date	Start date of employment in organization.
employment_end_date	date	Employment end date.

Manejando tipos

- Los datos vienen con diferentes "tipos".
 - Numéricos, categóricos (ordenados), fechas, enteros (positivos).
- Es valioso asegurar la coherencia respecto a lo que se esperaba. (¿por qué?)



```
In [6]:
taxi.dtypes
Out [6]:
unique_key      object
taxi_id          object
trip_start_timestamp  object
trip_end_timestamp  object
trip_seconds      float64
trip_miles        float64
pickup_census_tract  float64
dropoff_census_tract float64
pickup_community_area float64
dropoff_community_area float64
fare              float64
tips              float64
tolls             float64
extras            float64
trip_total        float64
payment_type      object
company           object
pickup_latitude   float64
pickup_longitude  float64
pickup_location   float64
dropoff_latitude   float64
dropoff_longitude float64
dropoff_location  float64
dtype: object
```

Conversión de tipos

Se pueden utilizar funciones para convertir entre tipos de datos, e.g., *to_datetime* de pandas.

"22-01-2019T15:00:02"


datetime.datetime(2019, 1, 22, 15, 0, 2)

```
In [13]:
taxi = taxi.assign(
    day=lambda df: df.trip_start_timestamp.map(lambda x: x.day),
    weekday=lambda df: df.trip_start_timestamp.map(lambda x: x.weekday),
    hour=lambda df: df.trip_start_timestamp.map(lambda x: x.hour)
)
taxi[["day", "weekday"]]
Out [13]:
   day  weekday
0     7         6
1     7         6
2     7         6
3    20         5
4    30         5
...    ...    ...
19995  7         6
19996  9         1
19997  7         6
19998  16        1
19999  5         4


[20000 rows x 2 columns]
```

Tipos categóricos


El número de niveles puede ser abrumador



Una sola categoría puede incorporar diferente información



Los niveles podrían no estar consolidados




Se podrían convertir en valores numéricos



Agrupar, unir y organizar

Se desea una representación en matriz que facilite el trabajo, pero...



cooperhewitt / collection

Code Issues Pull requests Projects Wiki

Branch: master collection / objects /

micahwalter data updated and migrated to use git ifs

102	20151113
135/726	20151113
136	20151113
152/749	20151113
169/619/579	20151113
180	data updated and migrated to use git ifs
181	data updated and migrated to use git ifs
182	data updated and migrated to use git ifs
183	data updated and migrated to use git ifs
184	data updated and migrated to use git ifs

```
width,height,channels,im_size,ctime,mtime,img_files
0,1300,1300,1,3383838,1515131214.7275624,1511274026.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img1510.tif
1,1300,1300,1,3383838,1515131210.4355597,1511274012.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img338.tif
2,1300,1300,1,3383838,1515131211.9995608,1511274005.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img1468.tif
3,1300,1300,1,3383838,1515131223.5595682,1511274001.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img857.tif
4,1300,1300,1,3383838,1515131222.8075676,1511274003.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img86.tif
5,1300,1300,1,3383838,1515131215.503563,1511274006.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img1276.tif
6,1300,1300,1,3383838,1515131223.479568,1511274002.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img1582.tif
7,1300,1300,1,3383838,1515131223.0555677,1511274031.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img127.tif
8,1300,1300,1,3383838,1515131213.975562,1511274031.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img1550.tif
9,1300,1300,1,3383838,1515131211.9235606,1511274013.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img1447.tif
10,1300,1300,1,3383838,1515131213.0635614,1511274005.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img894.tif
11,1300,1300,1,3383838,1515131215.6915631,1511274005.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img741.tif
12,1300,1300,1,3383838,1515131210.0635595,1511274007.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img522.tif
13,1300,1300,1,3383838,1515131210.1115596,1511274002.0,AOI_2_Vegas_Roads_Test_Public,PAN,PAN_AOI_2_Vegas_img1151.tif
```

Ancho y largo

ancho

id	dia_1	dia_2	dia_3
P01	7421	8110	6890
P02	10233	9877	11002
P03	5120	4890	5340

melt



pivot

largo

id	dia	pasos
P01	1	7421
P01	2	8110
P01	3	6890

Una fila = una observación. Una columna = una variable.

dia_1 no es una variable: es un valor de la variable día, agregado en el encabezado.

El inconveniente?

Los datos

Los mismos **datos**
(pero a la derecha)



La ayuda?



Herramientas



NumPy (**N**umerical **P**ython) es una **librería** de código abierto de Python que se utiliza en casi todos los campos de la ciencia y la ingeniería.

- Es el estándar universal para trabajar con **datos numéricos** en Python.
- La **API** de NumPy se utiliza ampliamente en Pandas, SciPy, Matplotlib, scikit-learn, scikit-image y la mayoría de los paquetes científicos y de ciencia de datos de Python.
- Añade potentes estructuras de datos que garantizan cálculos eficientes con *arrays* y proporciona una enorme biblioteca de funciones matemáticas de alto nivel que operan sobre estos *arrays*.

NumPy: por qué existe

Homogéneo

Un solo **dtype**, memoria contigua.
Por eso puede operar sin revisar
el tipo de cada elemento.

Vectorizado

pasos * 2 en lugar de un ciclo.
El ciclo baja a código compilado
en C.

Con ejes

axis=0 por columna,
axis=1 por fila.
Y versiones NaN-safe: np.nanmean.

1,000,000 de elementos, la misma operación
ciclo de Python 41 ms
NumPy 0.56 ms

≈ 70×

Operator	Equivalent ufunc	Description
+	<code>np.add</code>	Addition (e.g., $1 + 1 = 2$)
-	<code>np.subtract</code>	Subtraction (e.g., $3 - 2 = 1$)
-	<code>np.negative</code>	Unary negation (e.g., -2)
*	<code>np.multiply</code>	Multiplication (e.g., $2 * 3 = 6$)
/	<code>np.divide</code>	Division (e.g., $3 / 2 = 1.5$)
//	<code>np.floor_divide</code>	Floor division (e.g., $3 // 2 = 1$)
**	<code>np.power</code>	Exponentiation (e.g., $2 ** 3 = 8$)
%	<code>np.mod</code>	Modulus/remainder (e.g., $9 \% 4 = 1$)

Operator	Equivalent ufunc	Operator	Equivalent ufunc
<code>==</code>	<code>np.equal</code>	<code>!=</code>	<code>np.not_equal</code>
<code><</code>	<code>np.less</code>	<code><=</code>	<code>np.less_equal</code>
<code>></code>	<code>np.greater</code>	<code>>=</code>	<code>np.greater_equal</code>

Function name	NaN-safe version	Description
<code>np.sum</code>	<code>np.nansum</code>	Compute sum of elements
<code>np.prod</code>	<code>np.nanprod</code>	Compute product of elements
<code>np.mean</code>	<code>np.nanmean</code>	Compute mean of elements
<code>np.std</code>	<code>np.nanstd</code>	Compute standard deviation
<code>np.var</code>	<code>np.nanvar</code>	Compute variance
<code>np.min</code>	<code>np.nanmin</code>	Find minimum value
<code>np.max</code>	<code>np.nanmax</code>	Find maximum value
<code>np.argmin</code>	<code>np.nanargmin</code>	Find index of minimum value
<code>np.argmax</code>	<code>np.nanargmax</code>	Find index of maximum value
<code>np.median</code>	<code>np.nanmedian</code>	Compute median of elements
<code>np.percentile</code>	<code>np.nanpercentile</code>	Compute rank-based statistics of elements
<code>np.any</code>	N/A	Evaluate whether any elements are true
<code>np.all</code>	N/A	Evaluate whether all elements are true

Lo más básico

Command

`np.array([1,2,3])`

NumPy Array

1
2
3



	data
0	1
1	2
2	3

	data[0]
	1

	data[1]
	2

	data[0:2]
	1
	2

	data[1:]
	2
	3

	data[-2:]
	2
	3

	data	
0	1	
1	2	-2
2	3	-1
3		

`data = np.array([1,2])`

data

1
2

`ones = np.ones(2)`

ones

1
1

data + **ones** =

data	+	ones	=							
<table><tr><td>1</td></tr><tr><td>2</td></tr></table>	1	2		<table><tr><td>1</td></tr><tr><td>1</td></tr></table>	1	1		<table><tr><td>2</td></tr><tr><td>3</td></tr></table>	2	3
1										
2										
1										
1										
2										
3										

data - **ones** =

data	-	ones	=							
<table><tr><td>1</td></tr><tr><td>2</td></tr></table>	1	2		<table><tr><td>1</td></tr><tr><td>1</td></tr></table>	1	1		<table><tr><td>0</td></tr><tr><td>1</td></tr></table>	0	1
1										
2										
1										
1										
0										
1										

data * **data** =

data	*	data	=							
<table><tr><td>1</td></tr><tr><td>2</td></tr></table>	1	2		<table><tr><td>1</td></tr><tr><td>2</td></tr></table>	1	2		<table><tr><td>1</td></tr><tr><td>4</td></tr></table>	1	4
1										
2										
1										
2										
1										
4										

data / **data** =

data	/	data	=							
<table><tr><td>1</td></tr><tr><td>2</td></tr></table>	1	2		<table><tr><td>1</td></tr><tr><td>2</td></tr></table>	1	2		<table><tr><td>1</td></tr><tr><td>1</td></tr></table>	1	1
1										
2										
1										
2										
1										
1										

`np.array([[1,2],[3,4],[5,6]])`



1	2
3	4
5	6

data

	0	1
0	1	2
1	3	4
2	5	6

data[0,1]

	0	1
0	1	2
1	3	4
2	5	6

data[1:3]

	0	1
0	1	2
1	3	4
2	5	6

data[0:2,0]

	0	1
0	1	2
1	3	4
2	5	6

data

1	2
3	4
5	6

`.max()` = 6

data

1	2
3	4
5	6

`.min()` = 1

data

1	2
3	4
5	6

`.sum()` = 21

data

1	2
3	4
5	6


data.T

1	3	5
2	4	6

data


1
2
3
4
5
6

data.reshape(2,3)



1	2	3
4	5	6

data.reshape(3,2)



1	2
3	4
5	6



pandas es una **librería** de código abierto de Python que proporciona estructuras de datos rápidas, flexibles y expresivas.

Es adecuada para muchos tipos de **datos**:

- Datos tabulares con columnas de tipos heterogéneos, como en una tabla SQL o una hoja de cálculo Excel.
- Datos de series temporales ordenados y desordenados.
- Datos matriciales arbitrarios (de tipificación homogénea o heterogénea) con etiquetas de filas y columnas.
- Cualquier otra forma de conjunto de datos observacionales/estadísticos.

Series, DataFrame, índice

Series

Un arreglo de NumPy con etiquetas.

índice	fc_reposo
P01	68
P02	72
P03	61

Con el índice puesto, P03 deja de ser un valor más y pasa a ser una dirección.

DataFrame

Series que comparten un mismo índice.

índice	edad	grupo	fc_reposo
P01	34	medio	68
P02	41	alto	72
P03	29	bajo	61

Cada columna conserva su tipo: la tabla es heterogénea aunque cada columna sea homogénea.

`.loc` selecciona por etiqueta `.iloc` selecciona por posición

Python operator	Pandas method(s)
+	add
-	sub, subtract
*	mul, multiply
/	truediv, div, divide
//	floordiv
%	mod
**	pow

Aggregation	Returns
count	Total number of items
first, last	First and last item
mean, median	Mean and median
min, max	Minimum and maximum
std, var	Standard deviation and variance
mad	Mean absolute deviation
prod	Product of all items
sum	Sum of all items

Method	Description
get	Indexes each element
slice	Slices each element
slice_replace	Replaces slice in each element with the passed value
cat	Concatenates strings
repeat	Repeats values
normalize	Returns Unicode form of strings
pad	Adds whitespace to left, right, or both sides of strings
wrap	Splits long strings into lines with length less than a given width
join	Joins strings in each element of the Series with the passed separator
get_dummies	Extracts dummy variables as a DataFrame

Lo más básico

	a	b	c
1	4	7	10
2	5	8	11
3	6	9	12

```
df = pd.DataFrame(  
    {"a": [4, 5, 6],  
     "b": [7, 8, 9],  
     "c": [10, 11, 12]},  
    Index = [1, 2, 3])
```

		a	b	c
n	v			
d	1	4	7	10
	2	5	8	11
e	2	6	9	12

```
df = pd.DataFrame(  
    {"a": [4, 5, 6],  
     "b": [7, 8, 9],  
     "c": [10, 11, 12]},  
    Index = pd.MultiIndex.from_tuples(  
        [('d', 1), ('d', 2), ('e', 2)],  
        names=['n', 'v']))
```




pd.melt(df)

Gather columns into rows.




df.pivot(columns='var', values='val')

Spread rows into columns.



pd.concat([df1, df2])

Append rows of DataFrames



pd.concat([df1, df2], axis=1)

Append columns of DataFrames



Tarea 1: Gráficos engañosos

Programado para el Mañana, ...




Fecha de entrega: 9 sept, 23:00


Localizar una gráfica publicada —en prensa, en un artículo científico o en un informe institucional— cuya representación induzca a una lectura equivocada de los datos. Preparar un reporte de una cuartilla que identifique la fuente, describa qué afirma la gráfica y explique qué decisiones de diseño producen el engaño.

[Editar tarea](#)

(Go to live notebook)



Extra Libro



- 03.00-Introduction-to-Pandas.ipynb
- 03.01-Introducing-Pandas-Objects.ipynb
- 03.02-Data-Indexing-and-Selection.ipynb
- 03.03-Operations-in-Pandas.ipynb
- 03.04-Missing-Values.ipynb
- 03.05-Hierarchical-Indexing.ipynb
- 03.06-Concat-And-Append.ipynb
- 03.07-Merge-and-Join.ipynb
- 03.08-Aggregation-and-Grouping.ipynb
- 03.09-Pivot-Tables.ipynb
- 03.10-Working-With-Strings.ipynb
- 03.11-Working-with-Time-Series.ipynb
- 03.12-Performance-Eval-and-Query.ipynb
- 03.13-Further-Resources.ipynb

hussein@cicese.mx

