

Introducción a la Ciencia de Datos

Maestría en Ciencias
de la Computación

Dr. Irvin Hussein López Nava

Introducción a la Ciencia de Datos

Maestría en Ciencias de la Computación

Dr. Irvin Hussein López Nava

Introducción a la Ciencia de Datos

Maestría en Ciencias de la Computación

Dr. Irvin Hussein López Nava



Tarea 1: Gráficos engañosos

Fecha de entrega: 23:00



Publicado: Ayer

6

Entregadas


9

Asignadas

Localizar una gráfica publicada —en prensa, en un artículo científico o en un informe institucional— cuya representación induzca a una lectura equivocada de los datos. Preparar un reporte de una cuartilla que identifique la fuente, describa qué afirma la gráfica y explique qué decisiones de diseño producen el engaño.

[Ver instrucciones](#)

[Revisar trabajo](#)



1.4 Visualización


Let's keep talking

(and listening)

about

Data...

but visualization



No se pierdan el próximo seminario...

y más sobre los datos...

La forma en que nos relacionamos con los **datos** está evolucionando muy rápido.

Nuestras **mentes** se adaptan de forma natural a esta realidad híbrida construida a partir de **estructuras** tanto físicas como informativas.

El diseño visual –con su poder para llegar a nuestro **subconsciente** sin la mediación del lenguaje, y su capacidad inherente para transmitir **grandes** cantidades de información **estructurada** y **no estructurada** a través de las culturas– va a ser aún más fundamental.



DALL·E

History

Collections

Edit the detailed description



Surprise me


Upload



visual design with its power to instantly reach out to places in our subconscious

Generate






- Los pioneros de la **visualización de datos**, como William Playfair, John Snow y Charles Joseph Minard, comenzaron a aprovechar su potencial durante los siglos XVIII y XIX.
- Siglos después, autores como Edward Tufte, Ben Shneiderman y Alberto Cairo impulsaron un renovado interés en el campo y su aplicación al creciente mundo del **Big Data**.
- Este interés dio paso a una primera ola de **visualización de datos** en la web, acercándola a públicos mucho más amplios que los ámbitos académicos donde se había desarrollado.
- Sin embargo, su popularización también propició un uso superficial, convirtiéndola en ocasiones en un recurso para hacer frente a la abrumadora complejidad del **Big Data**.


¿todo se puede visualizar?

- El **diseño visual** a menudo se aplica a los **datos** simplemente como un retoque cosmético, en un intento de hacer que parezcan más simples de lo que son.
- La contradicción: intentar "simplificar la complejidad".
- Los fenómenos que gobiernan nuestro mundo son, por definición, **complejos**, **multifacéticos** y, en su mayoría, **difíciles de comprender**, entonces, ¿por qué alguien querría simplificarlos para tomar decisiones cruciales o transmitir mensajes importantes?



¿todo es malo en esta repentina locura por la visualización de datos?




- No, gran parte del mundo se ha familiarizado con los **lenguajes visuales**.
- Además, cuanto más ubicuos se vuelven los **datos**, más se requiere experimentar para hacerlos únicos, contextuales e íntimos.
- La forma en que lo visualizamos es crucial porque es la clave para traducir los números en conceptos con los que podamos identificarnos.





A continuación unas pautas...

Abrazar la complejidad




HOW TO READ IT?



HOW TO READ IT?



HOW TO READ IT?



Ir más allá de las normas


Nobels no degrees

This visualization explores Nobel Prizes and graduate qualifications from 1901 to 2012, by analysing the age of recipients at the time prizes were awarded, average age evolution through time and among categories, graduation grades, main university affiliations and the principal hometowns of the graduates.

How to read it?

Each dot represents a Nobel laureate, each recipient is positioned according to the year the prize was awarded (x axis) and age of the person at the time of the award (y axis).



The visualization has been designed and produced by Accurat (www.accurat.it), and was originally published in Italian on *La Lettura* the Sunday cultural supplement of *Corriere della Sera*.



Agregar el contexto (siempre)

Georgia


Week Thirty-six



Georgia realized that when she was unhelpful the first time she told someone, so she added that then as further information.

a week of indecision

Stefanie



Stefanie drew indecision as a twisting, rambling line. The only decision she suggested this week: her poor selection off the menu while eating at a restaurant.

Recordar que los datos son imperfectos (como nosotros)

What we actually have...



¿Qué hace que un gráfico sea bueno?

- **Permite la comprensión:** Parte de una pregunta interesante y la responde.
- **Prioriza los datos:** Maximiza la relación datos/tinta.
- Es **estéticamente bella** (aunque esto es controvertido).




Importancia de la visualización

- **Antes** de ejecutar cualquier análisis estadístico, o construir modelos de aprendizaje automático: **visualice los datos!!!**
 - Si no se puede identificar alguna tendencia o hacer una predicción a partir de los datos, es poco probable que un algoritmo automatizado lo haga.
- Es especialmente importante cuando se escuchan historias sobre el rendimiento "sobrehumano" de los métodos de IA
 - es posible, pero toma mucho tiempo, es costoso y no siempre se sabe cómo se logran los resultados.

Visualización vs estadística

- La visualización casi siempre presenta una **visión** más informativa (aunque menos cuantitativa) de los datos que las estadísticas (el sustantivo, no el campo).





Scatter Plot of Iris



	Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm
count	150.000000	150.000000	150.000000	150.000000	150.000000
mean	75.500000	5.843333	3.054000	3.758667	1.198667
std	43.445368	0.828066	0.433594	1.764420	0.763161
min	1.000000	4.300000	2.000000	1.000000	0.100000
25%	38.250000	5.100000	2.800000	1.600000	0.300000
50%	75.500000	5.800000	3.000000	4.350000	1.300000
75%	112.750000	6.400000	3.300000	5.100000	1.800000
max	150.000000	7.900000	4.400000	6.900000	2.500000

¿Basta con la estadística?

Cuatro conjuntos de datos distintos. Todos los resúmenes numéricos coinciden.



En los cuatro: media $x = 9.00$ media $y = 7.50$ desv. est. $x = 3.32$ desv. est. $y = 2.03$ $r = 0.816$ recta ajustada: $y = 3.00 + 0.50x$

Todo resumen numérico comprime, y la compresión pierde información. La gráfica es el control de calidad del resumen.

Tipos de visualización


Exploración

- Análisis en profundidad de los datos en busca de nuevo conocimiento.
- Descubriendo lo que es verdad.


Presentación

- Consiste en transmitirlos a un público de forma que queden claras sus implicaciones.
- Convencer a otras personas de que es verdad


Tipos de visualización




WHAT IS A DATA STORY?



¿Exploración o presentación?




Tipos de datos



Canales de codificación

Visualizar es asignar cada variable a un canal visual.



Los mismos cinco valores, codificados en cuatro canales distintos.

Posición

Longitud

Ángulo

Área

Color

Forma

Textura

La pregunta no es «¿qué gráfico hago?», sino «¿qué canal le doy a cada variable?».

No todos los canales son iguales

Precisión con la que percibimos cada canal

1 Posición en una escala común

mayor precisión

2 Posición en escalas no alineadas

3 Longitud



4 Ángulo y pendiente

5 Área

6 Volumen y curvatura

7 Saturación y tono de color

menor precisión



Los mismos datos. ¿En cuál puede ordenar A-E sin dudar?

El pastel codifica con ángulo (4º lugar) lo que las barras codifican con posición (1er lugar). Por eso el pastel casi siempre pierde.

Del dato al gráfico

Quiero ver	Variables	Gráfico habitual
Distribución	1 numérica	Histograma, densidad, caja y bigotes
Comparación entre categorías	1 categórica + 1 numérica	Barras, caja agrupada, violín
Relación	2 numéricas	Dispersión
Composición	1 categórica	Barras (pastel solo con 2 o 3 categorías)
Evolución	tiempo + 1 numérica	Líneas
Correlaciones	n numéricas	Matriz de correlación, matriz de dispersión


Ejemplos de visualizaciones

- La mayor parte de la discusión sobre los tipos de visualización se enfoca en qué elementos se intentan transmitir en el gráficos.
- Un enfoque distinto, es enfocarse en el tipo y la dimensionalidad de los datos (cuantitativos, cualitativos, discretos, continuos, nominales, ordinales).
- Tipos de visualización (no es una lista exhaustiva):
 - 1D: bar chart, pie chart, histogram
 - 2D: scatter plot, line plot, box and whisker plot, heatmap
 - 3D+: scatter matrix, bubble chart

1D – Bar chart


	Data
Nominal	✓
Ordinal	✓
Interval	X
Ratio	X

↑
Suggestions, not rules




1D – Pie chart

	Data
Nominal	X
Ordinal	X
Interval	X
Ratio	X




1D - Histogram

	Data
Nominal	X
Ordinal	X
Interval	✓
Ratio	✓




2D - Scatter plot

	Dim 1	Dim 2
Nominal	X	X
Ordinal	X	X
Interval	✓	✓
Ratio	✓	✓




2D - Heatmap (density, or 2D histogram)

	Dim 1	Dim 2
Nominal	X	X
Ordinal	X	X
Interval	✓	✓
Ratio	✓	✓




2D - Box and whiskers

	Dim 1	Dim 2
Nominal	✓	X
Ordinal	✓	X
Interval	X	✓
Ratio	X	✓




2D - Violin plot

	Dim 1	Dim 2
Nominal	✓	X
Ordinal	✓	X
Interval	X	✓
Ratio	X	✓




2D - Line plot

	Dim 1	Dim 2
Nominal	X	X
Ordinal	X	X
Interval	✓	✓
Ratio	✓	✓




2D - Heatmap (matrix)

	Dim 1	Dim 2
Nominal	✓	✓
Ordinal	✓	✓
Interval	X	X
Ratio	X	X




2D - Bubble plot

	Dim 1	Dim 2
Nominal	✓	✓
Ordinal	✓	✓
Interval	X	X
Ratio	X	X




3D - Scatter plot

	Dim 1	Dim 2	Dim 3
Nominal	X	X	X
Ordinal	X	X	X
Interval	✓	✓	✓
Ratio	✓	✓	✓




3D - Scatter plot matrix

	Dim 1	Dim 2	Dim 3
Nominal	X	X	X
Ordinal	X	X	X
Interval	✓	✓	✓
Ratio	✓	✓	✓




3D - Bubble plot

	Dim 1	Dim 2	Dim 3
Nominal	X	X	X
Ordinal	X	X	X
Interval	✓	✓	✓
Ratio	✓	✓	✓




3D - Color scatter plot

	Dim 1	Dim 2	Dim 3
Nominal	X	X	✓
Ordinal	X	X	✓
Interval	✓	✓	X
Ratio	✓	✓	X





Otros gráficos















Asylum claims in Europe, 2015*

Total EU claims**
530,265





En resumen



1D – una variable

2D – dos variables

3D y más –
tres o más variables

Cómo mentir con gráficos

Eje truncado · exagera diferencias pequeñas


Doble eje · fabrica correlaciones que no existen

3D innecesario · distorsiona áreas y volúmenes

Pastel con muchas rebanadas · vuelve imposible el orden

Exceso de tinta · el adorno tapa el dato

Agregación · el promedio esconde la dispersión



Casi siempre son errores honestos: nadie decide mentir, simplemente acepta el gráfico que la librería devuelve por omisión.

El color no es decoración

Secuencial



variable ordenada, un extremo

Divergente




punto neutro con dos sentidos

Cualitativa




categorías sin orden

Arcoíris



Perceptualmente uniforme



- La paleta se elige según el tipo de variable, no según el gusto.
- El arcoíris introduce fronteras que no están en los datos.
- Cerca del 8 % de los hombres tiene alguna deficiencia en la visión del color: nunca lo use como único canal.

Herramientas




Matplotlib es una biblioteca para crear visualizaciones estáticas, animadas e interactivas en Python. Matplotlib hace fácil lo fácil y posible lo difícil:


- Crear gráficos con calidad de publicación.
- Hacer figuras interactivas que se puedan ampliar, desplazar y actualizar.
- Personalizar el estilo visual y el diseño.
- Exportar a muchos formatos de archivo.
- Integración en JupyterLab e interfaces gráficas de usuario.
- Utilizar una amplia gama de paquetes de terceros basados en Matplotlib.

Basic


Basic plot types, usually y versus x.




`plot(x, y)`




`scatter(x, y)`




`bar(x, height)`




`stem(x, y)`



`step(x, y)`




`fill_between(x, y1, y2)`




`stackplot(x, y)`

Plots of arrays and fields


Plotting for arrays of data `Z(x, y)` and fields `U(x, y)`, `V(x, y)`.




`imshow(Z)`




`pcolormesh(X, Y, Z)`




`contour(X, Y, Z)`




`contourf(X, Y, Z)`



`barbs(X, Y, U, V)`




`quiver(X, Y, U, V)`




`streamplot(X, Y, U, V)`

Statistics plots


Plots for statistical analysis.




hist(x)




boxplot(X)




errorbar(x, y, yerr, xerr)




violinplot(D)




eventplot(D)



hist2d(x, y)




hexbin(x, y, C)




pie(x)

Unstructured coordinates


Sometimes we collect data z at coordinates (x, y) and want to visualize as a contour. Instead of gridding the data and then using `contour`, we can use a triangulation algorithm and fill the triangles.




tricontour(x, y, z)



tricontourf(x, y, z)




tripcolor(x, y, z)




triplot(x, y)

3D


3D plots using the `mpl_toolkits.mplot3d` library.




3D scatterplot




3D surface



Triangular 3D surfaces



3D voxel / volumetric plot




3D wireframe plot




Seaborn es una biblioteca de visualización basada en **matplotlib** para dibujar gráficos estadísticos atractivos e informativos.


- La biblioteca Seaborn ofrece varias ventajas importantes: distintos tipos de visualizaciones, sintaxis reducida y temas predeterminados muy atractivos.
- Es una herramienta ideal para la **visualización estadística**. Se utiliza para resumir **datos** en visualizaciones y distribución de datos.
- Además, Seaborn está mejor integrado que Matplotlib para trabajar con data frames de Pandas.

Example gallery






(Go to live notebook)



Extra Libro



- 04.00-Introduction-To-Matplotlib.ipynb
- 04.01-Simple-Line-Plots.ipynb
- 04.02-Simple-Scatter-Plots.ipynb
- 04.03-Errorbars.ipynb
- 04.04-Density-and-Contour-Plots.ipynb
- 04.05-Histograms-and-Binnings.ipynb
- 04.06-Customizing-Legends.ipynb
- 04.07-Customizing-Colorbars.ipynb
- 04.08-Multiple-Subplots.ipynb
- 04.09-Text-and-Annotation.ipynb
- 04.10-Customizing-Ticks.ipynb
- 04.11-Settings-and-Stylesheets.ipynb
- 04.12-Three-Dimensional-Plotting.ipynb
- 04.13-Geographic-Data-With-Basemap.ipynb
- 04.14-Visualization-With-Seaborn.ipynb
- 04.15-Further-Resources.ipynb

*Obligatorio

Instrucciones (opcional)

Crear un repositorio para cargar las prácticas realizadas en formato Notebook de Python, e.g., Github.

La primera práctica consiste en seleccionar un *Dataset* de interés, y realizar un análisis exploratorio, detallando en cada bloque de código las funciones aplicadas, y considerando las buenas prácticas de programación (<https://mitcommlab.mit.edu/broad/commkit/coding-and-comment-style/>).

El dataset seleccionado deberá cumplir con los siguientes requisitos:

- Al menos 500 registros y 10 atributos.
- Al menos 2 atributos numéricos y 2 atributos categóricos.
- Al menos un atributo que pueda funcionar como variable objetivo.
- Datos reales, presentando al menos una de las siguientes condiciones: valores faltantes, registros duplicados, inconsistencias de codificación, o valores fuera de rango.
- Procedencia verificable: fuente, fecha de recolección, unidad de observación y licencia de uso, con enlace público al origen.
- No se aceptan los conjuntos de uso didáctico con soluciones publicadas, e.g., iris, titanic, wine, penguins, mtcars, Boston housing, etc.

El análisis exploratorio deberá incluir:

- La descripción del contexto y la procedencia del dataset: qué mide, quién lo recolectó, cuándo, y cuál es la unidad de observación.
- La verificación de la estructura: dimensiones y tipo de cada atributo, incluyendo una celda inicial que compruebe el cumplimiento de los requisitos anteriores.
- El análisis de la calidad de los datos: patrón de valores faltantes, duplicados, valores imposibles, y cardinalidad de los atributos categóricos.
- El análisis univariado: distribución y estadísticos descriptivos de los atributos relevantes.
- El análisis bivariado: relaciones entre pares de atributos, justificando cuáles se exploran y por qué.
- Al menos una vista multivariada, e.g., matriz de correlación, matriz de dispersión, o el uso del color como tercera dimensión.
- La interpretación escrita de cada figura: qué se observa y qué implica. No se aceptan gráficas sin lectura.
- Un cierre con al menos tres hallazgos, las preguntas que abre el dataset, y los problemas que requerirían corrección antes de cualquier análisis posterior.

El repositorio deberá incluir un README con la descripción del dataset, los requisitos de ejecución, y las instrucciones de uso. Se entregará el enlace al repositorio y el notebook en la plataforma del curso.

hussein@cicese.edu.mx

