

Limpieza de datos

Joan Raygoza



¿Qué es la limpieza de datos?

- Proceso para:
 - Detectar problemas de calidad.
 - Corregir errores verificables.
 - Tratar valores faltantes.
 - Estandarizar representaciones.
- La limpieza implica decisiones metodológicas, no solamente operaciones automáticas.



Data Cleaning

Limpieza, transformación e ingeniería

- **Limpieza**


- Corrige errores, faltantes, duplicados e inconsistencias.

- **Transformación**

- Cambia la representación mediante escalamiento, codificación o transformaciones matemáticas.


- **Ingeniería de características**

- Construye variables nuevas usando conocimiento del problema.



Garbage in, garbage out

- Un modelo puede aprender perfectamente una representación incorrecta del problema.
- Un algoritmo avanzado/complejo no corrige automáticamente:
 - Etiquetas incorrectas.
 - Sesgos de muestreo.
 - Errores sistemáticos.
 - Variables mal definidas.
 - Fuga de información.



Consecuencias de una limpieza deficiente

Estimaciones sesgadas.

Relaciones espurias.

Pérdida de información.

Rendimiento artificialmente alto.

Predicciones poco confiables.

Resultados imposibles de reproducir.

Calidad de los datos

La calidad depende del objetivo.

Un conjunto puede ser:

- Adecuado para generar reportes estadísticos.
- Insuficiente para hacer inferencia.
- Útil para describir.
- Válido para una población, pero no para otra.

Dimensiones de calidad

Compleitud

- ¿Están disponibles los valores necesarios?

Validez

- ¿Los valores cumplen el formato y dominio esperados?

Consistencia

- ¿Los valores concuerdan entre variables y fuentes?

Exactitud

- ¿Representan correctamente el fenómeno?

Unidad de análisis

¿Qué representa exactamente una fila?

Puede representar:

- Una persona.
- Una medición.
- Una transacción.
- Un evento.
- Una imagen.

Diccionario de datos

- Debe incluir:
 - Nombre de la variable.
 - Descripción.
 - Tipo esperado.
 - Unidad.
 - Rango válido.
 - Categorías permitidas.
 - Significado de códigos especiales.
 - Fuente de la información.

Auditoría inicial


- ¿Cuántas filas y columnas existen?
- ¿Los tipos son correctos?
- ¿Las escalas son razonables?
- ¿Qué variables requieren revisión?
- **Problemas frecuentes:**
 - Números almacenados como texto.
 - Fechas almacenadas como cadenas.
 - Identificadores tratados como cantidades.
 - Booleanos representados como "Sí" y "No".
 - Categorías mezcladas con valores numéricos.

Perfil de variables


- **En variables numéricas examinar:**
 - Mínimo y máximo.
 - Media y mediana.
 - Desviación estándar.
 - Cuantiles.
 - Asimetría.
 - Valores únicos.
 - Valores físicamente imposibles.
- **En variables categóricas buscar:**
 - Categorías raras.
 - Variantes ortográficas.
 - Espacios adicionales.
 - Códigos desconocidos.
 - Diferencias entre mayúsculas y minúsculas.

Diagnóstico visual


- Histograma: forma y distribución.
- Boxplot: dispersión y extremos.
- Gráfica de barras: frecuencia de categorías.
- Mapa de calor: patrones de ausencia.




Histograma



Gráfica de barras



Boxplot



Mapa de calor

Datos faltantes

¿Por qué falta este valor?

La ausencia puede representar:

- Una falla de captura.
- Una pregunta no contestada.
- Un sensor desconectado.
- Una variable que no aplica.
- Un dato eliminado deliberadamente.

Representaciones de ausencia

- Los faltantes pueden aparecer como:
 - NaN
 - None
 - Cadena vacía
 - "N/A"
 - "Desconocido"
 - -999
 - 99
 - 0
 - Una fecha imposible
- Antes de cuantificarlos, deben estandarizarse.




Patrones de ausencia

- Analizar faltantes:
 - Por variable.
 - Por observación.
 - Por grupo o población.
 - Por periodo.
 - Por instrumento.
 - Por fuente de datos.
 - En combinación con otras variables.

Eliminación de filas

- Puede considerarse cuando:
 - La proporción es pequeña.
 - Las filas no pertenecen a un grupo específico.
 - La información faltante es desechable.
 - Existe suficiente muestra restante.
- **Riesgos:**
 - Reducir potencia estadística.
 - Cambiar la composición de la muestra.
 - Introducir sesgo.



Eliminación de variables

- Puede considerarse cuando:
 - Tiene una proporción muy alta de ausencia.
 - Su calidad es baja.
 - No resulta esencial.
 - Otras variables contienen información equivalente.

Imputación simple

- **Media**
 - Adecuada solamente en casos limitados.
 - Sensible a extremos.
 - Reduce artificialmente la varianza.
- **Mediana**
 - Más robusta en distribuciones asimétricas.
- **Moda**
 - Puede utilizarse en variables categóricas.
 - Aumenta la frecuencia de la categoría dominante.

Interpolación

- Útil en datos:
 - Temporales.
 - Espaciales.
 - Provenientes de sensores.
- **Métodos:**
 - Lineal.
 - Polinomial.
 - Spline.
 - Hacia adelante.
 - Hacia atrás.

Imputación multivariante

- **KNN Imputer**

- Usa observaciones similares.
- Depende de la escala y métrica de distancia.

- **Imputación iterativa**

- Modela cada variable incompleta usando las demás.
- Puede preservar relaciones multivariantes.
- Ambas requieren validación.

Unidades incompatibles

- Ejemplo:
 - Altura en metros y centímetros.
 - Temperatura en Celsius y Fahrenheit.
 - Masa en gramos y kilogramos.



Fechas problemáticas



- Problemas comunes:
 - 03/04/2026 puede tener dos interpretaciones.
 - Fechas imposibles.
 - Zonas horarias ausentes.
 - Formatos mezclados.
 - Fechas futuras inesperadas.

Restricciones entre variables


Una columna puede ser válida individualmente y contradictoria en combinación.

Ejemplos:

- Fecha de egreso anterior al ingreso.
- Edad incompatible con fecha de nacimiento.
- Precio final mayor que precio original sin recargo.
- Paciente marcado como fallecido con consultas posteriores.


Duplicados

- Duplicados exactos
- Duplicados según una clave
- Ejemplo:
 - Un paciente puede aparecer muchas veces.
 - Un paciente en la misma fecha puede representar un duplicado o varias pruebas.




Valores atípicos

- Un valor atípico puede ser:
 - Un error de captura.
 - Un fallo instrumental.
 - Una observación válida poco frecuente.
 - Un cambio en el sistema.
 - El evento científicamente más interesante.
- Detectar un valor atípico no justifica eliminarlo.




Atípicos univariantes

- Se identifican respecto a una variable.
- Métodos:
 - Inspección del histograma.
 - Boxplot.
 - Rango intercuartíl.
 - Puntaje Z.
 - Mediana y MAD.
- El método debe considerar la distribución.




Regla del rango intercuartílico

- $IQR = Q_3 - Q_1$
- Límite inferior:
 - $L_i = Q_1 - 1.5 * IQR$
- Límite superior:
 - $L_s = Q_3 + 1.5 * IQR$
- Los valores fuera de estos límites podríamos considerarlos como valores atípicos.



Atípicos multivariantes

- Una observación puede parecer normal en cada variable, pero extraña en combinación.
- Ejemplo:
 - Edad: válida.
 - Ingreso: válido.
 - Combinación edad–ingreso: muy improbable.
- **Métodos:**
 - Isolation Forest.
 - Local Outlier Factor.





Tratamiento de valores atípicos


- Opciones:
 - Corregir desde la fuente.
 - Eliminar con justificación.
 - Transformar la escala.
 - Usar métricas robustas.
 - Utilizar modelos robustos.

Sesgo introducido por la limpieza

- Ejemplos:
 - Eliminar casos incompletos excluye una población.
 - Imputar la media reduce la variabilidad.
 - Eliminar extremos borra eventos relevantes.
 - Fusionar categorías elimina diferencias.
 - Filtrar mediciones difíciles produce resultados artificialmente buenos.

Transformación de variables

- Una transformación cambia la representación matemática de una variable.
- Objetivos frecuentes:
 - Reducir asimetría.
 - Disminuir la influencia de valores extremos.
 - Estabilizar la varianza.
 - Aproximar una distribución simétrica.
 - Convertir relaciones no lineales en relaciones más simples.
 - Facilitar el aprendizaje del modelo.
- La transformación modifica la forma de la distribución; el escalado modifica principalmente su magnitud.



¿Por qué transformar una variable?

- Considere una variable con distribución muy asimétrica, como el ingreso.
- Sin transformación:
 - Unos pocos valores dominan la escala.
 - La media resulta poco representativa.
 - La relación con la variable objetivo puede ser no lineal.



¿Qué es el escalado?

- El escalado modifica el rango o dispersión de una variable sin cambiar necesariamente la forma de su distribución.
- Sin escalado, las variables con valores numéricos grandes pueden dominar:
 - Distancias.
 - Gradientes.
 - Penalizaciones.
 - Componentes principales.

Escalado estándar

- Este escalado transforma cada observación mediante:

$$z_i = \frac{x_i - \mu}{\sigma}$$

- Después de la transformación:

$$\mu_z \approx 0 \quad \sigma_z \approx 1$$

- Conserva:
 - La forma de la distribución.
 - El orden de las observaciones.
 - La presencia de valores atípicos.

Escalado mínimo– máximo

- Transforma una variable al intervalo $[0, 1]$:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

- La ventaja es que produce un intervalo conocido.
- La limitación es que resulta muy sensible a valores extremos.

Escalado robusto

- Utiliza la mediana y el rango intercuartíl:

$$x' = \frac{x - \tilde{x}}{Q_3 - Q_1}$$

- La ventaja es que reduce la influencia de valores extremos.
- Pero no elimina los atípicos, solamente disminuye su efecto sobre el escalado.

+

•

○

Modelos sensibles al escalado

- El escalado suele ser importante para:
 - K vecinos más cercanos (KNN).
 - K-means.
 - Máquinas de vectores de soporte (SVM).
 - Regresión lineal.
 - Regresión logística.
 - Redes neuronales.
- Motivo:
 - Utilizan distancias.
 - Utilizan productos internos.
 - Optimizan mediante gradientes.
 - Penalizan el tamaño de los coeficientes.


+ • Modelos ◦ menos sensibles al escalado

- Los árboles de decisión generalmente no requieren escalado:
 - Árbol de decisión.
 - Random Forest.
 - Gradient Boosting.
 - XGBoost.
 - LightGBM.
- Estos modelos dividen una variable según umbrales:
$$x_j < c$$
- Una transformación monotónica conserva el orden de los valores.
- Aun así, el escalado puede ser necesario si el árbol forma parte de un pipeline con otros métodos.

Transformar la variable objetivo

- En regresión, también puede transformarse y con alguno de los métodos anteriormente mencionados.
- El modelo se entrena en la escala transformada y predice valores transformados.
- Después tenemos que regresarlos a la escala original.
- Las métricas finales deben calcularse en la escala que corresponda al objetivo del problema.

Costo de la baja calidad de los datos



Gracias

jraygoza@cicese.edu.mx