




Aumento de datos

Joan Raygoza



Class Imbalance



Over-sampling



Under-sampling



**Data
Augmentation**

¿Qué es el aumento de datos?


- El **aumento de datos** consiste en generar nuevas muestras de entrenamiento a partir de los datos existentes mediante transformaciones o modelos generativos, preservando la información relevante para la tarea.
- No busca crear datos completamente nuevos, sino producir **variaciones plausibles** que aumenten la diversidad del conjunto de entrenamiento.

¿Qué es el aumento de datos?

- El aumento de datos busca:
 - Incrementar el tamaño efectivo del dataset.
 - Reducir el sobreajuste (*overfitting*).
 - Mejorar la capacidad de generalización.
 - Hacer los modelos más robustos frente a variaciones del mundo real.
- El aumento de datos **no crea información nueva**, sino nuevas formas de presentar la información ya existente.

Datos reales vs datos sintéticos

- **Datos sintéticos:** Son muestras generadas artificialmente que intentan seguir la misma distribución que los datos reales.
- **Ventajas**
 - Más ejemplos
 - Balanceo de clases
 - Mayor privacidad
 - Menor costo de adquisición
- **Riesgos**
 - Distribución incorrecta
 - Sesgos
 - Ejemplos irreales
 - Data Leakage



“

ORIGINAL


“The weather was very rainy, so he decided to pack accordingly. He brought rain boots, an umbrella, and a waterproof jacket. Although there was heavy cloud cover, the news said it was going to lighten up by the afternoon, so he packed his favorite sunglasses.”

“


PARAPHRASE

“He packed ahead for the rainy day, and he also brought sunglasses in case it got sunny.”


Original Data




Jitter




Awareness




Flip



Shrink



Stretch



Original image



Horizontally



Vertically



Rotation left



Rotation Right




¿Por qué funciona el aumento de datos?

Regularización: El aumento de datos actúa como una regularización implícita, impide que el modelo memorice ejemplos específicos.

Robustez: El modelo aprende a tolerar ruido y pequeñas deformaciones sin modificar la predicción.

Espacio de características: Cada instancia ocupa una pequeña region, con el aumento de datos estas regiones se expanden.



Tipos de aumento de datos

Basado en transformaciones

- Se aplican modificaciones directamente sobre los datos originales sin alterar su etiqueta (rotación, escalamiento, ruido, recorte e inversión horizontal).

Basado en modelos generativos

- Se entrenan modelos capaces de generar nuevas muestras sintéticas (GANs, VAEs, modelos de difusión y LLMs).

Mezcla de muestras

- Se combinan dos o más ejemplos existentes para generar uno nuevo (SMOTE, interpolación temporal, CutMix y MixUp).

Balanceo de clases

Muchos conjuntos de datos presentan clases muy desbalanceadas.

Random OverSampling

- Duplica aleatoriamente ejemplos de la clase minoritaria.
- **Ventajas:** Simple y no eliminan información.
- **Limitaciones:** Duplicas exactamente los mismos ejemplos y puede aumentar el sobreajuste.


Random UnderSampling

- Elimina ejemplos de la clase mayoritaria.
- **Ventajas:** Reduce tiempo de entrenamiento y balancea rápidamente.
- **Limitaciones:** Puede eliminar información importante y reduce el tamaño del dataset.


Datos tabulares

- En datos tabulares tenemos variables continuas y categóricas, las técnicas de aumento deben respetar cada tipo de variable.
- El principal reto del aumento tabular es **preservar la distribución conjunta** de todas las variables, no únicamente generar nuevos valores individuales.

Real data



Real + Augmented Data



Métodos clásicos

- **Ruido Gaussiano**

- Consiste en añadir un pequeño ruido aleatorio a variables continuas.

$$x' = x + \epsilon$$

- donde

$$\epsilon \sim \mathcal{N}(0, \sigma^2)$$

- **Jittering**

- Es una aplicación práctica del ruido Gaussiano con una varianza pequeña para generar ligeras perturbaciones.
- Muy utilizado cuando existe ruido natural en las mediciones.

Métodos clásicos

- **Escalamiento**

- Modificar ligeramente la magnitud de una variable.

$$x = \alpha x$$

- donde

$$\alpha \approx 1$$

- **Permutación**

- Intercambiar valores entre observaciones o atributos bajo ciertas condiciones.


SMOTE (Synthetic Minority Over- sampling Technique)

- El problema del oversampling es que simplemente copiar ejemplos no genera nueva información.
- SMOTE genera ejemplos sintéticos mediante **interpolación** entre vecinos cercanos.
- **Algoritmo**
 - Seleccionar una muestra minoritaria.
 - Buscar sus **k vecinos** más cercanos.
 - Elegir uno aleatoriamente.
 - Interpolar entre ambos.

$$x_{new} = x_i + \lambda(x_j - x_i)$$

- donde

$$0 < \lambda < 1$$




SMOTE (Synthetic Minority Over- sampling Technique)

- **Ventajas**

- Genera nuevos ejemplos.
- Reduce overfitting.
- Preserva la estructura local.


- **Limitaciones**

- Puede generar ejemplos en regiones incorrectas.
- No considera la distribución global.
- Sólo funciona con variables continuas.



Variantes de SMOTE

- **Borderline-SMOTE:** Solo genera ejemplos cerca de la frontera entre clases.
- **ADASYN (Adaptive Synthetic Sampling):** Genera más ejemplos en regiones donde el problema es más complejo.
- **SMOTE-NC (Nominal Continuous):** Extiende SMOTE para trabajar con variables continuas y variables categóricas simultáneamente.





Aumento en series de tiempo

- El objetivo es generar nuevas series plausibles, coherentes y preservando la dinámica temporal.
- **Transformaciones clásicas**
 - **Jittering:** Añade ruido gaussiano.
 - **Scaling:** Multiplica toda la señal por un factor.
 - **Magnitude Warping:** Como scaling pero el factor cambia suavemente a lo largo del tiempo.




Aumento en series de tiempo

- El objetivo es generar nuevas series plausibles, coherentes y preservando la dinámica temporal.
- **Transformaciones temporales**
 - **Time Warping:** Algunas regiones se aceleran.
 - **Window Warping:** Se selecciona una Ventana y se estira o comprime únicamente esa región.
 - **Window Slicing:** Se elimina una pequeña ventana temporal.



Aumento en series de tiempo

- El objetivo es generar nuevas series plausibles, coherentes y preservando la dinámica temporal.
- **Otras técnicas**
 - **Permutation:** La serie se divide en segmentos y estos se reorganizan.
 - **Time Series Interpolation:** Interpolación entre dos series.
 - **Time Series Combination:** Combinación lineal entre dos series.
 - **Bootstrapping:** Remuestreo de bloques temporales.



Aumento en imágenes

- Las imágenes presentan muchas variaciones que **no cambian la clase**.
- **Transformaciones geométricas**
 - Rotación.
 - Flip Horizontal.
 - Flip Vertical.
 - Crop: Simula zoom y objetos parcialmente visibles.
 - Traslación.

Aumento en imágenes

- Las imágenes presentan muchas variaciones que **no cambian la clase**.
- **Transformaciones fotométricas**
 - Brillo.
 - Contraste.
 - Saturación.
 - Blur.
 - Ruido.

Aumento en imágenes

- Las imágenes presentan muchas variaciones que **no cambian la clase**.
- **Mezcla de imágenes**
 - Mixup: Se toman dos imágenes y se calcula el promedio lineal.
 - CutMix: En lugar de promediar, copia una región de otra imagen.

Original Image



Horizontal



Vertically



+45 Rotation



-45 Rotation



Blur



Brighter



Noise added



Darker



Grayscale



Crop



Augmented Images

Image 1





Image 2



CutMix (Mixing Ratio: 0.90)




Image 1







Image 2



MixUp (Mixing Ratio: 0.70)







Aumento en texto

- En imágenes, una pequeña rotación normalmente no cambia la clase.
- En texto, modificar una sola palabra puede cambiar completamente el significado.
- **Easy Data Augmentation (EDA)**
 - Reemplazo de sinónimos.
 - Inserción aleatoria.
 - Intercambio aleatorio.
 - Eliminación aleatoria.



Aumento en texto

- **Back Translation:** Traducir el texto a otro idioma y volver al idioma original.
- **Ventajas**
 - Conserva la semántica.
 - Produce expresiones naturales.
 - Introduce diversidad sintáctica.
- **Limitaciones**
 - Costoso computacionalmente.
 - Depende de la calidad del traductor.
 - Puede alterar matices del significado.



Aumento en texto

- **Embedding-based Augmentation:** Utilizar embeddings para encontrar palabras semánticamente similares.
- **Ventajas**
 - Reemplazos más coherentes.
 - Conserva relaciones semánticas.
 - Más robusto que EDA.
- **Limitaciones**
 - Los embeddings clásicos no consideran completamente el contexto.
 - Dependencia de la calidad de los embeddings.



Aumento en texto

- **LLMs para aumento de texto:** Los LLMs pueden generar múltiples versiones de un mismo texto.
- **Ventajas**
 - Excelente calidad.
 - Preservan semántica.
 - Muy flexibles.
- **Limitaciones**
 - Costo elevado.
 - Para ciertas tareas complejas no logran hacerlo correctamente (ironía, sarcasmo o comedia).

¿Cómo elegir una técnica de aumento?

- **No existe una técnica que sea mejor siempre**
- La elección depende de tipo de dato, problema, modelo, cantidad de datos y/o conocimiento del dominio.
- Cada dominio posee invariancias distintas.

¿Cómo influye el tamaño del dataset?

- **Dataset pequeño**
 - Menos de unos pocos miles de ejemplos.
 - **Recomendaciones**
 - Aumento de datos
 - Transfer Learning
 - Fine-Tuning
- **Dataset mediano**
 - Se puede combinar
 - Aumento de datos
 - Modelos generativos
 - Datos reales
- **Dataset muy grande**
 - El beneficio del aumento de datos suele disminuir.
 - Es preferible mejorar
 - Calidad
 - Diversidad
 - Etiquetado

¿Cómo evaluar el aumento de datos?

- **¿Cómo sabemos si realmente funcionó?**
- **Validación:** Comparar el modelo sin aumento y con aumento.
- Utilizar las métricas adecuadas según sea el problema.
- **Importante:** No evaluar únicamente sobre entrenamiento. El objetivo es mejorar el conjunto de prueba.

Data Leakage

- **Uno de los errores más comunes** es aplicar aumento de datos ANTES de dividir entrenamiento y prueba.
- Las versiones sintéticas de un dato pueden terminar tanto en entrenamiento como en prueba.
- El modelo ve prácticamente el mismo ejemplo en ambos conjuntos por lo que las métricas quedan artificialmente infladas.

Estudio de ablación

Consiste en eliminar o añadir componentes del sistema para medir su contribución.

Configuración	Accuracy
Sin aumento	91.2
+ Rotación	93.5
+ Rotación + Ruido	94.0
+ Rotación + Ruido + CutMix	95.1

Conclusiones

- Ninguna técnica garantiza por sí sola una mejora del rendimiento.
- La elección debe estar guiada por el tipo de dato, el conocimiento del dominio y una evaluación experimental rigurosa.
- En investigación, el valor del ***aumento de datos*** no reside en generar más datos, sino en generar ejemplos **plausibles, diversos y representativos** que permitan mejorar la capacidad de generalización del modelo.

Muchas gracias

jraygoza@cicese.edu.mx