




Ingenieria de Características

Joan Raygoza

Feature Engineering

Machine learning



Input



Iris Versicolor



Iris Setosa



Iris Virginica

Feature
extraction

Output

	sepalength	sepalwidth	petallength	petalwidth	class
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa
...	...	...	...	...	...
145	6.7	3.0	5.2	2.3	Iris-virginica
146	6.3	2.5	5.0	1.9	Iris-virginica
147	6.5	3.0	5.2	2.0	Iris-virginica
148	6.2	3.4	5.4	2.3	Iris-virginica
149	5.9	3.0	5.1	1.8	Iris-virginica

150 rows x 5 columns

Aprendizaje automático clásico

Datos etiquetados



Iris Versicolor



Iris Setosa




Iris Virginica

Extracción y selección de características




Clasificación



*versicolor,
setosa,
virginica*

Aprendizaje profundo



Extracción de características

Clasificación

*versicolor,
setosa,
virginica*

¿Qué es una característica?

Dato original	Ejemplos de características
Documento	Frecuencia de palabras o expresiones
Imagen	Distribución de colores, textura y forma
Audio	Distribución de energía en tiempo y frecuencia

- Una **característica** es una propiedad medible utilizada para describir una observación.
- Una observación puede representarse mediante un vector:

$$\mathbf{x} = [x_1, x_2, \dots, x_d]^\top$$

- Cada componente describe un aspecto del dato.



¿Qué es la ingeniería de características?

- Es el proceso de diseñar representaciones que permitan analizar datos y resolver una tarea.

Dato original $\xrightarrow{\phi}$ Representación numérica

- La función ϕ transforma el dato.
- La representación depende del problema.
- El conocimiento del dominio orienta su diseño.
- Una misma observación puede tener varias representaciones útiles.

Construcción, extracción y selección

Proceso	Propósito	Ejemplo
Construcción	Crear variables a partir de otras	Operación entre dos mediciones
Extracción	Obtener descriptores del dato original	Calcular MFCC de una señal
Selección	Conservar un subconjunto de características	Elegir términos relevantes

- Los procesos pueden combinarse.
- En esta clase, el énfasis estará en la **extracción y representación**.
- La selección requiere evaluar qué características aportan a la tarea.



Representaciones locales y globales

- **Locales**
 - Describen regiones, ventanas o fragmentos.
 - Conservan información sobre variaciones dentro del dato.
- **Globales**
 - Resumen la observación completa.
 - Facilitan construir vectores de tamaño fijo.
- Depende de cuánto detalle local necesita el problema.

Propiedades de una representación útil

- **Relevancia:** describe aspectos relacionados con la tarea.
- **Robustez:** tolera pequeñas perturbaciones o ruido.
- **Invariancia:** permanece estable ante transformaciones específicas.
- **Sensibilidad:** detecta cambios que sí importan.
- **Interpretabilidad:** permite comprender sus componentes.
- **Eficiencia:** tiene un costo y una dimensionalidad manejables.


Representar implica perder información

$$\mathbf{x} = \phi(s)$$


- Si dos datos distintos producen la misma representación:

$$\phi(s_1) = \phi(s_2)$$

- Un análisis basado únicamente en esas características no podrá distinguirlos.
- Un histograma de color pierde la ubicación de los píxeles.
- BoW con unigramas pierde el orden de las palabras.
- Promediar MFCC pierde la secuencia temporal.
- **La pérdida de información debe ser compatible con la tarea.**



 Los documentos tienen longitud variable y contenido simbólico.





Para representarlos
necesitamos:

- Dividir el texto en unidades.
- Construir un vocabulario.
- Asignar un valor a cada término.
- Organizar los valores en una matriz.



Para representarlos
necesitamos:

- Dividir el texto en unidades.
- Construir un vocabulario.
- Asignar un valor a cada término.
- Organizar los valores en una matriz.



Tokenización y vocabulario

- La **tokenización** divide el texto en unidades llamadas tokens.
- Ejemplo:
 - “El modelo aprende patrones”
 - [el, modelo, aprende, patrones]
- El vocabulario reúne las unidades consideradas:
$$V = \{t_1, t_2, \dots, t_{|V|}\}$$
- Cada término ocupa una posición.
- Todos los documentos utilizan el mismo orden de columnas.
- El vocabulario se construye con los datos de entrenamiento.


Bag of Words

- **Bag of Words (BoW):** representa un documento mediante la presencia o frecuencia de sus términos.

$$x_j = \text{conteo}(t_j, d)$$

- Cada columna corresponde a un término.
- Cada valor indica cuántas veces aparece.
- Documentos de diferente longitud quedan representados en el mismo espacio.

$$x_d \in \mathbb{R}^{|V|}$$



Bag of Words Model explanation

Corpus

A collection of text documents



Tokenize

Divide the text into smaller units called tokens, usually words or phrases



Count word frequencies

Create a vocabulary of unique words and count the number of times each word appears in each document.



Encode the data

Encoding the text data as numerical values by creating a vector for each document, with each element of the vector representing the frequency count of a particular word in the document

Example

Corpus:

The dog is happy. The child makes the dog happy. The dog makes the child happy



Tokenization:

D1: [The] [dog] [is] [happy]

D2: [The] [child] [makes] [the] [dog] [happy]

D3: [The] [dog] [makes] [the] [child] [happy]



Documents	Counting word frequencies
D1	the: 1, dog: 1, is: 1, happy: 1
D2	the: 2, dog: 1, makes: 1, child: 1, happy: 1
D3	the: 2, child: 1, makes: 1, dog: 1, happy: 1



Encode	child	dog	happy	is	makes	the	BoW Vector representations
D1	0	1	1	1	0	1	[0,1,1,1,0,1]
D2	1	1	1	0	1	2	[1,1,1,0,1,2]
D3	1	1	1	0	1	2	[1,1,1,0,1,2]

Variantes de BoW

- **Presencia binaria**

$$x_j = \mathbb{1}[t_j \in d]$$

- Indica si el término aparece.

- **Conteo**

$$x_j = c(t_j, d)$$

- Conserva el número de apariciones.

- **Frecuencia relativa**

$$x_j = \frac{c(t_j, d)}{\sum_k c(t_k, d)}$$

- Reduce el efecto directo de la longitud del documento.
- **La elección depende de si la repetición aporta información.**

Limitaciones de BoW con unigramas

- Pierde el orden de las palabras.
- No representa explícitamente relaciones gramaticales.
- Trata sinónimos como términos distintos.
- No distingue los significados de una palabra según su contexto.
- Produce vectores de alta dimensión y muchos ceros.
- Ejemplo:
 - “el perro persigue al gato”
“el gato persigue al perro”
- Ambas oraciones tienen los mismos conteos de palabras, pero describen situaciones diferentes.

N-gramas de palabras

- Un **n-grama** es una secuencia de n tokens consecutivos.
- Capturan orden dentro de una ventana local.
- Permiten representar expresiones.
- Pueden combinarse varios valores de n .

Tipo	Unidades
Unigramas	El, modelo, aprende, patrones
Bigramas	el modelo, modelo aprende, aprende patrones
Trigramas	el modelo aprende, modelo aprende patrones

N-gramas de caracteres

- Se construyen sobre secuencias de caracteres.
- Ejemplo: trigramas de “datos”
[dat, ato, tos]
- Pueden ser útiles para representar:
 - Fragmentos morfológicos.
 - Variantes ortográficas.
 - Palabras con errores.
 - Términos poco frecuentes.
- **Limitación:** también generan fragmentos sin significado claro y aumentan el vocabulario.

Term Frequency– Inverse Document Frequency (TF-IDF)

- Busca ponderar términos considerando:
 - Su frecuencia dentro de un documento.
 - Su frecuencia de aparición en el conjunto de documentos.
- Un término recibe más peso cuando:
 - Aparece frecuentemente en un documento.
 - Aparece en relativamente pocos documentos del corpus.

$$\text{TF-IDF}_{(n,d)} = \text{TF}_{(n,d)} \times \text{IDF}_{(n)}$$

Peso de un término (n) en un documento (d)	Frecuencia de aparición de un término (n) en un documento (d)	Factor IDF de un término (n)
--	---	------------------------------

TF-IDF

- Una formulación básica es:

$$TF - IDF(t, d) = TF(t, d) * IDF(t)$$

$$IDF(t) = \ln \left(\frac{N}{df(t)} \right)$$
- Donde:
 - N : número de documentos.
 - $df(t)$: documentos que contienen el término.
 - $TF(t, d)$: frecuencia del término en el documento.


	tf(t, d)							
	blue	bright	can	see	shining	sky	sun	today
1	1/2	0	0	0	0	1/2	0	0
2	0	1/3	0	0	0	0	1/3	1/3
3	0	1/3	0	0	0	1/3	1/3	0
4	0	1/6	1/6	1/6	1/6	0	1/3	0

- TF-IDF: Multiply TF and IDF scores, use to rank importance of words within documents
- Most important word for each document is highlighted

X

	idf(t, D)							
	blue	bright	can	see	shining	sky	sun	today
	0.602	0.125	0.602	0.602	0.602	0.301	0.125	0.602

$$tfidf(t, d, D) = tf(t, d) \cdot idf(t, D)$$



	blue	bright	can	see	shining	sky	sun	today
1	0.301	0	0	0	0	0.151	0	0
2	0	0.0417	0	0	0	0	0.0417	0.201
3	0	0.0417	0	0	0	0.100	0.0417	0
4	0	0.0209	0.100	0.100	0.100	0	0.0417	0

¿Qué podemos describir en una imagen?









- La representación adecuada depende de la señal visual relevante.
- **Ejemplo:** reconocer una textura puede requerir características diferentes a reconocer una silueta.

Propiedad	Descriptor
Distribución de colores	Histograma de color
Patrones locales de textura	LBP
Orientaciones de bordes y contornos	HOG
Distribución espacial de una forma	Momentos de Hu

Preparación de imágenes

- Antes de extraer características:
 - Definir la región de interés.
 - Elegir la resolución.
 - Seleccionar el espacio de color.
 - Convertir a escala de grises cuando corresponda.
 - Segmentar el objeto si el descriptor requiere su forma.
- **El preprocesamiento modifica el descriptor.**
- Ejemplos:
 - Cambiar la resolución afecta detalles de textura.
 - Una segmentación incorrecta altera los momentos de Hu.
 - Cambiar de RGB a HSV modifica la interpretación del histograma de color.

Histogramas de color



- Un histograma cuenta cuántos píxeles pertenecen a cada intervalo de valores.

$$h_b = \sum_{p=1}^P \mathbb{1} [I(p) \in B_b]$$

- Donde:
 - P : número de píxeles.
 - $I(p)$: valor del píxel.
 - B_b : intervalo o bin b .
- El histograma describe **cuánto aparece cada color**, sin indicar dónde aparece.

Número de bins y normalización

- Con B bins por canal:
 - Tres histogramas independientes: $3B$ características.
- Para $B = 8$:

$$3B = 24$$

- Normalización por el total de conteos:

$$\hat{h}_b = \frac{h_b}{\sum_j h_j}$$

- Pocos bins: representación más compacta.
- Muchos bins: mayor detalle y sensibilidad.
- La normalización reduce la dependencia del número de píxeles.




Histogramas de color: interpretación y limitaciones

- Son simples y de bajo costo.
- Son útiles cuando la distribución de color distingue las observaciones.
- Pierden la disposición espacial.
- Pueden variar por iluminación, fondo y balance de blancos.
- **Pero** podemos reorganizar los mismos píxeles produce una **imagen distinta con un histograma idéntico**.
- Una alternativa para conservar ubicación aproximada:
 - Dividir la imagen en regiones.
 - Calcular un histograma por región.
 - Concatenar los resultados.

Local Binary Pattern (LBP)

- Describe la textura comparando un píxel con sus vecinos.
- Para cada vecino:
 - Valor mayor o igual que el centro: 1.
 - Valor menor que el centro: 0.
- Los bits se combinan para formar un código.
- Puede representar el patrón de contrastes locales alrededor de cada píxel.



LBP

$$\text{LBP}_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p$$
$$s(z) = \begin{cases} 1, & z \geq 0 \\ 0, & z < 0 \end{cases}$$

- Donde:
 - g_c : intensidad central.
 - g_p : intensidad del vecino p .
 - P : número de vecinos.
 - R : radio del vecindario.
- El orden de recorrido de los vecinos debe mantenerse fijo.



LBP: parámetros y limitaciones

- **Radio:** determina la escala espacial del patrón.
- **Número de vecinos:** controla el muestreo del entorno.
- **Variante:** puede agrupar patrones o incorporar invariancia a rotación.
- **Regiones:** determinan cuánto detalle espacial se conserva.
- Propiedades:
 - Es sensible al ruido en regiones casi uniformes.
 - El LBP clásico no es invariante a rotación.


Audio como señal discreta

- Una señal digital se representa como:
 $x[n], n = 0, \dots, N - 1$
- La frecuencia de muestreo f_s indica cuántas muestras se registran por segundo.

- Duración:


$$T = \frac{N}{f_s}$$

- La forma de onda muestra amplitud en el tiempo.
- En audio, el contenido frecuencial cambia durante la grabación.




Análisis por ventanas

- Se divide la señal en segmentos cortos llamadas **ventanas**.
- Parámetros:
 - Longitud de la ventana L .
 - Salto entre ventanas H .
 - Solapamiento $L - H$.




¿Qué es un espectrograma?

- Un espectrograma representa la magnitud o potencia de la STFT (Short Time Fourier Transform).
- Ejes:
 - Horizontal: tiempo.
 - Vertical: frecuencia.
 - Color: magnitud o potencia.



Escala Mel


- La escala Mel proporciona una transformación no lineal de la frecuencia, motivada por la percepción del tono.
- Una formulación habitual:
$$\text{Mel}(f) = 2595 \log_{10} \left(1 + \frac{f}{700} \right)$$
- Se aplica un conjunto de filtros y después el logaritmo para tener la representación log-Mel: tiempo x bandas Mel.




Mel-Frequency Cepstral Coefficients (MFCC)

- Dividir la señal en ventanas.
- Calcular la FFT y el espectro de potencia.
- Integrar energía con filtros Mel.
- Aplicar el logaritmo.
- Calcular la transformada discreta del coseno (DCT).
- Conservar un subconjunto de coeficientes.


Raw Spectrogram Image



Mel-Spectrogram Image



MFCC Feature Image





MFCC: parámetros y representación final

- Parámetros principales:
 - Frecuencia de muestreo.
 - Longitud de ventana y salto.
 - Número y rango de filtros Mel.
 - Número de coeficientes retenidos.
- El MFCC pierde el orden temporal y es un resumen de las variaciones de la representación log-Mel del espectrograma.

Integrar características y evitar fuga de información

- Es posible concatenar descriptores.
- Antes de combinarlos:
 - Revisar escalas y normalizaciones.
 - Considerar la dimensionalidad de cada bloque.
 - Examinar redundancia y costo computacional.
- Para una evaluación válida:
 - Separar entrenamiento y prueba antes de ajustar vocabulario, IDF o escaladores.
 - Mantener sujetos, objetos o grabaciones relacionadas en la partición adecuada.
 - Evitar repartir ventanas de una misma grabación entre entrenamiento y prueba cuando se evalúa generalización a nuevas grabaciones.



Conclusiones

- La ingeniería de características define qué información estará disponible para el análisis.
- BoW y TF-IDF representan términos y los n-gramas incorporan contexto local.
- Histogramas de color y LBP, describen propiedades visuales diferentes.
- Espectrogramas y MFCC ofrecen distintos niveles de detalle del audio.
- La dimensionalidad, la invariancia y la pérdida de información deben responder a la tarea.
- La utilidad se comprueba mediante validación y comparación de descriptores, individualmente y en combinación.