



Selección de características

Joan Raygoza



Dimensionality reduction



Feature selection



¿Qué es la selección de características?

- Partimos de un conjunto:

$$F = \{x_1, x_2, \dots, x_p\}$$

- El objetivo es encontrar un subconjunto:

$$S \subseteq F$$

- Que produzca un modelo con buen desempeño predictivo y menor complejidad.
- La selección no necesariamente busca el subconjunto que maximiza exclusivamente el rendimiento.

¿Qué es la selección de características?

- Puede buscar un compromiso entre:
 - Error predictivo.
 - Número de variables.
 - Tiempo de inferencia.
 - Interpretabilidad.
 - Robustez.
- Una formulación general es:
$$S^* = \arg \min_{S \subseteq F} [\text{Error}(S) + \lambda \mathcal{C}(S)]$$
- donde $\mathcal{C}(S)$ penaliza la complejidad del subconjunto.

Objetivo

- Reducir el número de características tanto como sea posible sin comprometer el desempeño predictivo.
- El modelo con 50 variables tiene el mayor AUC, pero el modelo con 20 podría representar un mejor compromiso entre desempeño y complejidad.

Características	AUC
100	0.912
50	0.914
20	0.910
10	0.896
5	0.842



¿Por qué seleccionar características?

- **Desempeño:** Las variables irrelevantes pueden añadir ruido y facilitar el sobreajuste.
- **Eficiencia:** Menos variables pueden reducir:
 - Uso de memoria.
 - Tiempo de entrenamiento.
 - Tiempo de inferencia.
 - Costo de almacenamiento.
- **Interpretabilidad:** Un conjunto reducido puede ayudar a entender qué información utiliza el modelo.
- **Adquisición de datos:** Algunas variables requieren pruebas médicas, sensores o procesos costosos.
- **Mantenimiento:** Un pipeline con menos entradas suele ser más fácil de validar, desplegar y monitorear.

Características relevantes

- Una característica es relevante cuando contiene información útil para predecir el objetivo.
- **Fuertemente relevante:** Su eliminación produce una pérdida de información que no puede recuperarse mediante las demás variables.
- **Débilmente relevante:** Puede aportar información útil, pero esta información también puede estar parcialmente representada por otras variables.

Características irrelevantes y redundantes

- **Irrelevante:** No contiene una relación útil con el objetivo, ni individualmente ni en combinación con otras variables.
- **Redundante:** Contiene información que ya está representada por otras características.
- Una variable redundante puede ser predictiva, pero no necesariamente indispensable.

Interacciones entre características

- Una variable puede parecer irrelevante individualmente y ser fundamental en combinación con otra.

- Individualmente:

$$I(x_1; y) \approx 0, I(x_2; y) \approx 0$$

- Sin embargo, la combinación de ambas determina completamente el objetivo:

$$y = x_1 \oplus x_2$$

- Esto muestra una limitación importante de la selección univariada.

x1	x2	y
0	0	0
0	1	1
1	0	1
1	1	0

Selección no es causalidad

Una característica seleccionada:


- Es útil para un modelo concreto.
- Bajo una distribución de datos determinada.
- Para una métrica específica.
- En presencia de las demás variables disponibles.

No necesariamente:

- Es la causa del fenómeno.
- Mantendrá su importancia en otra población.
- Será indispensable para otro modelo.
- La selección de características es principalmente una herramienta predictiva.

Taxonomía general

- Los métodos pueden clasificarse en:
 - **Filter:** Seleccionan variables mediante una medida previa o independiente del modelo final.
 - **Wrapper:** Evalúan repetidamente diferentes subconjuntos mediante el desempeño de un modelo.
 - **Intrínsecos o embedded:** La selección ocurre como parte del propio entrenamiento.
- Existe además otro enfoque:
 - Búsqueda greedy.
 - Búsqueda global.
- Estos enfoques no son equivalentes. Un wrapper puede emplear una búsqueda greedy o global.



Métodos filter

- **Funcionamiento:**
 - Calcular una puntuación para cada característica.
 - Ordenar las características.
 - Aplicar un umbral o elegir las mejores k .
 - Entrenar el modelo con las variables seleccionadas.
- **Ventajas:**
 - Rápidos.
 - Escalables.
 - Independientes del modelo final.
- **Limitaciones:**
 - Pueden ignorar interacciones.
 - Pueden seleccionar variables redundantes.
 - La medida del filtro puede no coincidir con el objetivo predictivo.

Métodos filter

- **Ejemplos:**
 - Eliminación por baja varianza.
 - Correlación entre características.
 - Pearson y Spearman.
 - Correlación con el objetivo.
 - ANOVA para clasificación.
 - Chi-cuadrada.
 - Información mutua.
- Una variable puede ser estadísticamente significativa y aportar muy poca mejora predictiva.

Métodos filter

- Una vez calculada una puntuación s_j , existen dos estrategias comunes.

- **Selección por umbral**


$$S = \{x_j: s_j > \tau\}$$

- **Selección top k**

$$S = \text{TopK}(s_1, \dots, s_p)$$


- El valor de k puede tratarse como hiperparámetro:

$$k \in \{10, 25, 50, 100\}$$



Métodos wrapper

- Un wrapper utiliza el modelo como función de evaluación.
- Para cada subconjunto S :
 - Se seleccionan las columnas correspondientes.
 - Se entrena el modelo.
 - Se estima el desempeño.
 - El resultado guía la búsqueda del siguiente subconjunto.
- Su función objetivo puede ser:
$$J(S) = F1\ Score_{CV}(S)$$
- La ventaja es que evalúa directamente la utilidad predictiva de las combinaciones.
- La desventaja es alto costo computacional.




Métodos embedded

- Incorporan la selección dentro del entrenamiento.
- **Ejemplos:**
 - Lasso.
 - Regresión logística con penalización L1.
 - Elastic Net.
 - Árboles de decisión.
 - MARS.
 - Algunos modelos de boosting.
- **Ventajas:**
 - Generalmente más rápidos que los wrappers.
 - La selección está conectada con la función objetivo.
- **Limitación:**
 - El subconjunto depende del modelo utilizado.

Métodos embedded

- **Ejemplos:**

- Regularización (Ridge L2 y Lasso L1): La regularización modifica la función de pérdida.
 - $\min_{\beta} [L(y, X\beta) + \lambda P(\beta)]$
 - donde: L : pérdida del modelo, $P(\beta)$: penalización y λ : intensidad de regularización.
- Elastic Net (combina L1 y L2).
- Selección en árboles: Maximizar la reducción de impureza.
- Importancia en ensembles de árboles.
- Importancia por permutación.




El espacio de subconjuntos

- Con p características existen 2^p subconjuntos posibles.
- Evaluar exhaustivamente todos los subconjuntos rápidamente se vuelve inviable.
- Por ello se requieren estrategias de búsqueda.

A decorative graphic on the left side of the slide, consisting of several concentric, slightly irregular blue rings of varying opacity, creating a sense of depth and movement.

Búsqueda greedy

- Una búsqueda greedy elige en cada paso la modificación que ofrece el mejor beneficio inmediato.
- **Características:**
 - Construye una trayectoria concreta.
 - No explora exhaustivamente el espacio.
 - Reduce el costo computacional.
 - Puede producir buenas soluciones rápidamente.
 - No garantiza alcanzar el óptimo global.
- Su problema central es que una decisión que parece conveniente ahora puede impedir alcanzar una mejor combinación posteriormente.



Forward selection

- Comienza sin características:
$$S_0 = \emptyset$$
- En cada paso se añade la variable que más aumente el criterio:
$$x^* = \arg \max_{x_j \notin S_t} J(S_t \cup \{x_j\})$$
- Después:
$$S_{t+1} = S_t \cup \{x^*\}$$
- El proceso termina cuando:
 - No hay mejora suficiente.
 - Se alcanza un tamaño máximo.
 - Se cumple un presupuesto.
 - El criterio penalizado deja de mejorar.
- La ventaja es que no requiere entrenar inicialmente con todas las variables.



Backward elimination

- Comienza con todas las características:

$$S_0 = F$$

- En cada iteración se elimina la variable cuya exclusión produce el mejor resultado:

$$x^* = \arg \max_{x_j \in S_t} J(S_t \setminus \{x_j\})$$

- Después:


$$S_{t+1} = S_t \setminus \{x^*\}$$

- **Ventajas:**

- Evalúa inicialmente las variables en presencia de las demás.
- Puede capturar cierta información multivariada.

- **Limitaciones:**

- Requiere que el modelo pueda ajustarse con todas las variables.
- Puede ser costoso cuando p es grande.
- Una variable eliminada generalmente no vuelve a considerarse.

A decorative graphic on the left side of the slide, consisting of several concentric, irregular blue rings of varying shades, creating a circular, water-like effect.

Recursive Feature Elimination

- RFE es una forma de eliminación hacia atrás basada en importancia.
- Procedimiento:
 - Entrenar el modelo con todas las variables actuales.
 - Calcular la importancia de cada variable.
 - Eliminar la variable o grupo menos importante.
 - Reentrenar el modelo.
 - Repetir para diferentes tamaños.
 - Elegir el tamaño mediante validación.

Limitaciones de la búsqueda greedy

- **Óptimos locales:** Puede encontrar un subconjunto que no puede mejorarse mediante un cambio pequeño.
- **Interacciones:** Dos variables pueden ser útiles juntas, pero parecer inútiles cuando se analizan por separado.
- **Irreversibilidad:** Forward selection normalmente no elimina lo añadido y backward elimination no recupera lo eliminado.
- **Dependencia del inicio:** La solución puede cambiar según el subconjunto inicial.
- **Inestabilidad:** Cambios pequeños en los datos pueden modificar la trayectoria completa.

A decorative graphic on the left side of the slide, consisting of several concentric, slightly irregular blue rings of varying opacity, creating a sense of depth and movement.

Búsqueda global

- Los métodos globales exploran una región más amplia del espacio.
- A diferencia de una estrategia estrictamente greedy, pueden:
 - Reconsiderar combinaciones anteriores.
 - Aceptar temporalmente soluciones peores.
 - Mantener varias soluciones candidatas.
 - Escapar de óptimos locales.
- No garantizan necesariamente encontrar el verdadero óptimo global, pero amplían la exploración.
- Su costo puede ser considerable porque cada evaluación requiere entrenar y validar un modelo.



Búsqueda global

- Un subconjunto puede representarse mediante un vector:

$$\mathbf{z} = (z_1, z_2, \dots, z_p)$$

- donde:

$$z_j = \begin{cases} 1, & x_j \text{ seleccionada} \\ 0, & x_j \text{ excluida} \end{cases}$$

- Ejemplo:

$$\mathbf{z} = [1, 0, 1, 1, 0]$$

- representa:

$$S = \{x_1, x_3, x_4\}$$

- Esta representación permite utilizar algoritmos de optimización combinatoria.

Búsqueda global

- **Diseño de la función objetivo**
- Si solo se maximiza el desempeño:
$$J(S) = \text{F1 Score}_{CV}(S)$$
- El algoritmo puede preferir subconjuntos grandes.

- Puede incorporarse una penalización:

$$J(S) = \text{F1 Score}_{CV}(S) - \lambda \frac{|S|}{p}$$

- En regresión:

$$J(S) = \text{RMSE}_{CV}(S) + \lambda \frac{|S|}{p}$$



Búsqueda global

- **Algoritmos:**
 - Simulated annealing.
 - Algoritmos genéticos.
 - Particle Swarm Optimization.
 - Ant Colony Optimization.

Sobreajuste a las características

- Si se evalúan suficientes subconjuntos, alguno puede funcionar bien por azar.
- Esto ocurre incluso si:
 - Las características contienen poca señal.
 - Las etiquetas tienen ruido.
 - Se utiliza un método sofisticado.
- La selección es una forma de optimización. Si se utiliza repetidamente la misma información para buscar y evaluar, se sobreajusta el proceso de selección.

Conclusiones

- La selección de características busca reducir la complejidad del modelo sin comprometer su capacidad predictiva.
- No existe un método superior: la elección depende del tipo de datos, el modelo, la dimensionalidad y el costo computacional disponible.
- El subconjunto seleccionado debe evaluarse considerando desempeño, tamaño, estabilidad e interpretabilidad.
- Una característica seleccionada es útil para un modelo y unos datos determinados, pero no necesariamente es causal.