



Introducción a la Ciencia de Datos

Maestría en Ciencias
de la Computación

Dr. Irvin Hussein López Nava







¿Qué es

Machine Learning

aprendizaje de máquina, aprendizaje
automático, aprendizaje computacional ?

Definiciones

ChatGPT

Es una subdisciplina de la IA que se enfoca en el desarrollo de algoritmos y modelos computacionales que permiten a las máquinas aprender y mejorar su rendimiento en tareas específicas a partir de datos y experiencias previas, sin una programación explícita para cada tarea.

<https://chat.openai.com/>

Wikipedia

Es un subcampo de las ciencias de la computación y una rama de la IA, cuyo objetivo es desarrollar técnicas que permitan que las computadoras aprendan. Se dice que un agente aprende cuando su desempeño mejora con la experiencia y mediante el uso de datos.

https://es.wikipedia.org/wiki/Aprendizaje_automatico

Gemini

Es un subcampo de la IA que se centra en desarrollar sistemas que aprenden de los datos sin ser explícitamente programados para ello. Estos sistemas pueden aprender a realizar tareas como clasificar imágenes, detectar objetos, traducir idiomas y generar texto.

<https://gemini.google.com/>

Classical Machine Learning

Task Driven

Data Driven

Supervised Learning

(Pre Categorized Data)

Classification

(Divide the socks by Color)

Eg. Identity
Fraud Detection

Regression

(Divide the Ties by Length)

Eg. Market
Forecasting

Unsupervised Learning

(Unlabelled Data)

Clustering

(Divide by Similarity)

Eg. Targeted
Marketing

Association

(Identify Sequences)

Eg. Customer
Recommendation

Dimensionality Reduction

(Wider Dependencies)

Eg. Big Data
Visualization

Obj: Predications & Predictive Models

Pattern/ Structure Recognition





03

Regresión



PREDICT SINGLE Y VALUE AFTER LINEAR REGRESSION



3.1 Regresión lineal

¿Qué es Regresión lineal?

A woman with dark hair, wearing an orange sweater, is shown in profile, looking upwards and to the right. She is holding a tablet in her left hand and reaching out with her right hand towards a glowing point on a digital globe. The background is a complex, futuristic interface with various data visualizations, including line graphs, bar charts, and circular progress indicators, all in shades of blue and white. The globe is a central element, showing the Americas. The overall aesthetic is high-tech and data-driven.

Definiciones

ChatGPT

Es una técnica estadística y un modelo matemático que se utiliza en estadística y aprendizaje automático para analizar y modelar la relación entre una variable dependiente (variable objetivo) y una o más variables independientes (variables predictoras).

<https://chat.openai.com/>

Wikipedia

Es un enfoque lineal para modelar la relación entre una respuesta escalar y una o más variables explicativas. El caso de una variable explicativa se denomina regresión lineal simple; para más de una, el proceso se llama regresión lineal múltiple.

https://en.wikipedia.org/wiki/Linear_regression

Gemini

Es un modelo estadístico que describe la relación entre una variable dependiente y una o más variables independientes. La variable dependiente es la variable que se desea predecir, y las variables independientes son las variables que se utilizan para predecir la variable dependiente.

<https://gemini.google.com/>

Regresión lineal en ML

- Recordando que ML es una rama de la IA que se centra en el desarrollo de algoritmos y modelos estadísticos que pueden aprender de los datos y hacer predicciones sobre ellos.
- La **regresión lineal** también es un tipo de algoritmo de aprendizaje automático (**supervisado**) que aprende de los conjuntos de datos etiquetados y asigna puntos de datos a funciones lineales optimizadas, que pueden utilizarse para la predicción en nuevos conjuntos de datos.

Tareas en aprendizaje supervisado

- Es un tipo de aprendizaje automático en el que el algoritmo aprende de datos etiquetados: el valor objetivo ya se conoce en los datos de entrenamiento.
- El **aprendizaje supervisado** tiene dos tipos principales de tareas:
 - **Clasificación:** predice la clase a partir de las variables de entrada. La clase toma valores categóricos, e.g., gato o perro.
 - **Regresión:** predice una variable de salida **continua** a partir de las variables de entrada, e.g., el precio de una vivienda en función de su ubicación, su superficie y su distancia a la carretera principal.
- Uno de los tipos más simples de regresión es la **regresión lineal**.

Regresión lineal

- Calcula la relación lineal entre una **variable dependiente** y una o más **variables independientes**.
 - Con una sola **variable independiente** se llama regresión lineal **simple**; con más de una, regresión lineal **múltiple**. El término *multivariada* se reserva para cuando hay varias variables dependientes.
- El objetivo es encontrar la mejor ecuación lineal que pueda predecir el valor de la **variable dependiente** en función de las **variables independientes**.
 - En el caso simple, la ecuación es una línea recta; con más variables, un plano o un hiperplano.
 - La pendiente indica cuánto cambia la variable **dependiente** por un cambio unitario en una variable **independiente**, manteniendo las demás constantes.

¿Dónde se puede utilizar?

- La **regresión lineal** se utiliza en muchos campos, incluidas las finanzas, la economía, la salud y la psicología, para comprender y predecir el comportamiento de una variable en particular.
- Por ejemplo, en finanzas, para comprender la relación entre el precio de las acciones de una empresa y sus ganancias; en salud, para estimar la progresión de una enfermedad a partir de mediciones clínicas.
- **Cuidado:** predecir el valor futuro de una moneda a partir de su desempeño pasado es una serie de tiempo. Sus observaciones no son independientes, y la independencia es uno de los supuestos de la regresión lineal.

Regresión, predicción

- En el conjunto de registros de regresión están presentes los valores X e Y y estos valores se usan para aprender una función, por lo que si se desea predecir Y a partir de una X desconocida, se puede usar esta función aprendida.
- En la regresión se requiere encontrar el valor de Y .
 - Por lo tanto, se requiere una función que prediga Y continua en el caso de regresión, dada X como características independientes.

Variables X y Y

- Primero, Y se denomina variable dependiente u objetivo, y X se denomina variable independiente, también conocida como predictor de Y.
- Hay muchos tipos de funciones o módulos que se pueden utilizar para la regresión.
 - Una función lineal es el tipo de función más simple.
- Por su parte, X puede ser una característica única o múltiples características que representan el problema.

Suposiciones

- **Linealidad:** la variable dependiente cambia de forma lineal con las independientes.
- **Independencia:** las observaciones son independientes entre sí; el valor de la variable dependiente en una observación no depende del de otra.
- **Homocedasticidad:** la varianza de los errores es constante en todos los niveles de las variables independientes.
- **Normalidad:** los errores del modelo se distribuyen normalmente.
- **Sin colinealidad** (regresión múltiple): las variables independientes no están fuertemente correlacionadas entre sí.

Función de hipótesis para regresión lineal

- Con una sola característica, x es la variable independiente (e.g., la temperatura máxima del día) y y la dependiente (e.g., la demanda máxima de electricidad).
- Si la relación entre x y y es lineal, y se puede predecir con:

$$\hat{Y} = \theta_0 + \theta_1 X \qquad \hat{y}_i = \theta_0 + \theta_1 x_i$$

donde $y_i \in Y$ ($i = 1, 2, \dots, n$) son las etiquetas de los datos (aprendizaje supervisado)
 $x_i \in X$ ($i = 1, 2, \dots, n$) son los datos de entrada (una sola variable de entrada)
 $\hat{y}_i \in \hat{Y}$ ($i = 1, 2, \dots, n$) son los valores predichos.

Función de hipótesis para regresión lineal

- El modelo obtiene la mejor línea de ajuste al encontrar los mejores valores de θ_0 y θ_1 .
 - θ_0 : intercepto, el valor de $\hat{y}$ cuando $x = 0$
 - θ_1 : pendiente, o coeficiente de x
- Una vez que se encuentran los mejores valores de θ_0 y θ_1 , se obtiene la línea de mejor ajuste.
- Entonces, cuando usemos el modelo para la predicción, este predecirá el valor de y para el valor de entrada de x .

Función de costo

- La función de costo, o función de pérdida, no es más que el error o diferencia entre el valor predicho $\hat{\mathbf{Y}}$ y el valor verdadero $\mathbf{Y}$.
 - Es el error cuadrático medio (MSE) entre el valor predicho y el valor verdadero.
- La función de costo J se puede escribir como:

$$J(\theta_0, \theta_1) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

¿Cómo actualizar θ_0 y θ_1 para obtener la línea de mejor ajuste?

- Para lograr la línea de regresión de mejor ajuste, el modelo busca predecir el valor objetivo $\hat{Y}$ de modo que la diferencia entre el valor predicho $\hat{Y}$ y el valor verdadero Y sea mínima.
- Por lo tanto, se buscan los valores de θ_0 y θ_1 que minimicen el error entre el valor predicho $\hat{y}$ y el valor verdadero y :

$$\min_{\theta_0, \theta_1} \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Gradient Descent

- Se puede entrenar un modelo de regresión lineal con el algoritmo de optimización de **descenso de gradiente**, que modifica iterativamente los parámetros del modelo para reducir su error cuadrático medio (MSE) en un conjunto de datos de entrenamiento.
- Para actualizar los valores θ_0 y θ_1 con el fin de reducir la función de costo (minimizando el MSE) y lograr la línea de mejor ajuste, el modelo utiliza descenso de gradiente.
- La idea es comenzar con valores aleatorios de θ_0 y θ_1 y luego actualizarlos de forma iterativa, hasta alcanzar el costo mínimo.

Gradient Descent

- Un gradiente no es más que una derivada que define los efectos sobre las salidas de la función con un poco de variación en las entradas.
- Calculamos la derivada de la función de costo J con respecto a θ_0 :

$$\begin{aligned}\frac{\partial J}{\partial \theta_0} &= \frac{\partial}{\partial \theta_0} \left[\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \right] \\ &= \frac{1}{n} \sum_{i=1}^n 2(\hat{y}_i - y_i) \frac{\partial}{\partial \theta_0} (\theta_0 + \theta_1 x_i - y_i) \\ &= \frac{1}{n} \sum_{i=1}^n 2(\hat{y}_i - y_i) (1 + 0 - 0) \\ &= \frac{2}{n} \sum_{i=1}^n (\hat{y}_i - y_i)\end{aligned}$$

Gradient Descent

- Después, la derivada de J con respecto a θ_1 :

$$\begin{aligned}\frac{\partial J}{\partial \theta_1} &= \frac{\partial}{\partial \theta_1} \left[\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \right] \\ &= \frac{1}{n} \sum_{i=1}^n 2(\hat{y}_i - y_i) \frac{\partial}{\partial \theta_1} (\theta_0 + \theta_1 x_i - y_i) \\ &= \frac{1}{n} \sum_{i=1}^n 2(\hat{y}_i - y_i) (0 + x_i - 0) \\ &= \frac{2}{n} \sum_{i=1}^n (\hat{y}_i - y_i) x_i\end{aligned}$$

Gradient Descent


- El objetivo es encontrar los coeficientes que mejor se ajustan a los datos; se actualizan en la dirección del gradiente negativo del MSE.
- El tamaño de cada paso lo controla α , la tasa de aprendizaje:


$$\theta_0 \leftarrow \theta_0 - \alpha \frac{\partial J}{\partial \theta_0} = \theta_0 - \alpha \frac{2}{n} \sum_{i=1}^n (\hat{y}_i - y_i)$$

$$\theta_1 \leftarrow \theta_1 - \alpha \frac{\partial J}{\partial \theta_1} = \theta_1 - \alpha \frac{2}{n} \sum_{i=1}^n (\hat{y}_i - y_i) x_i$$

- Si x tiene una escala grande, el descenso puede necesitar cientos de miles de iteraciones; estandarizar x lo resuelve.

En resumen






Mínimos cuadrados: la solución cerrada

- Igualando a cero las derivadas (slides 24 y 25):

$$\theta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$\theta_0 = \bar{y} - \theta_1 \bar{x}$$

- Es la solución que calcula `LinearRegression` de `scikit-learn`.
- Descenso de gradiente llega al mismo θ ; hace falta cuando no hay solución cerrada.



La recta minimiza la suma de los cuadrados de los segmentos verticales. 60 pacientes del dataset diabetes.

Regresión lineal múltiple

- Con p variables independientes, el modelo es:

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_p x_p$$

- En forma matricial, mínimos cuadrados da las **ecuaciones normales**:

$$\hat{y} = X\theta \qquad \hat{\theta} = (X^T X)^{-1} X^T y$$

- Cada θ_j es el cambio en $\hat{y}$ cuando x_j aumenta una unidad, **manteniendo las demás constantes**.
 - Un θ_j grande no implica una variable más importante: depende de las unidades.
 - Con variables muy correlacionadas, los coeficientes se vuelven inestables.

¿Qué tan bueno es el modelo?

- Un modelo se ajusta con unos datos y se evalúa con otros que **no vio**.

Entrenamiento (80 %)
se estiman los parámetros θ

Prueba (20 %)
se mide el error

```
train_test_split(X, y, test_size=0.2, random_state=42)
```


- Evaluar con los mismos datos del ajuste premia memorizar en lugar de generalizar: es el **sobreajuste**.

Métricas de regresión

Métrica	Definición	Cómo se lee
MSE	$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Error cuadrático medio. Penaliza más los errores grandes; es la J que minimizamos.
RMSE	$\sqrt{\text{MSE}}$	Raíz del MSE: queda en las mismas unidades que y.
MAE	$\frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	Error absoluto medio. Menos sensible a valores atípicos.
R²	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Compara contra predecir siempre el promedio: 1 es perfecto, 0 no mejora al promedio y puede ser negativo.

Residuales: revisar los supuestos

- El residual es lo observado menos lo predicho:
$$e_i = y_i - \hat{y}_i$$
- Se grafican contra $\hat{y}$. Señales de alarma:
 - Una curva: falta linealidad.
 - Un embudo: la varianza no es constante.
 - Un orden en el tiempo: no hay independencia.
- Sin patrón alrededor de 0, como a la derecha, el modelo es razonable.



Regresión múltiple con las 10 variables del diabetes: sin patrón claro.

Entonces, ¿regresión lineal es ML?

- Según Tom Mitchell: “Se dice que un programa de computadora aprende de la experiencia E con respecto a alguna clase de tareas T y medida de desempeño P si su desempeño en las tareas en T , medido por P , mejora con la experiencia E ”
- La regresión es ML cuando su tarea es proporcionar un valor estimado a partir de características predictivas en alguna aplicación. Su rendimiento debería mejorar a medida que experimenta más datos.


¿Cómo se utiliza?

	Ajustar una línea	Predecir un valor	Clasificar
Pregunta	¿Qué relación hay entre x y y ?	¿Cuánto valdrá y en un caso nuevo?	¿A qué clase pertenece?
Qué importa	El coeficiente y su intervalo de confianza	El error con datos que el modelo no vio	Los aciertos y errores por clase
Ejemplo	+5.6 por kg/m^2 de IMC, ajustado por las otras variables (+10.2 sin ajustar)	La progresión de un paciente nuevo	¿Su progresión será alta?


El primer uso es el de los estudios clínicos de asociación: efectos «ajustados por» otras variables. Con un desenlace binario usan regresión logística.

¿Y si la variable objetivo es una clase?

Regresión: ¿cuánto?



Clasificación: ¿cuál?



- **Regresión** responde **¿cuánto?**: la calidad de un vino, de 3 a 8. **Clasificación** responde **¿cuál?**: si el vino es bueno (calidad ≥ 7) o no.
- Una recta ajustada a 0 y 1 clasifica con un umbral ($\hat{y} \geq 0.5$), pero da valores fuera de $[0, 1]$: no son probabilidades.

Filters

Search datasets...



Keywords



Data Type



Subject Area



Task



Classification



Regression



Clustering



Other



Features



Instances



Feature Type



Browse Datasets



SORT BY # VIEWS, DESC



EXPAND ALL



Iris

A small classic dataset from Fisher, 1936. One of the earliest known datasets used for evaluating classification methods.

Classification

Tabular

150 Instances

4 Features



Heart Disease

4 databases: Cleveland, Hungary, Switzerland, and the VA Long Beach

Classification

Multivariate

303 Instances

13 Features



Adult

Predict whether income exceeds \$50K/yr based on census data. Also known as "Census Income" dataset.

Classification

Multivariate

48.84K Instances

14 Features



Dry Bean Dataset

Images of 13,611 grains of 7 different registered dry beans were taken with a high-resolution camera. A total of 16 features; 12 dimensions are...

Classification

Multivariate

13.61K Instances

16 Features




Diabetes

This diabetes dataset is from AIM '94

20 Features

Caso de estudio

Generación de electricidad renovable en EE.UU.

	Hydropower	Solar ¹	Wind	Geothermal	Biomass	Total Renewables
2004	 6.7%	 0.0%	 0.4%	 0.4%	 1.3%	 8.8%
2005	 6.7%	 0.0%	 0.4%	 0.4%	 1.3%	 8.8%
2006	 7.1%	 0.0%	 0.7%	 0.4%	 1.3%	 9.5%
2007	 5.9%	 0.0%	 0.8%	 0.4%	 1.3%	 8.5%
2008	 6.2%	 0.1%	 1.3%	 0.4%	 1.3%	 9.3%
2009	 6.9%	 0.1%	 1.9%	 0.4%	 1.4%	 10.6%
2010	 6.3%	 0.1%	 2.3%	 0.4%	 1.4%	 10.4%
2011	 7.8%	 0.2%	 2.9%	 0.4%	 1.4%	 12.6%
2012	 6.8%	 0.3%	 3.4%	 0.4%	 1.4%	 12.4%
2013	 6.6%	 0.5%	 4.1%	 0.4%	 1.5%	 13.1%
2014	 6.3%	 0.8%	 4.4%	 0.4%	 1.6%	 13.5%

17 %


de la electricidad generada en EE. UU. en 2025 fue eólica o solar (EIA).

En 2014, la última fila de la tabla, eran 5.2 %.

Planteamiento del problema


- La energía eólica y solar son intermitentes.
- Se necesitan centrales eléctricas tradicionales cuando no hay viento.
 - Muchas plantas de energía (e.g., las nucleares) no se pueden encender/apagar fácilmente ni acelerar/desactivar rápidamente.
- Con pronósticos más precisos, la energía eólica y solar se convierten en alternativas más eficientes.
 - Un mejor pronóstico de viento le ahorró a Xcel Energy 6 millones de dólares en 2010 (NCAR, 2011).
- ¿Se puede pronosticar con precisión la energía que se consumirá mañana?
 - Es difícil de estimar a partir de modelos “a priori”.
 - Pero se tienen muchos datos a partir de los cuales construir modelos.

Ejemplo de consumo eléctrico



Predecir la demanda máxima debido a las altas temperaturas

- ¿Cuál será la demanda máxima el día de mañana?
- De saber algo más sobre el mañana (como la temperatura alta), se puede usar para predecir la demanda máxima.
- Los datos son de verano (junio a agosto) en Pittsburgh. En invierno la calefacción también eleva la demanda y la relación deja de ser lineal.




Planteamiento del problema

- Un modelo lineal que predice la demanda:

$$\text{demanda máxima predicha} = \theta_0 + \theta_1 \cdot (\text{temperatura máxima})$$

- Parámetros del modelo:

$$\theta_0, \theta_1 \in \mathbb{R} \quad (\theta_0 = -1.46, \theta_1 = 0.046)$$



Modelo lineal simple

- Se puede usar un modelo como el anterior para hacer predicciones.
- ¿Cuál será la demanda máxima mañana?
- Se sabe, por el informe meteorológico, que la temperatura máxima será de 80 °F, unos 27 °C (ignorar por el momento que esto también es una predicción).
- Entonces la demanda máxima prevista es:


$$\theta_0 + \theta_1 \cdot 80 = -1.46 + 0.046 \cdot 80 = 2.22 \text{ GW}$$

Formalización del modelo


- **Entrada:** $x_i \in \mathbb{R}^p$, $i = 1, \dots, n$
 - Ej.: $x_i \in \mathbb{R}^1 = \{\text{temperatura máxima del día } i\}$
- **Salida:** $y_i \in \mathbb{R}$ (tarea de *regresión*)
 - Ej.: $y_i = \{\text{demanda máxima del día } i\}$
- **Parámetros del modelo:** $\theta \in \mathbb{R}^{p+1}$
- **Salida predicha:** $\hat{y}_i \in \mathbb{R}$
 - Ej.: $\hat{y}_i = \theta_0 + \theta_1 \cdot x_i$

n : número de observaciones · p : número de características

(Go to live notebook)



Extra Libro



- [05.00-Machine-Learning.ipynb](#)
- [05.01-What-Is-Machine-Learning.ipynb](#)
- [05.02-Introducing-Scikit-Learn.ipynb](#)
- [05.03-Hyperparameters-and-Model-Validation.ipynb](#)
- [05.04-Feature-Engineering.ipynb](#)
- **[05.06-Linear-Regression.ipynb](#)**



Tarea 3: Notebook de regresión

Programado para el Mañana, ...



Fecha de entrega: 7 sept 2027, 23:00

Usen el dataset de calidad de vino tinto (winequality-red.csv de UCI). Partición 80/20 con `random_state=42`.

- Regresión. Predigan *quality* con regresión lineal. Reporten RMSE y R^2 en prueba y compárenlos con predecir siempre el promedio.
- Clasificación. Definan bueno = *quality* ≥ 7 , ajusten la misma regresión a esa columna y clasifiquen como bueno si $\hat{y} \geq 0.5$. Reporten el porcentaje de aciertos en prueba, el de predecir siempre «no bueno» y cuántas $\hat{y}$ quedan fuera de $[0, 1]$. Conclusión. En un párrafo: ¿qué cambia entre los dos problemas y qué le falla a la recta como clasificador?

[Editar tarea](#)

