

Introducción a la Ciencia de Datos

Maestría en Ciencias
de la Computación

Dr. Irvin Hussein López Nava

IS LOGISTIC REGRESSION



REGRESSION?



03

Regresión




Recordando

- En **regresión lineal**, se intenta estimar la variable continua Y dependiendo de cualquier tipo de variable X cuando existe una **relación lineal** entre X e Y.
 - Relación lineal significa que hay un patrón entre X e Y, e.g. al aumentar X una cantidad, se encuentra un cambio constante en Y.
- Esto se representa como una ecuación lineal **$Y = mX + c$**
- Si **c** es 0, entonces la ecuación se convierte en **$Y = mX$**
 - Si **m** = 2, entonces $Y = 2X$, i.e., al aumentar X una unidad, Y aumenta 2 unidades.


Visualmente

- Entonces, en regresión lineal, el cambio de Y es constante para cualquier valor de X.
- El valor de Y aumenta constantemente 2 veces el de X.



Ahora bien

- Considere que el valor de Y no es continuo. Si el valor de Y es **discreto**, y binomial, entonces el valor de Y sólo puede ser 0 o 1.
- El verdadero problema ocurre al pretender **predecir** nuevos valores.
- En este ejemplo, para un valor más alto de X, los valores de Y van más allá de 1.
 - Pero los posibles valores son 0 o 1.



¿qué se puede hacer?


- Entonces, ¿cómo podemos mapear/normalizar los valores de Y dentro de 0 y 1 para cualquier valor correspondiente de X ?
- Se requiere un efecto constante en Y para un valor de X , pero no debe ir más allá de 1 ni por debajo de 0.
- Esto se puede representar por una variable de Bernoulli donde las probabilidades están acotadas en ambos extremos (entre 0 y 1).

Limitaciones de la regresión lineal

- En regresión lineal las predicciones no son adecuadas para la clasificación, ya que la probabilidad verdadera debe estar entre 0 y 1, porque pueden ser mayores que 1 o menores que 0.
 - La clasificación no se distribuye normalmente, lo que viola el supuesto de **normalidad**.
 - Cualquier factor que afecte la probabilidad cambiará no solo la media sino también la varianza de las observaciones, lo que viola además el supuesto de **homocedasticidad**.
- Como resultado, no se puede aplicar directamente la regresión lineal.

La recta como clasificador: Tarea 3

- En la Tarea 3, una recta ajustada a *bueno* (calidad ≥ 7) clasificó como bueno si $\hat{y} \geq 0.5$.
- **82 de las 320** $\hat{y}$ de prueba son negativas: no son probabilidades.
- Acierta **86.2 %**, pero decir siempre «no bueno» acierta **85.3 %**.
- Detecta **5 de los 47** vinos buenos.



*Son dos problemas distintos. El primero es del **modelo**, y lo resuelve la regresión logística. El segundo es de la **decisión**, y lo mide la matriz de confusión.*

Modelos lineales generalizados (GLM)

- Un **modelo lineal generalizado** (GLM) extiende la regresión lineal a respuestas que no son normales: binarias, conteos o tiempos positivos.
 - La respuesta sigue una distribución de la familia exponencial: normal, Bernoulli o binomial, Poisson, gamma.
 - Una **función de enlace** g transforma la media de la respuesta para que sea lineal en los predictores:
$$g(E[Y | x]) = \theta_0 + \theta_1 x$$
- Para una respuesta binaria el enlace es el **logit**, y su inversa es la **función logística**, también llamada sigmoide.
 - La **regresión logística** es el GLM con respuesta Bernoulli y enlace logit.

¿Qué regresión usar?


Depende del tipo de variable que quieres predecir.

01

Regresión lineal

CASOS DE USO

- 1 Modelado econométrico
- 2 Marketing Mix Model
- 3 Valor de vida del cliente (CLV)



Continua $\Rightarrow$ Continua

$$y = \alpha_0 + \sum_{i=1}^N \alpha_i x_i$$

EN R

```
lm(y ~ x1 + x2, data)
```

INTERPRETACIÓN


Un aumento de 1 unidad en x **suma α** a y

02

Regresión logística

CASOS DE USO

- 1 Tasa de clics (CTR)
- 2 Tasa de conversión
- 3 Scoring crediticio



Continua $\Rightarrow$ Verdadero / Falso

$$y = \frac{1}{1 + e^{-z}}$$
$$z = \alpha_0 + \sum_{i=1}^N \alpha_i x_i$$

EN R

```
glm(y ~ x1 + x2, data,  
family = binomial())
```

INTERPRETACIÓN


Un aumento de 1 unidad en x **suma α a los log-odds**

03

Regresión de Poisson

CASOS DE USO

- 1 Pedidos por cliente
- 2 Número de visitas por usuario
- 3 Tickets de soporte por día



Continua $\Rightarrow$ 0, 1, 2, ...

$$y \sim \text{Poisson}(\lambda)$$
$$\ln \lambda = \alpha_0 + \sum_{i=1}^N \alpha_i x_i$$

EN R

```
glm(y ~ x1 + x2, data,  
family = poisson())
```

INTERPRETACIÓN

Un aumento de 1 unidad en x **multiplica y por e^α**

3.2 Regresión logística

¿Qué es Regresión logística?

A woman with dark hair, wearing an orange sweater, is shown in profile, looking upwards and to the right. She is holding a tablet in her left hand and reaching out with her right hand towards a glowing point on a digital globe. The background is a complex, futuristic digital interface with various data visualizations, including line graphs, bar charts, and circular progress indicators. The overall color scheme is dominated by blue and orange.

Definiciones

ChatGPT

Es un método de análisis estadístico utilizado para modelar y predecir la probabilidad de un evento binario, es decir, un evento que tiene solo dos posibles resultados, como sí/no, 1/0, éxito/fracaso, o clases positivas/negativas.

<https://chat.openai.com/>

Wikipedia

Es un modelo estadístico que modela la probabilidad de que ocurra un evento haciendo que las probabilidades logarítmicas del evento sean una combinación lineal de una o más variables independientes.

https://en.wikipedia.org/wiki/Logistic_regression

Gemini

Es un tipo de análisis de regresión que se utiliza para predecir el resultado de una variable categórica, como si un paciente tiene cáncer o no, si un cliente comprará un producto o no, o si un candidato ganará una elección o no.

<https://gemini.google.com/>

Tipos de regresión logística

- **Regresión logística binomial** o binaria – dos resultados posibles "0" y "1"
Ejemplo: Éxito/Fracaso, Sí/No.
- **Regresión logística multinomial** – más de dos resultados que no pueden ordenarse. **Ejemplo:** Selección de curso: Curso A, Curso B, Curso C.
- **Regresión logística ordinal** – similar a la multinomial, pero los resultados pueden ordenarse. **Ejemplo:** Clasificación de películas: Excelente, Buena, Regular, Mala.


Cuando hay dos resultados posibles, puede compararse con la distribución de Bernoulli.

Distribución de Bernoulli

- Describe un experimento con dos resultados: **éxito** (1) o **fracaso** (0). Lleva el nombre de Jakob Bernoulli (1654-1705).
- Si la probabilidad de éxito es p , la de fracaso es $1 - p$.
- Las dos caben en una sola fórmula:

$$P(Y=y) = p^y (1-p)^{1-y}, \quad y \in \{0, 1\}$$

- Con $y = 1$ queda p ; con $y = 0$ queda $1 - p$.



Media y varianza

- Si en 10 ensayos hay 8 éxitos, p se estima como $8/10 = 0.8$: la **proporción de unos**.
- La media de una variable 0/1 es p , y su varianza, $p(1 - p)$:

$$E[Y] = p$$

$$\text{Var}(Y) = p(1 - p)$$

- Predecir la media de Y es predecir la probabilidad de éxito: eso hace la regresión logística.
- La varianza cambia con p , así que no puede ser constante: por eso la recta viola la homocedasticidad (lámina 8).

Momios (*odds*)


- Los **momios** comparan la probabilidad de éxito con la de fracaso.
- Van de 0 a ∞ , y valen 1 cuando éxito y fracaso son igual de probables ($p = 0.5$).
- La **razón de momios** (RM, *odds ratio*) es el cociente de los momios de dos grupos o de dos valores de x .
 - Una RM de 2 dice que los momios del grupo 1 son el doble que los del grupo 0. Es la medida que reporta la regresión logística (lámina 28).

$$\text{momios} = \frac{p}{1 - p}$$

$$\text{RM} = \frac{\text{momios}_1}{\text{momios}_0}$$

Ejemplo


- Si $p = 0.8$, los momios son $0.8 / 0.2 = 4$, o 4 a 1: por cada 4 éxitos, 1 fracaso.
- Si $p = 0.25$, son $0.25 / 0.75 = 1/3$, o 1 a 3: por cada éxito, 3 fracasos.
- La razón de momios entre los dos casos es $4 / (1/3) = 12$.
- Los momios no son simétricos: 1 a 3 y 3 a 1 quedan a distinta distancia de 1.
¿Cómo llevarlos a toda la recta real, con el 1 en el centro? Con el **logaritmo**.



Logaritmo

- $\ln x$ es el logaritmo natural, en base $e \approx 2.718$; $\log_{10} x$ es el de base 10.
 - En la regresión logística, en NumPy (`np.log`) y en scikit-learn, *log* significa $\ln$.
- El logaritmo y la exponencial son inversos:
$$\ln(e^x) = x \qquad e^{\ln x} = x \quad (x > 0)$$
- Convierte productos en sumas:
$$\ln(ab) = \ln a + \ln b$$
- Lleva $(0, \infty)$ a $(-\infty, \infty)$: $\ln 1 = 0$, y $\ln(1/3) = -\ln 3 = -1.10$.

Ejemplo



p	momios $p / (1 - p)$	$\ln(\text{momios})$
0.001	0.001	-6.907
0.01	0.0101	-4.595
0.1	0.111	-2.197
0.2	0.25	-1.386
0.25	0.333	-1.099
0.5	1	0.000
0.75	3	1.099
0.8	4	1.386
0.9	9	2.197
0.99	99	4.595
0.999	999	6.907

Pasar de la probabilidad al logaritmo de sus momios se llama **logit**: es la función de enlace de la regresión logística.

De regresión lineal a regresión logística

- La función de enlace lleva la probabilidad p , que vive entre 0 y 1, a una escala sin límites:

$$\text{logit}(p) = \ln \frac{p}{1-p} \in (-\infty, \infty)$$



- En esa escala, el modelo sí es lineal en los predictores:

$$\text{logit}(p_i) = \theta_0 + \theta_1 x_i$$

- **Ojo:** no se transforman los datos. Cada y observada vale 0 o 1, y su logit sería $-\infty$ o ∞ . Por eso los θ no se estiman con mínimos cuadrados, sino por **máxima verosimilitud** (lámina 26).

Funciones logit y logística

- Son inversas: el **logit** lleva la probabilidad a la escala lineal del modelo, y la **logística** la regresa a una probabilidad.



De regresión lineal a regresión logística


$$\ln \frac{p}{1-p} = \theta_0 + \theta_1 x$$

$$\Rightarrow \frac{p}{1-p} = e^{\theta_0 + \theta_1 x}$$

$$\Rightarrow p = \frac{e^{\theta_0 + \theta_1 x}}{1 + e^{\theta_0 + \theta_1 x}}$$

$$\Rightarrow p = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x)}}$$

Con el IMC, las dos cruzan 0.5 casi en el mismo punto (30.4 y 30.2 kg/m²), pero solo la curva se queda entre 0 y 1.



Finalmente

- Con θ_0 y θ_1 estimados, la función logística convierte cualquier x en una probabilidad:

$$p = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x)}}$$

- Para clasificar hace falta un **umbral** t :
 - si $p \geq t$, la salida es 1 (positivo, éxito);
 - si $p < t$, la salida es 0 (negativo, fracaso).
- El umbral habitual, $t = 0.5$, es una elección y no parte del modelo. Cambiarlo cambia las decisiones, no las probabilidades (lámina 42).

¿Cómo se ajustan θ_0 y θ_1 ?

- Cada y_i es un ensayo de Bernoulli con probabilidad p_i (lámina 16). La **verosimilitud** es la probabilidad de observar justo esos datos:

$$L(\theta) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1 - y_i}$$

- Se eligen los θ que la hacen máxima: **máxima verosimilitud**.
- Con logaritmo, signo menos y promedio, el producto se vuelve una suma: la función de costo **log-loss**, o entropía cruzada:

$$J(\theta) = -\frac{1}{n} \sum_{i=1}^n [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$$

- Si $y_i = 1$, cuesta $-\ln p_i$: casi nada si $p_i \approx 1$ y muchísimo si $p_i \approx 0$.

Descenso de gradiente, otra vez

- Aquí no hay ecuaciones normales: $J(\theta)$ se minimiza iterando.
- Las derivadas tienen la forma de la sesión 10, con p_i en lugar de $\hat{y}_i$:

$$J'_{\theta_0} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i) \qquad J'_{\theta_1} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i) x_i$$

- Y la actualización es la misma: $\theta_j \leftarrow \theta_j - \alpha J'_{\theta_j}$
- $J(\theta)$ es **convexa**, con un solo mínimo: el descenso no se atora. scikit-learn y statsmodels usan métodos más rápidos (lbfgs, Newton) que llegan al mismo punto.

¿Cómo se lee un coeficiente?



- θ_1 es lo que cambia el logaritmo de los momios cuando x aumenta una unidad.
- Al exponenciar, e^{θ_1} es la **razón de momios** entre $x + 1$ y x :

$$\frac{\text{momios}(x + 1)}{\text{momios}(x)} = e^{\theta_1}$$

- Multiplica los momios, no la probabilidad:
cuánto cambia p depende de en qué parte de la curva esté el paciente.

× 1.37

en los momios de progresión alta por
cada kg/m² de IMC
IC 95 %: 1.28 a 1.48 · 353 pacientes

Regresión Lineal	Regresión Logística	Explicación
La variable objetivo es continua	La variable objetivo es binaria (con extensiones multinomial y ordinal)	La regresión lineal predice valores continuos (como temperatura, altura, etc.), mientras que la regresión logística predice la probabilidad de que ocurra un evento discreto (como si va a llover o no, si un cliente comprará o no, etc.).
Valores predichos son la media	Valores predichos son probabilidades	La regresión lineal predice el valor promedio de la variable objetivo, mientras que la regresión logística predice la probabilidad de que la variable objetivo pertenezca a una determinada categoría.
Resuelve problemas de regresión	Resuelve problemas de clasificación	La regresión lineal se utiliza para modelar relaciones entre variables continuas, mientras que la regresión logística se utiliza para clasificar datos en categorías.
Ejemplo: ¿Cuál es la temperatura?	Ejemplo: ¿Va a llover o no?	La regresión lineal podría utilizarse para predecir la temperatura en función de otros factores (como la hora del día, la estación del año, etc.), mientras que la regresión logística podría utilizarse para predecir si lloverá o no en función de variables como la humedad, la presión atmosférica, etc.
		La relación entre las variables en la regresión lineal se representa mediante una línea recta, mientras que en la regresión logística se representa mediante una curva en forma de S (curva logística).

Implementaciones de Scikit-learn




1.1. Linear Models > Logistic regression

https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

Logistic Regression 3-class Classifier

https://scikit-learn.org/stable/auto_examples/linear_model/plot_iris_logistic.html#logistic-regression-3-class-classifier

(Go to live notebook)



Métricas

Accuracy

- La exactitud (en inglés "*accuracy*") es una métrica utilizada para evaluar el rendimiento de un modelo de clasificación.
- Representa la proporción de predicciones correctas realizadas por el modelo en relación con el total de predicciones realizadas.
 - En otras palabras, mide qué tan acertado es un modelo en clasificar correctamente los ejemplos en un conjunto de datos.

$$\text{Exactitud} = \frac{\text{Número de predicciones correctas}}{\text{Total de predicciones}}$$

NO confundir
con la métrica
precisión!!

¿Qué tan bueno es un 73 %?

Datos	Modelo	Aciertos	Siempre «no»	Positivos detectados
Diabetes, IMC	recta	74.2 %	73.0 %	8 de 24
Diabetes, IMC	logística	73.0 %	73.0 %	8 de 24
Vino, 11 variables	recta	86.2 %	85.3 %	5 de 47
Vino, 11 variables	logística	86.2 %	85.3 %	13 de 47

- Con el IMC, la logística decide igual que la recta salvo en un paciente de 89: **arregla la probabilidad, no la decisión.**
- En el vino, las dos aciertan lo mismo, pero una detecta 5 vinos buenos y la otra 13. El accuracy no dice *en qué* se equivoca el modelo: para eso está la **matriz de confusión.**

Matriz de confusión (caso binario)

- Es una herramienta que permite la visualización del desempeño de un modelo de clasificación.
- Las columnas pueden representar el número de predicciones de cada clase, mientras que las filas representan las instancias en la clase real, o viceversa.

		PREDICCIÓN	
		Positivo	Negativo
VALOR REAL	Positivo	VP Verdadero positivo Predijo positivo y era positivo.	FN Tipo II Falso negativo Predijo negativo, pero era positivo.
	Negativo	FP Tipo I Falso positivo Predijo positivo, pero era negativo.	VN Verdadero negativo Predijo negativo y era negativo.

DIAGNÓSTICO (PREDICCIÓN)

REALIDAD

Embarazo

Dice «sí»

Verdadero positivo

Estás embarazada

Dice «no»

Falso negativo

No estás embarazada

Error tipo II

Sin embarazo

Falso positivo

Estás embarazado

Error tipo I

Verdadero negativo

No estás embarazado

Matriz de confusión (caso binario)

- Una matriz de confusión, o matriz de error, es un diseño de tabla específico que permite visualizar el rendimiento de un modelo de clasificación.

		Predicted		
		Positive	Negative	
Actual	Positive	True positive (TP)	False negative (FN)	Sensitivity
	Negative	False positive (FP)	True negative (TN)	Specificity
		Precision		F-measure


Matriz de confusión (tipos de errores)

		Predicted	
		Positive	Negative
Actual	Positive	TP	FN (error type I)
	Negative	FP (error type II)	TN


- El primer tipo de error es **el rechazo** de una hipótesis nula verdadera. El segundo es **el NO rechazo** de una hipótesis nula falsa.
- Como ejemplo, un error de tipo I corresponde a condenar a un acusado inocente; mientras que un tipo II corresponde a absolver a un criminal.

- Accuracy (ACC):
$$ACC = \frac{TP + TN}{P + N} = \frac{TP + TN}{TP + TN + FP + FN}$$
- Sensitivity, recall, o true positive rate (TPR):
$$TPR = \frac{TP}{P} = \frac{TP}{TP + FN}$$
- Specificity o true negative rate (TNR):
$$TNR = \frac{TN}{N} = \frac{TN}{TN + FP}$$
- Precision o positive predictive value (PPV):
$$PPV = \frac{TP}{TP + FP}$$
- F1 score es la media armónica entre precision and sensitivity:
$$F_1 = 2 \cdot \frac{PPV \cdot TPR}{PPV + TPR} = \frac{2TP}{2TP + FP + FN}$$

(Go to live notebook)



El umbral es una decisión




Umbral	IMC $\geq$	Detectados	Especificidad
0.5	30.2	8 de 24	0.88
0.4	28.9	11 de 24	0.80
0.3	27.5	15 de 24	0.74

Bajar el umbral detecta más casos a cambio de más falsas alarmas. En el vino, con 0.2 detecta 34 de 47 en lugar de 13, pero 43 de sus 77 alarmas son falsas.

¿Cuál es mejor? Depende del costo de cada error. El jueves: todos los umbrales a la vez, con la curva ROC.

Extra Libro?



Logistic Regression is a classification algorithm and not Regression



Logistic Regression is Regression and models continuous outcome



Logistic Regression is a Binomial regression with logit link



Logistic Regression is a special case of Generalized linear Model (GLM) like Poisson, Beta and Gamma



Logistic Regression can be used as classification only when a probability cut off (e.g. 0.4, 0.5, 0.6 etc) is set externally.



