

Introducción a la Ciencia de Datos

Maestría en Ciencias
de la Computación

Dr. Irvin Hussein López Nava


Lectura: Domingos (2012)

Domingos, P. (2012). A few useful things to know about machine learning. Communications of the ACM, 55(10), 78–87.


1. ¿Cómo se filtra información de prueba a un clasificador sin entrenar con ella?
2. En su figura 2, Naive Bayes le gana a un aprendiz de reglas aunque la regla verdadera sea un conjunto de reglas. ¿Cómo gana el modelo «equivocado»?
3. En el notebook 11, ¿qué cambió más las decisiones: pasar de la recta a la curva, o de una variable a diez?

Las doce lecciones

1. Aprender = representación + evaluación + optimización
- 2. Lo que cuenta es la generalización**
3. Los datos solos no bastan
- 4. El sobreajuste tiene muchas caras**
5. La intuición falla en altas dimensiones
6. Las garantías teóricas no son lo que parecen
- 7. La ingeniería de características es la clave**
8. Más datos le ganan a un algoritmo más listo
9. Aprendan muchos modelos, no solo uno
10. Simplicidad no implica exactitud
11. Representable no implica aprendible
12. Correlación no implica causalidad







04

Clasificación



Classical Machine Learning

Task Driven

Data Driven

Supervised Learning

(Pre Categorized Data)

Classification

(Divide the socks by Color)

Eg. Identity
Fraud Detection

Regression

(Divide the Ties by Length)

Eg. Market
Forecasting

Unsupervised Learning

(Unlabelled Data)

Clustering

(Divide by Similarity)

Eg. Targeted
Marketing

Association

(Identify Sequences)

Eg. Customer
Recommendation

Dimensionality Reduction

(Wider Dependencies)

Eg. Big Data
Visualization

Obj: Predications & Predictive Models

Pattern/ Structure Recognition



4.1 Modelos de clasificación

¿Qué es Clasificación?



Definiciones

ChatGPT

Es una tarea que implica asignar una etiqueta predefinida a un elemento de entrada en función de sus características. El objetivo es aprender a generalizar a partir de datos de entrenamiento para hacer predicciones precisas sobre nuevos datos no etiquetados.

<https://chat.openai.com/>

Wikipedia

Es el problema de identificar a cuál de un conjunto de categorías pertenece una observación; e.g., asignar un correo electrónico a la clase "spam" o "no spam", o asignar un diagnóstico a un paciente determinado según sus características observadas.


https://en.wikipedia.org/wiki/Statistical_classification

Gemini


Es un tipo de aprendizaje supervisado que se utiliza para asignar etiquetas a los datos. El objetivo es crear un modelo que pueda predecir la categoría de un nuevo dato, dado un conjunto de datos de entrenamiento con etiquetas conocidas.

<https://gemini.google.com/>

Un primer caso



Clasificador general



¿Qué es clasificación?

- En el **aprendizaje supervisado**, la **clasificación** es el proceso de **identificar** a cuál de un conjunto de clases pertenece una nueva **observación** (fase de prueba), a partir de un conjunto de **datos de entrenamiento** que contiene **observaciones** cuya clase se conoce (fase de entrenamiento).

Fase de entrenamiento

- El entrenamiento se lleva a cabo utilizando datos de entrenamiento $\mathcal{T} = \{(\mathcal{X}_i, y_i)_{i=1}^n\}$ con n pares de vectores de características $\mathcal{X}_i$ y sus correspondientes etiquetas y_i
- A partir de los datos de entrenamiento $\mathcal{T}$ se construye un modelo utilizando métodos de inferencia supervisada, $\mathcal{I}$, antes de utilizarlo en la **fase de prueba**.
- Los parámetros del modelo λ deben aprenderse para minimizar el error de clasificación en $\mathcal{T}$ si se ha utilizado un **algoritmo paramétrico** para construir modelos.
- En cambio, los **algoritmos basados en instancias**, como kNN, guardan los datos de entrenamiento etiquetados, $\lambda = \mathcal{T}$, y dejan el trabajo para la **fase de prueba**.

Fase de prueba


- Las pruebas se realizan utilizando un modelo entrenado con parámetros λ , que asigna cada nuevo vector de características $\mathcal{X}_i$ a un conjunto de etiquetas de clase $\mathcal{Y} = y^1, \dots, y^c$ con sus correspondientes puntuaciones $\mathcal{P}_i = p_i^1, \dots, p_i^c$.

$$p_i(y|\mathcal{X}_i, \lambda) = \mathcal{I}(\mathcal{X}_i, \lambda), \text{ for each } y \in \mathcal{Y}$$

- con el método de inferencia $\mathcal{I}$. A continuación, las puntuaciones $\mathcal{P}_i$ calculadas se utilizan para obtener la puntuación máxima y seleccionar la etiqueta de clase y_i correspondiente como salida de la clasificación.

$$y_i = \operatorname{argmax}_{y \in \mathcal{Y}, p \in \mathcal{P}_i} p_i(y|\mathcal{X}_i, \lambda)$$

Algoritmos de inferencia




¿Hasta qué punto confiamos en el clasificador aprendido?

- Los clasificadores (tanto supervisados como no supervisados) se aprenden (entrenan) en un conjunto de **datos de entrenamiento finito**.
- Un clasificador, o modelo, aprendido debe probarse experimentalmente en una prueba diferente (datos de prueba).
- El rendimiento experimental sobre los **datos de prueba** es una aproximación al rendimiento en datos desconocidos – comprueba la capacidad de generalización del clasificador.
- Se necesita una función que evalúe experimentalmente el rendimiento del clasificador, e.g., su tasa de error, precisión, sensibilidad, especificidad.
 - Es necesario comparar los clasificadores experimentalmente.


La evaluación es una prueba de hipótesis

- La evaluación debe tratarse como una **prueba de hipótesis** en estadística.
- El valor del parámetro poblacional debe deducirse estadísticamente a partir de las estadísticas de la muestra (i.e., un **conjunto de prueba**).




Riesgo de sobreajuste


- **Aprender** de los datos de entrenamiento con demasiada precisión suele dar lugar a malos resultados de clasificación en nuevos datos.
- ¡El clasificador debe tener la capacidad de **generalizar**!



underfit



fit



overfit

Uso de los datos: conjuntos de entrenamiento y de prueba

Problema: sólo se dispone de datos finitos y deben utilizarse tanto para el entrenamiento como para las pruebas.


- Un mayor número de datos de entrenamiento mejora la generalización.
- Más datos de prueba dan una mejor estimación de la probabilidad de error de clasificación.
- **NUNCA** se debe evaluar el rendimiento de los clasificadores en función de los **datos de entrenamiento**: la conclusión tendría un sesgo optimista.

División de los datos

Partición (división) del conjunto finito de datos disponible en subconjuntos de entrenamiento/prueba:

- Hold out.
- Cross validation.
- Bootstrap.

Una vez finalizada la evaluación, todos los datos disponibles pueden utilizarse para entrenar el clasificador final.



Hold out method

- Los datos se dividen **aleatoriamente**, de preferencia estratificados por clase, en dos conjuntos independientes.
- El **conjunto de entrenamiento** (e.g., 2/3 de los datos) para la construcción del modelo estadístico, i.e., el aprendizaje del clasificador.
 - Generalmente la proporción de los datos es mayor al conjunto de prueba.
- El **conjunto de prueba** (e.g., 1/3 de los datos) se utiliza para estimar el desempeño del clasificador.

DATASET COMPLETO

1	2	3	4	5	6	7	8	9	10	11	12
---	---	---	---	---	---	---	---	---	----	----	----

TRAIN

9	10	3	7	1	12	2	6	8	4	5	11
---	----	---	---	---	----	---	---	---	---	---	----

TEST

Entrenamiento, validación y prueba

Entrenamiento · 60 %

Validación · 20 %

Prueba · 20 %

- **Entrenamiento:** ajusta los parámetros del modelo, como los θ de la logística.
- **Validación:** elige lo que el ajuste no aprende: hiperparámetros, umbral, variables o el modelo.
- **Prueba:** se usa una sola vez, al final, para estimar el desempeño con datos nuevos.
- Con pocos datos, la validación cruzada dentro del entrenamiento sustituye a la validación.

Todo lo que aprende de los datos (escalado, imputación, selección de variables, SMOTE) se ajusta solo con el entrenamiento. En scikit-learn, dentro de un Pipeline.

K-fold cross validation

- El **conjunto de entrenamiento** se divide **aleatoriamente** en k conjuntos disjuntos de igual tamaño en los que cada parte tiene aproximadamente la misma distribución de clases (estratificación).
 - El clasificador se evalúa k veces, cada vez con un conjunto diferente que se utiliza como **conjunto de prueba**.
 - El rendimiento del clasificador es la media de los k resultados; su desviación estándar indica qué tan estable es la estimación.

$n = 12$
 $k = 3$

TRAIN


TEST

data

1	2	3	4	5	6	7	8	9	10	11	12
---	---	---	---	---	---	---	---	---	----	----	----

Leave-one-out

- Un caso especial de validación cruzada k -fold con $k = n$, donde n es el número total de muestras del conjunto de datos.
 - Se realizan n experimentos utilizando $n - 1$ muestras para el entrenamiento y la muestra restante para las pruebas.
- Es bastante costosa desde el punto de vista computacional.




Bootstrap method

- Forma el conjunto de entrenamiento con n observaciones muestreadas **con reemplazo**: algunas se repiten y otras no salen.
- La probabilidad de que una observación no salga nunca es:
$$\left(1 - \frac{1}{n}\right)^n \longrightarrow e^{-1} \approx 0.368$$
- Cada muestra contiene en promedio 63.2 % de las observaciones. Se entrena con ella, se evalúa con las que quedaron fuera (≈ 36.8 %) y se repite m veces.
- El estimador .632 compensa que se entrena con menos observaciones distintas:

$$\hat{\epsilon}_{.632} = 0.368 \hat{\epsilon}_{\text{entrenamiento}} + 0.632 \hat{\epsilon}_{\text{fuera}}$$


Combinar los m modelos, votando o promediando, es otra técnica: bagging (sesión 18).

Resumen de los métodos



La partición también se contamina

- El vino tiene 240 filas duplicadas: 460 de los 1599 vinos tienen una gemela idéntica.
- En la validación cruzada usual, una copia puede caer en entrenamiento y su gemela en prueba.
- Con las gemelas en el mismo pliegue, el 1 vecino y el árbol pasan de los primeros lugares a los últimos.



Weka y Orange usan la partición usual: en la demo, el 1 vecino y el árbol se verán mejor de lo que son.

Métricas

Retomando el *accuracy*

- La **exactitud** es el porcentaje de clasificaciones correctas.
- La **tasa de error** es el porcentaje de clasificaciones incorrectas.
- $Accuracy = 1 - Error\ rate$.

Problemas con estas métricas:

- Asume costes iguales para la clasificación errónea.
- Supone una distribución de clases relativamente uniforme (e.g., 0.5% de pacientes con una determinada enfermedad).

Se pueden derivar otras métricas de la matriz de confusión.

Recordatorio: dos clases

	Predicho +	Predicho -
Real +	TP	FN
Real -	FP	TN

Con más de dos clases no hay un solo «positivo»: cada clase lo es por turnos.

Exactitud

$$\frac{TP + TN}{n}$$

Sensibilidad (recall)

$$\frac{TP}{TP + FN}$$

Especificidad

$$\frac{TN}{TN + FP}$$

Precisión

$$\frac{TP}{TP + FP}$$

F1

$$\frac{2PS}{P+S}$$

P: precisión; S: sensibilidad

Matriz de confusión (tres clases)

		Predicha			Total
		baja	media	alta	
Real	baja	112	36	1	149
	media	51	64	13	128
	alta	3	25	15	43
	Total	166	125	29	320

- Vino tinto en tres clases: baja (calidad 3 a 5), media (6) y alta (7 y 8). Regresión logística, 320 vinos de prueba.
- La diagonal son los aciertos: $112 + 64 + 15 = 191$.
- Exactitud = $191 / 320 = 0.597$. Decir siempre «baja» acierta **0.466**.
- Casi todos los errores son entre clases vecinas: solo 4 vinos saltan de baja a alta o al revés.

Uno contra el resto

	Predicha		
	baja	media	alta
baja	112	36	1
media	51	64	13
alta	3	25	15

- TP:** su celda de la diagonal
- FN:** el resto de su fila
- FP:** el resto de su columna
- TN:** todo lo demás



	«alta» contra el resto	
	alta	resto
alta	TP = 15	FN = 28
resto	FP = 14	TN = 263

$$FN = 3 + 25 \cdot FP = 1 + 13 \cdot TN = 112 + 36 + 51 + 64$$

$$TP_k = C_{kk}$$

$$FN_k = \sum_j C_{kj} - C_{kk}$$

$$FP_k = \sum_i C_{ik} - C_{kk} \quad TN_k = n - TP_k - FN_k - FP_k$$

Se repite con cada clase: tres matrices de 2×2 .

Métricas por clase

Clase	Soporte	TP	FN	FP	TN	Precisión	Sensibilidad	Especificidad	F1
baja	149	112	37	54	117	0.675	0.752	0.684	0.711
media	128	64	64	61	131	0.512	0.500	0.682	0.506
alta	43	15	28	14	263	0.517	0.349	0.949	0.417

- Cada clase usa las fórmulas del caso binario con su propia matriz de 2×2 .
- «alta» es la que peor se detecta: 15 de 43 (sensibilidad **0.349**). Su especificidad es la más alta (**0.949**) porque casi nunca se predice «alta».
- **Ejercicio:** comprueben la fila de «media» con la matriz de la lámina 31.

Tres maneras de promediar

Macro

todas las clases pesan igual

$$\bar{m}_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K m_k$$

Ponderado

cada clase pesa según su soporte

$$\bar{m}_{\text{pond}} = \sum_{k=1}^K \frac{n_k}{n} m_k$$

Micro

se suman TP, FP y FN antes de dividir

$$P_{\text{micro}} = \frac{\sum_k \text{TP}_k}{\sum_k (\text{TP}_k + \text{FP}_k)}$$

	Macro	Ponderado	Micro
Precisión	0.568	0.588	0.597
Sensibilidad	0.534	0.597	0.597
F1	0.545	0.589	0.597

*El macro castiga que «alta» se detecte mal; el ponderado lo diluye entre los 277 vinos de las otras clases. Con una etiqueta por vino, el micro es la exactitud. La sensibilidad macro es la **exactitud balanceada**.*

¿Qué reporta cada herramienta?

	Por clase	Promedio que muestra	Especificidad
scikit-learn	classification_report: precision, recall, f1-score y support	macro avg y weighted avg, además de accuracy	No la reporta; se calcula con multilabel_confusion_matrix
Weka	Detailed Accuracy By Class, una fila por clase: TP Rate, FP Rate, Precision, Recall...	Weighted Avg.: ponderado. No muestra el macro	1 - FP Rate
Orange	Test and Score con Target class = una clase: uno contra el resto	(None, show average over classes): ponderado	Columna Spec, oculta: clic derecho en el encabezado

*El F1 que muestran Weka y Orange es el ponderado: **0.589** en el ejemplo, contra **0.545** del macro. Para el macro, promedien la columna de cada clase.*

Costes desiguales de las decisiones

- **Diagnóstico médico:** El coste de una indicación falsa de cáncer de mama en el cribado de la población es menor que el coste de pasar por alto una enfermedad verdadera.
- **Defensa contra misiles aéreos:** El coste de no detectar un ataque real es mucho mayor que el de una falsa alarma.

Problema de la distribución de clases desconocida

En muchas circunstancias, se desconoce la distribución de clases, e.g., un filtro de spam de correo electrónico. Los modelos estadísticos deben aprenderse de antemano.

- Diagnóstico médico: 95 % sano, 5 % enfermedad.
- Comercio electrónico: el 99 % no compra, el 1 % compra.
- Seguridad: el 99.999 % de los ciudadanos no son terroristas.

Una situación similar ocurre con los clasificadores multiclase. La clase mayoritaria puede acertar el 99 %, pero es inútil.

Desbalance: se equilibra el entrenamiento

Submuestreo (sampling)

Quitar al azar casos de la clase mayoritaria, o repetir los de la minoritaria, hasta igualarlas.

Aumento (augmentation)


Generar casos sintéticos de la clase minoritaria, e.g., SMOTE (sesión 6).

- Las dos se aplican **solo al entrenamiento**, después de partir.
- La prueba conserva la proporción real de clases y nunca lleva datos sintéticos: representa los datos con los que se usará el modelo.
- Equilibrar tiene un efecto parecido a mover el umbral: cambia las decisiones. Por eso se evalúa por clase o con promedios macro.
- Sin tocar los datos: pesos por clase (`class_weight="balanced"`) o un umbral elegido con validación.

¿Es suficiente una métrica para evaluar el rendimiento de un clasificador?


- Las características escalares, como la exactitud, no proporcionan suficiente información.
- Dos números –la tasa de verdaderos positivos y la tasa de falsos positivos– son mucho más informativos que un solo número.
- Estos dos números se visualizan mejor mediante una curva, e.g., mediante una *Receiver Operating Characteristic* (ROC), que informa sobre:
 - Rendimiento para todos los posibles costes de clasificación errónea.
 - Rendimiento para todas las relaciones de clase posibles.
- ¿En qué condiciones el clasificador c_1 supera al clasificador c_2 ?

ROC – Receiver Operating Characteristic



- Cada umbral es un punto: tasa de falsos positivos (1 - especificidad) contra sensibilidad.
- La curva recorre todos los umbrales a la vez. La diagonal es un clasificador que decide al azar.
- Sirve con cualquier puntaje que ordene los casos: la probabilidad de la logística, los votos de un árbol, la distancia de una SVM.
- Los puntos son los umbrales de la sesión 11: bajar de 0.5 a 0.3 sube la sensibilidad de **0.33** a **0.63** y los falsos positivos de **0.12** a **0.26**.

Área bajo la curva (AUC)



$$AUC = P(s_+ > s_-)$$


- Es la probabilidad de que un positivo al azar reciba un puntaje mayor que un negativo al azar: 0.5 es el azar y 1 separa perfecto.
- Con el IMC, en **1165 de las 1560** parejas (alta, no alta), el paciente con progresión alta tiene mayor probabilidad: AUC = **0.747**. Con 10 variables, **0.854**.
- No depende del umbral ni de la proporción de clases.
- Con varias clases, una curva por clase (uno contra el resto). Vino: baja **0.82**, media **0.66**, alta **0.86**; macro **0.78**.

Demo: Weka

	Weka	En el curso
1. Explorer › Preprocess › Open file: datos/vinos-3clases.arff. La clase, calidad, es el último atributo.	TP Rate, Recall	sensibilidad
2. Classify › Choose: rules › ZeroR, functions › Logistic, trees › J48, lazy › IBk.	FP Rate	1 - especificidad
3. Test options: Cross-validation, 10 folds › Start.	Precision	precisión
4. Leer la Confusion Matrix (filas: real; columnas: «classified as») y Detailed Accuracy By Class.	F-Measure	F1
	ROC Area	AUC, uno contra el resto
	Weighted Avg.	promedio ponderado
	ZeroR	línea base


J48 da F-Measure 0.740, 0.606 y 0.566: el macro es 0.637 y Weka reporta el ponderado, 0.663. IBk, con un solo vecino, sale primero (69.3 %) gracias a los duplicados.

Demo: Orange




1. **File:** `datos/vinos-3clases.csv`; en la columna calidad, Role: target.
2. **Test and Score:** Cross validation, 10 folds, Stratified. La versión actual empieza en 5.
3. **Target class:** «(None, show average over classes)» da el promedio ponderado; «alta» da uno contra el resto.
4. **Confusion Matrix:** con «Proportion of predicted», la diagonal es la precisión; con «Proportion of actual», la sensibilidad.

(Go to live notebook)



Extra Libro



- 05.00-Machine-Learning.ipynb
- 05.01-What-Is-Machine-Learning.ipynb
- 05.02-Introducing-Scikit-Learn.ipynb
- **05.03-Hyperparameters-and-Model-Validation.ipynb**
- 05.04-Feature-Engineering.ipynb
- 05.06-Linear-Regression.ipynb

¿El reto?




karen zack
@teenybiscuit





nice lady | creative at @wiedenkenndy
[Traducir la biografía](#)

📍 los angeles 🌐 [karenzack.com](#) 📅 Se unió en junio de 2009

845 Siguiendo 6.171 Seguidores

Ninguna de las cuentas que sigues sigue a este usuario





Gracias!

¿Alguna pregunta?

hussein@cicese.edu.mx

