Introducción a la Ciencia de Datos

Maestría en Ciencias de la Computación

Dr. Irvin Hussein López Nava





Estudiantes de CMU en la marcha del G20, Pittsburgh, 2009

04

Clasificación

4.5 Support vector machines


¿Qué son las
Máquinas de
Soporte Vectorial?

Definiciones

ChatGPT

Es un algoritmo de aprendizaje automático que busca encontrar hiperplanos de separación óptimos para clasificar datos en espacios de alta dimensión, destacándose por su capacidad para maximizar el margen entre las clases y su robustez frente al sobreajuste.

https://chat.openai.com/

Wikipedia

Es un modelo supervisado de margen máximo: busca el hiperplano que deja la mayor separación, o margen, entre las dos clases. Ese hiperplano queda determinado por los puntos más cercanos a él, llamados vectores de soporte.

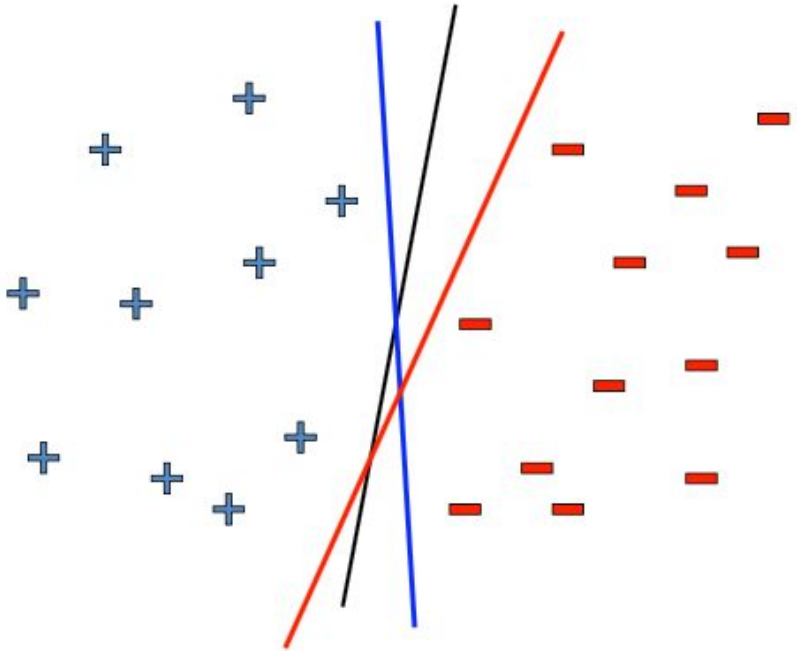
https://en.wikipedia.org/wiki/Support_vector_machine

Gemini

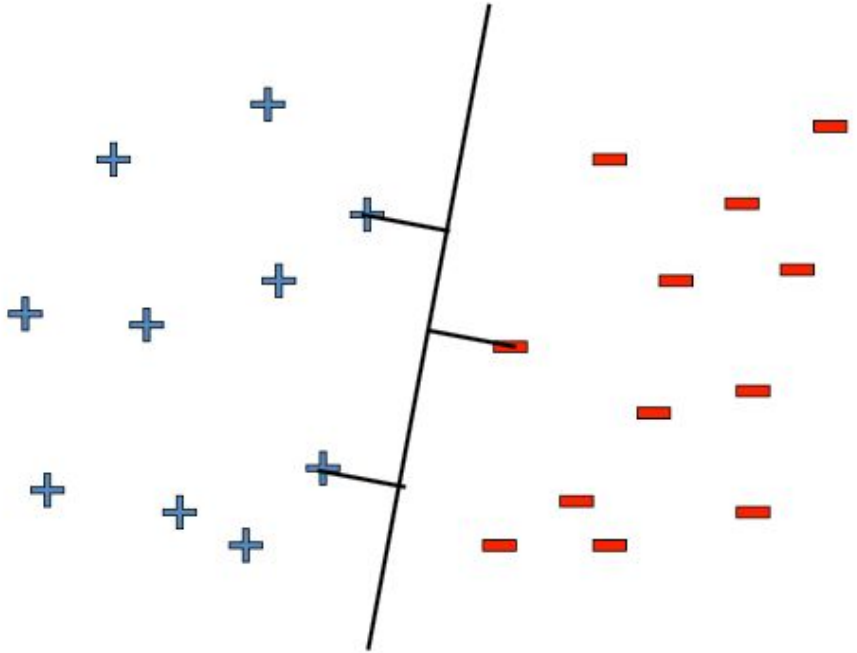
Son un tipo de algoritmo de aprendizaje automático que se utiliza para problemas de clasificación y regresión.
Se basan en el concepto de encontrar un hiperplano que separe los datos de dos clases de forma óptima.
El hiperplano óptimo es el que tiene el margen más amplio entre los dos conjuntos de datos.

https://gemini.google.com/

Clasificadores lineales: ¿qué línea es mejor?



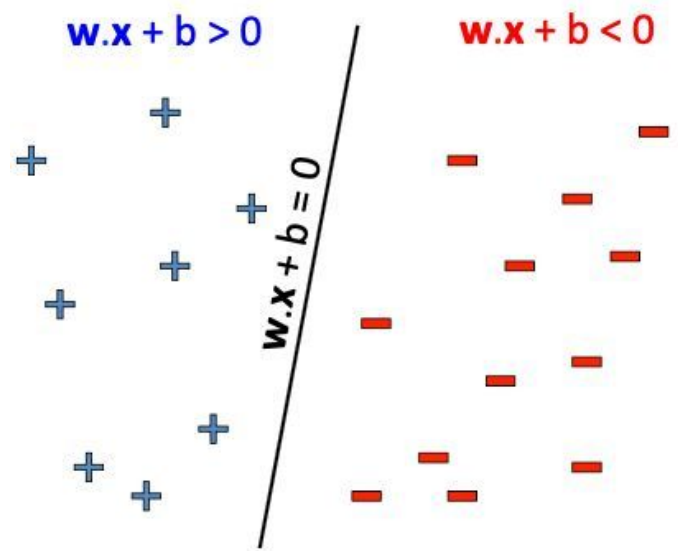
Elegir el que tenga mayor margen



Parametrización del límite de decisión

- **Frontera**: $w \cdot x + b = 0$, perpendicular a w.
- Etiquetas $y_j \in \{-1, +1\}$; se predice el signo de $w \cdot x + b$.
- Margen funcional: $y_j(w \cdot x_j + b) > 0$ si x_j está bien clasificado.
- Distancia de x a la frontera:

$$d(x) = \frac{|\, w \cdot x + b \,|}{\|w\|}$$



La logística de la sesión 11 también separa con una recta: $p = 0.5$ donde $\theta_0 + \theta_1 x = 0$. SVM elige su recta por el margen; la logística, por la verosimilitud.

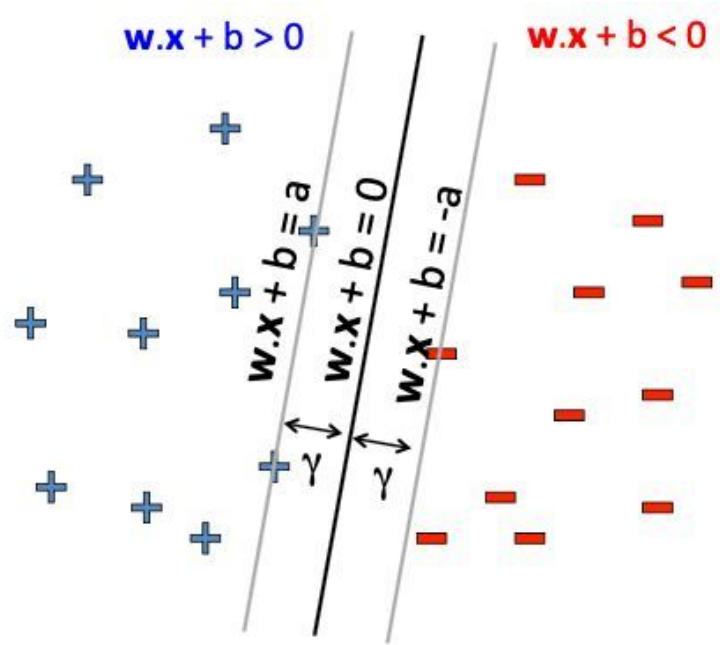
Maximizando el margen

- El **margen** γ: la distancia del ejemplo más cercano a la frontera.

$$\max_{w,\ b} \quad \gamma = \frac{a}{\|w\|}$$

$$y_j\,(w \cdot x_j + b) \;\geq\; a \quad \text{para todo } j$$

- *a* es arbitraria: dividir *w* y *b* entre *a* no mueve la recta. Se fija *a* = 1: los más cercanos quedan en *w*·*x* + *b* = ±1.
- La banda completa mide 2γ = 2/‖*w*‖.



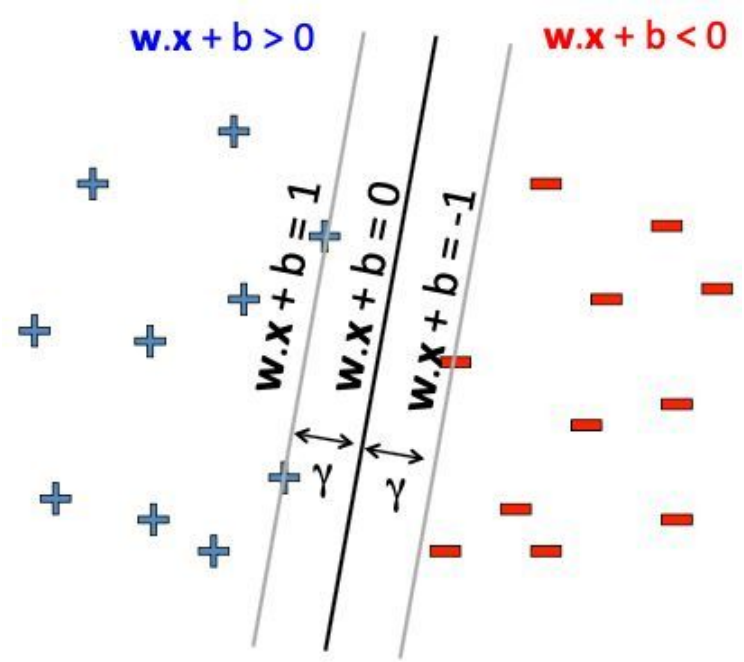
Máquinas de soporte vectorial

Forma primal:

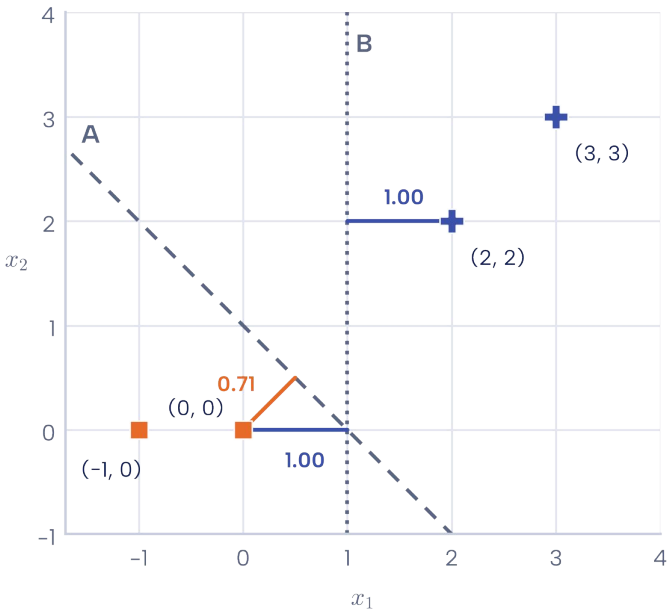
$$\min_{w,\, b} \quad \frac{1}{2} \|w\|^2$$

$$y_j \, (w \cdot x_j + b) \, \geq \, 1, \quad \; j = 1, \ldots, n$$

- Maximizar 1/‖*w*‖ es minimizar ‖*w*‖. Con el cuadrado y el ½ queda un problema de programación cuadrática (QP): convexo, con un único óptimo.
- Algoritmos de solución bien estudiados: `SVC` de scikit-learn usa SMO (libsvm).



Cuatro puntos: el margen de dos rectas



¿Hay una recta con más margen?

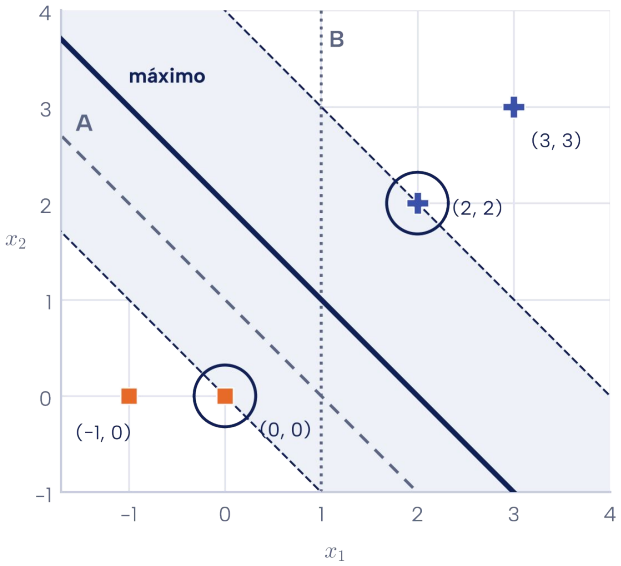
Positivos: (2, 2) y (3, 3). **Negativos**: (0, 0) y (−1, 0).
La distancia con signo de cada punto a una recta:

$$d_j = \frac{y_j\,(w \cdot x_j + b)}{\|w\|}$$ y el margen de la recta es la menor.

Punto	*y*	a A	a B
(2, 2)	+1	2.12	**1.00**
(3, 3)	+1	3.54	2.00
(0, 0)	−1	**0.71**	**1.00**
(−1, 0)	−1	1.41	2.00
margen		**0.71**	**1.00**

- A: w = (1, 1), $\|w\| = \sqrt{2}$; (0, 0): $(-1)(0 + 0 - 1)/\sqrt{2} = 0.71$.
- B: w = (1, 0), $\|w\| = 1$; empatan (2, 2) y (0, 0), a 1.00.

La recta de margen máximo, paso a paso

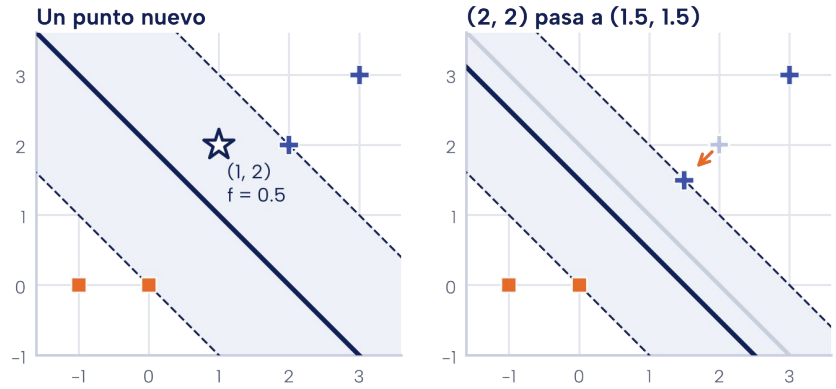


1. Los más cercanos de cada clase, (2, 2) y (0, 0), quedan sobre el margen: $w\cdot(2,2)+b=1$ y $w\cdot(0,0)+b=-1$.
2. La segunda da **$b=-1$**. La primera queda $2w_1+2w_2-1=1$, o sea $w_1+w_2=1$.
3. Entre esos w, el de menor $\tfrac{1}{2}\|w\|^2$. Con $w_2=1-w_1$, la derivada de $\tfrac{1}{2}[w_1^2+(1-w_1)^2]$ es $2w_1-1$, que se anula en $w_1=\tfrac{1}{2}$: **$w=(\tfrac{1}{2},\tfrac{1}{2})$**.
4. Las cuatro restricciones $y_j(w\cdot x_j+b)\geq 1$ valen 1, 2, 1 y 1.5: se cumplen, con igualdad solo en los dos VS.

$\tfrac{1}{2}x_1+\tfrac{1}{2}x_2-1=0$, que es $x_1+x_2=2$.
$\|w\|=1/\sqrt{2}$, así que el margen $1/\|w\|$ vale $\sqrt{2}=1.41$
y la banda $2/\|w\|=2.83=\|(2,2)-(0,0)\|$.

Leer la solución y moverla

- **Un punto nuevo, (1, 2):**
  $f(x) = ½x_1 + ½x_2 - 1 = 0.5 + 1 - 1 = 0.5$.
  - El signo da la clase: +.
  - $|f| < 1$: cae dentro de la banda.
  - $f/\|w\| = 0.5 \cdot \sqrt{2} = 0.71$: su distancia a la frontera.
- **Mover (3, 3) a (4, 2):**
  $y \cdot f = 2 > 1$, sigue fuera del margen y nada cambia.
- **Mover (2, 2) a (1.5, 1.5):** ahora $1.5(w_1 + w_2) - 1 = 1$, así que $w = (⅔, ⅔)$. El margen baja a 1.06 y la frontera pasa a $x_1 + x_2 = 1.5$.



Solo los vectores de soporte fijan la frontera.

Del primal al dual

Un multiplicador $\alpha_j \geq 0$ por cada restricción del primal (diapositiva 11):

$$L(w, b, \alpha) = \frac{1}{2}\,\|w\|^2 - \sum_j \alpha_j [\, y_j\,(w \cdot x_j + b) - 1\,], \qquad \alpha_j \geq 0$$

Igualar a 0 las derivadas respecto a ***w*** y a ***b***:

$$\frac{\partial L}{\partial w} = w - \sum_j \alpha_j\, y_j\, x_j = 0 \;\Rightarrow\; w = \sum_j \alpha_j\, y_j\, x_j \qquad \frac{\partial L}{\partial b} = -\sum_j \alpha_j\, y_j = 0 \;\Rightarrow\; \sum_j \alpha_j\, y_j = 0$$

Al sustituir ***w*** en *L*, el término con ***b*** se anula y queda el dual:

$$\max_{\alpha} \; \sum_{j=1}^{n} \alpha_j \;-\; \frac{1}{2} \sum_{j=1}^{n} \sum_{k=1}^{n} \alpha_j\, \alpha_k\, y_j\, y_k\; x_j \cdot x_k \qquad \alpha_j \geq 0, \qquad \sum_{j=1}^{n} \alpha_j\, y_j = 0$$

Un $\alpha_j > 0$ solo puede estar sobre el margen: son los VS. Con cualquier VS, $b = y_s - w \cdot x_s$.
Los dos son QP convexos y llegan al mismo valor. *w* es único; los α, no siempre (diapositiva 20).

El dual de los cuatro puntos

$$W(\alpha) = \sum_j \alpha_j - \frac{1}{2}\alpha^\top Q\,\alpha, \qquad Q_{jk} = y_j\, y_k\, x_j \cdot x_k$$

con $\alpha \geq 0$ y $\alpha_1 + \alpha_2 = \alpha_3 + \alpha_4$.

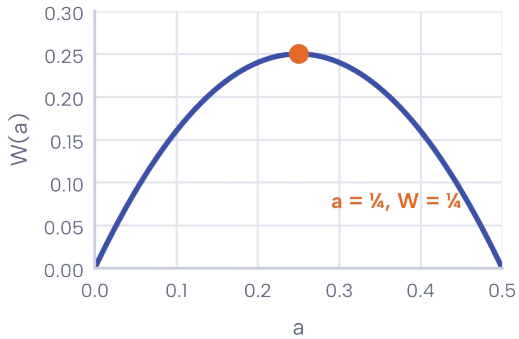
Con los VS de la diapositiva 13, $\alpha_2 = \alpha_4 = 0$ y la restricción da $\alpha_1 = \alpha_3 = a$. Solo queda $Q_{11} = 8$:

$$W(a) = 2a - \frac{1}{2}(8a^2) = 2a - 4a^2, \qquad W'(a) = 2 - 8a = 0 \;\Rightarrow\; a = \frac{1}{4}$$

- $\boldsymbol{w}$ = ¼(2, 2) − ¼(0, 0) = **(½, ½)**, y $\boldsymbol{b}$ = 1 − w·(2, 2) = **−1**.
- W(¼) = ½ − ¼ = ¼ = ½‖w‖²: el mismo valor del primal.
- Con el dual, el punto nuevo (1, 2) da ¼(2, 2)·(1, 2) − ¼(0, 0)·(1, 2) − 1 = 1.5 − 1 = **0.5**:
  lo mismo que el primal, con solo los dos VS.

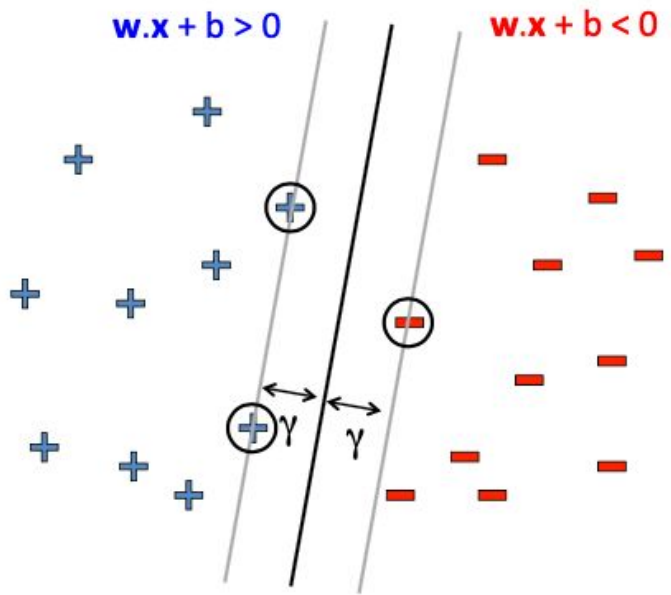
Q_{jk}	(2, 2)	(3, 3)	(0, 0)	(−1, 0)
(2, 2)	8	12	0	2
(3, 3)	12	18	0	3
(0, 0)	0	0	0	0
(−1, 0)	2	3	0	1

Por ejemplo, Q_{14} = (+1)(−1)[(2)(−1) + (2)(0)] = 2.



Vectores de soporte

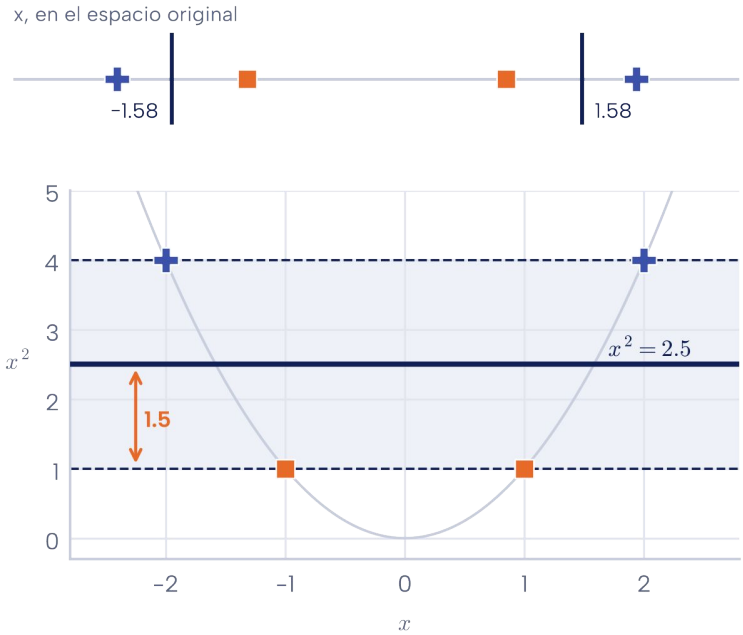
- El hiperplano lineal se define por "vectores de soporte".
- Mover un poco otros puntos no afecta el límite de decisión.
- Sólo es necesario almacenar los vectores de soporte para predecir etiquetas de nuevos puntos.



Con clases que se traslapan pueden ser casi todos: 909 de los 1279 vinos

¿Qué pasa si los datos no son separables linealmente?

- Usar características de características…:
  x_1^2, x_2^2, x_1x_2, …, $\exp(x_1)$.
- Ejemplo: −2 y 2 son positivos; −1 y 1, negativos. Ningún umbral los separa.
- Con $\varphi(x) = (x, x^2)$ y $w_1 = 0$ por simetría, los VS dan $4w_2 + b = 1$ y $w_2 + b = -1$: $\boldsymbol{w_2 = 2/3}$ y $\boldsymbol{b = -5/3}$.
- Margen: $1/\|w\| = 1.5$. La frontera $\frac{2}{3}x^2 - 5/3 = 0$ es $x^2 = \mathbf{2.5}$: dos umbrales, en ±1.58.
- Con D atributos, el grado 2 da $D + D + D(D-1)/2 = D(D+3)/2$ características (77 en el vino), y con ellas crece el riesgo de sobreajuste.



Kernel SVM

El dual solo usa productos punto entre ejemplos. El truco del kernel: cambiarlos por

$$K(x, z) = \Phi(x) \cdot \Phi(z)$$

Primal, en el espacio proyectado, de mayor dimensión:

$$\min_{w,\, b} \ \frac{1}{2}\|w\|^2 \qquad y_j\,(w \cdot \Phi(x_j) + b) \geq 1$$

Clasificar: $w \cdot \Phi(x) + b > 0$

Dual, en el espacio original, con $\alpha_j \geq 0$ y $\Sigma\, \alpha_j y_j = 0$:

$$\max_{\alpha} \ \sum_j \alpha_j \ - \ \frac{1}{2}\sum_j \sum_k \alpha_j\, \alpha_k\, y_j\, y_k\, K(x_j, x_k)$$

Clasificar: $\displaystyle\sum_{j \,\in\, \mathrm{VS}} \alpha_j\, y_j\, K(x_j, x) \ + \ b > 0$

Con $\varphi(x) = (x, x^2)$, $K(x, z) = xz + x^2z^2$:
$K(2, -1) = 2 = (2, 4)\cdot(-1, 1)$.
Es el truco de Kernel PCA (sesión 8).

El kernel de juguete, con números

$K(x, z)$	−2	2	−1	1
−2	20	12	6	2
2	12	20	2	6
−1	6	2	2	0
1	2	6	0	2

Por ejemplo, $K(-2, -1) = (-2)(-1) + (4)(1) = 6$.

- $K(x, z) = xz + x^2z^2$ (diapositiva 19): las cuentas no necesitan φ.
- Con $\alpha = 1/9$ en los cuatro puntos ($\Sigma\, \alpha_j y_j = 0$) y $b = 1 - (1/9)(12 + 20 - 2 - 6) = -5/3$, calculado con el VS $x = 2$:

$$f(x) = \frac{1}{9}[\, K(-2, x) + K(2, x) - K(-1, x) - K(1, x)\,] - \frac{5}{3}$$

$$= \frac{1}{9}[\, (-2x + 4x^2) + (2x + 4x^2) - (-x + x^2) - (x + x^2)\,] - \frac{5}{3} = \frac{2}{3}x^2 - \frac{5}{3}$$

La misma frontera de la diapositiva 18, sin calcular φ. SVC devuelve otros α, (1/18, 1/6, 0, 2/9), con 3 VS, y también son óptimos: el dual puede tener varias soluciones; w, b y la frontera, una sola.

Kernels comunes

Kernel	$K(x, z)$	En SVC	Qué controla
Lineal	$x \cdot z$	`kernel="linear"`	solo C
Polinomial	$(\gamma\, x \cdot z + r)^d$	`kernel="poly"`, `degree` = d, `coef0` = r	d y r; ¡`coef0` = 0 por omisión!
RBF (gaussiano)	$\exp(-\gamma \lVert x - z \rVert^2)$	`kernel="rbf"` (por omisión), `gamma`	$\gamma = 1/(2\sigma^2)$: con γ grande, cada VS influye solo cerca de sí

- `gamma="scale"` (por omisión) vale $1/(D \cdot \mathrm{Var}(X))$, con la varianza de toda la matriz: con datos estandarizados, $1/D$.
- `coef0` = 0 deja solo los términos de grado d: el grado 2 cae de 0.568 a 0.438 en el vino.

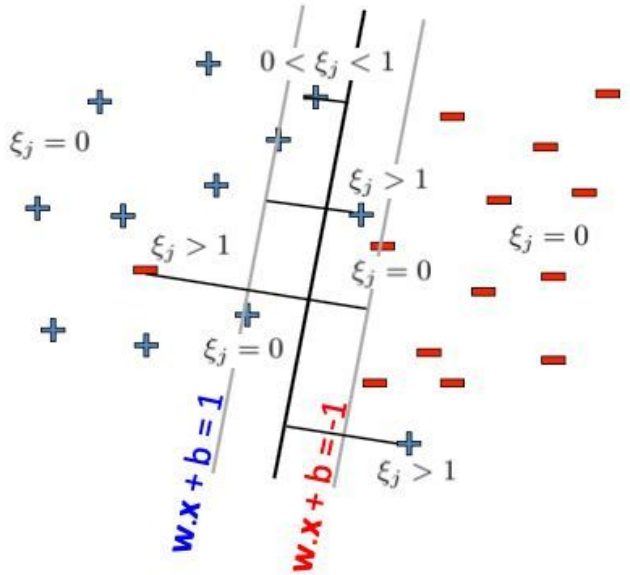
Soft-margin SVM

- Contar errores (pérdida 0/1) no es convexo y no distingue un error por poco de uno grave. Mejor, una holgura $\xi_j \geq 0$ por ejemplo:

$$\min_{w,\, b,\, \xi} \quad \frac{1}{2}\|w\|^2 + C\sum_j \xi_j$$

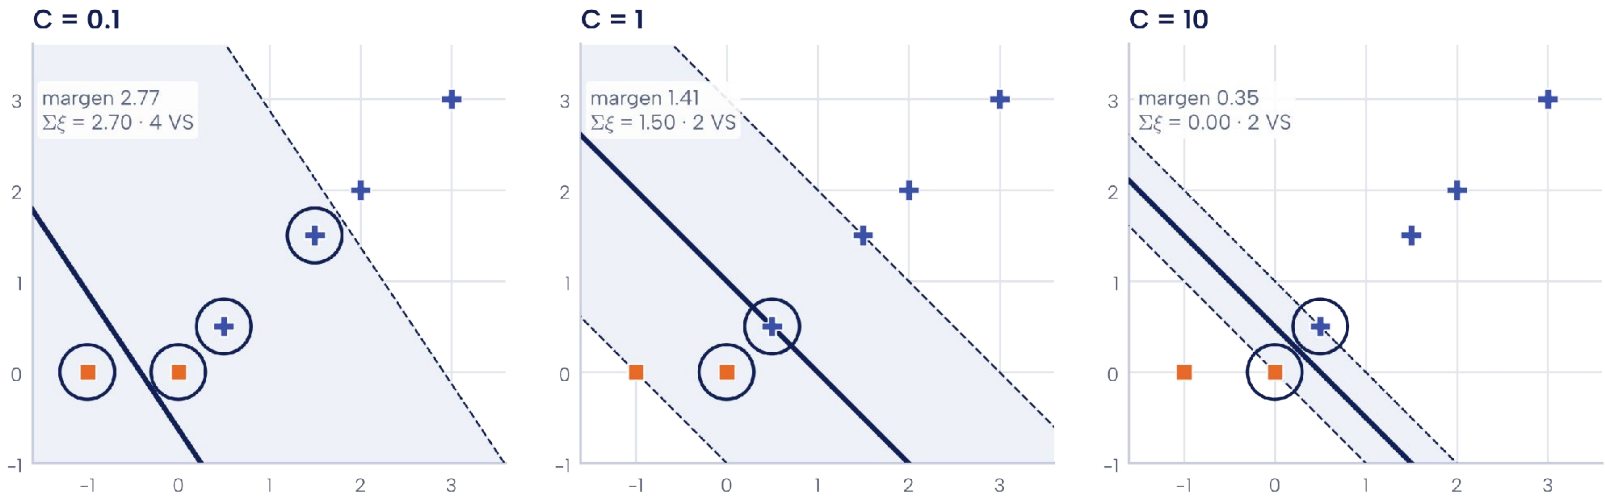
$$y_j\,(w \cdot x_j + b) \;\geq\; 1 - \xi_j, \qquad \xi_j \geq 0$$

- $\xi_j = 0$: fuera del margen; $0 < \xi_j < 1$: dentro, bien clasificado; $\xi_j > 1$: mal clasificado.
- *C*: el costo de cada violación. Grande: margen estrecho, pocas violaciones; chico: margen ancho. Se elige con validación; sigue siendo QP.



SVC usa este C. Con w·w en lugar de ½‖w‖², el mismo modelo lleva un C del doble.

El efecto de *C*



- $C = 0.1$: margen ancho y un error, (0, 0). $C = 10$: separa todo, con margen 0.35.
- El dual del margen suave es el de la 13 con $0 \leq \alpha_j \leq C$. Tres tipos de puntos: $\alpha = 0$, fuera del margen; $0 < \alpha < C$, sobre él; $\alpha = C$, dentro o mal clasificado.

Holguras con números

Con $C = 1$: $w = (½, ½)$ y $b = -½$.

Punto	$y \cdot f$	ξ	α	Lectura
(2, 2)	1.5	0	0	fuera del margen
(3, 3)	2.5	0	0	fuera del margen
(1.5, 1.5)	1	0	0	sobre el margen, sin ser VS
(0.5, 0.5)	0	1	C	sobre la frontera
(0, 0)	0.5	0.5	C	dentro del margen
(−1, 0)	1	0	0	sobre el margen, sin ser VS

- $\Sigma\xi = 1 + 0.5 = 1.5$ y $½\|w\|^2 = 0.25$: el objetivo vale $0.25 + 1 \cdot 1.5 = 1.75$.
- $w = 1 \cdot (0.5, 0.5) - 1 \cdot (0, 0) = (½, ½)$: solo pesan los dos puntos con $\alpha = C$.

El objetivo $½\|w\|^2 + C\Sigma\xi$ de cada solución, evaluado con cada C:

Solución	$C = 0.1$	$C = 1$	$C = 10$
la de $C = 0.1$ (margen 2.77)	**0.335**	2.765	27.065
la de $C = 1$ (margen 1.41)	0.400	**1.750**	15.250
la de $C = 10$ (margen 0.35)	4.000	4.000	**4.000**

En cada columna gana la diagonal: con C chico conviene pagar holgura; con C grande, estrechar el margen.

Con C = 0.1, ningún VS queda sobre el margen: cualquier b entre 0 y 0.25 da el mismo objetivo; libsvm toma 0.125.

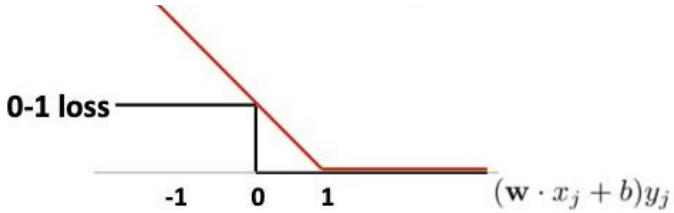
Slack variables – Hinge loss

El margen suave, escrito como pérdida más regularización:

$$\min_{w,\,b} \quad \frac{1}{2}\|w\|^2 + C\sum_j (1 - y_j\, f(x_j))_+$$

$$f(x) = w \cdot x + b, \qquad (z)_+ = \max(0,\ z)$$

- La bisagra vale 0 si $y_j f(x_j) \geq 1$ y crece en línea recta si el ejemplo entra al margen o cruza la frontera. La 0/1 solo cuenta errores.
- ½‖*w*‖² es una penalización L2: la que la logística de la sesión 11 quitó con $C = \infty$. En el SVM no se quita: maximizar el margen es regularizar.



SVM vs. Logistic Regression

SVM: pérdida bisagra $(1 - y\,f(x))_+$

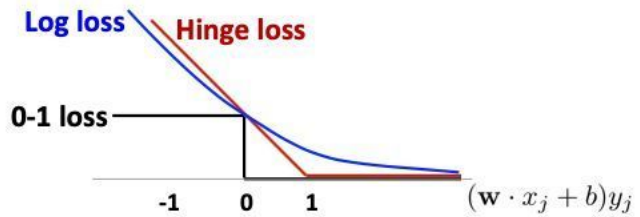
Regresión logística: pérdida logarítmica $-\ln P(y \mid x) \;=\; \ln\left(1 + e^{-y\,f(x)}\right)$

Es la $J(\theta)$ de la sesión 11 con $p = 1/(1 + e^{-f})$, en sus dos casos:

$$y = +1: \quad -\ln p = -\ln \frac{1}{1+e^{-f}} = \ln\left(1+e^{-f}\right)$$

$$y = -1: \quad -\ln(1-p) = -\ln \frac{e^{-f}}{1+e^{-f}} = \ln\left(1+e^{f}\right)$$

En los dos, $\ln(1 + e^{-yf})$. Las dos penalizan $\|w\|^2$ y usan C.
La bisagra vale 0 más allá del margen: solo cuentan los VS.
La logarítmica nunca vale 0 —cuentan todos—, pero da probabilidades.



La curva azul está en base 2: vale 1 en 0.

y·f	**−1**	**0**	**0.5**	**1**	**2**
bisagra	2.00	1.00	0.50	0.00	0.00
logarítmica	1.31	0.69	0.47	0.31	0.13

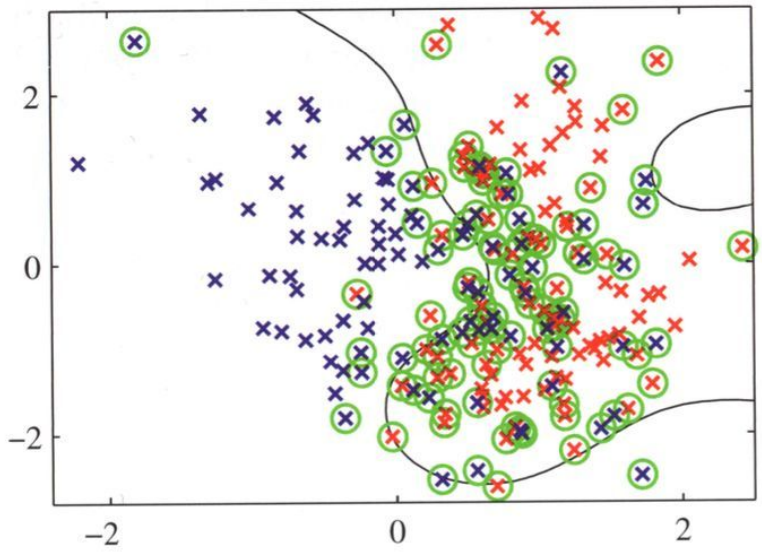
Soft-margin SVM using Gaussian Kernel

- Los puntos encerrados en un círculo son los vectores de soporte: ejemplos con α_j distinto de cero.
- Las curvas son niveles constantes de

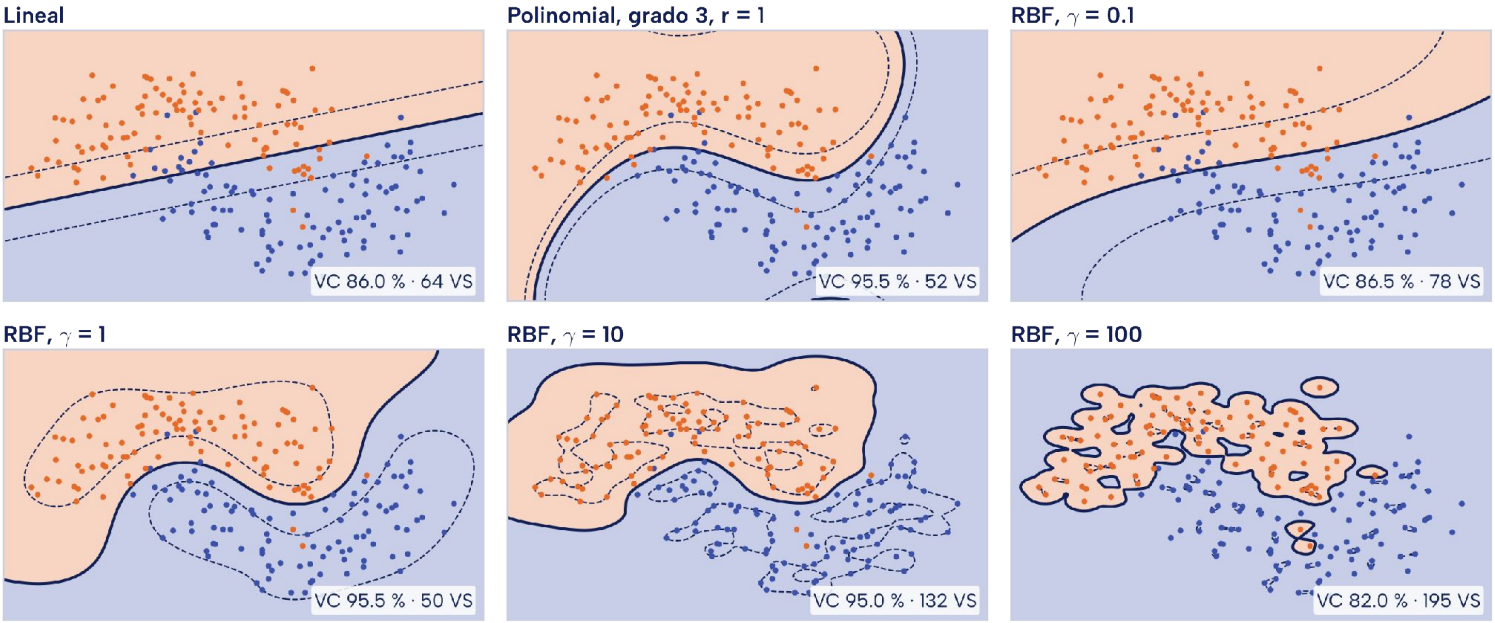
$$\hat{f}(x) = b + \sum_j \alpha_j \, y_j \, K(x, x_j)$$

$$K(x, x_j) = e^{-\gamma \|x - x_j\|^2}, \qquad \gamma = \frac{1}{2\sigma^2}$$

- Un voto ponderado por parecido, como el de Shepard (sesión 15): solo votan los VS, y su peso α_j se aprende.



El ancho del kernel: gamma

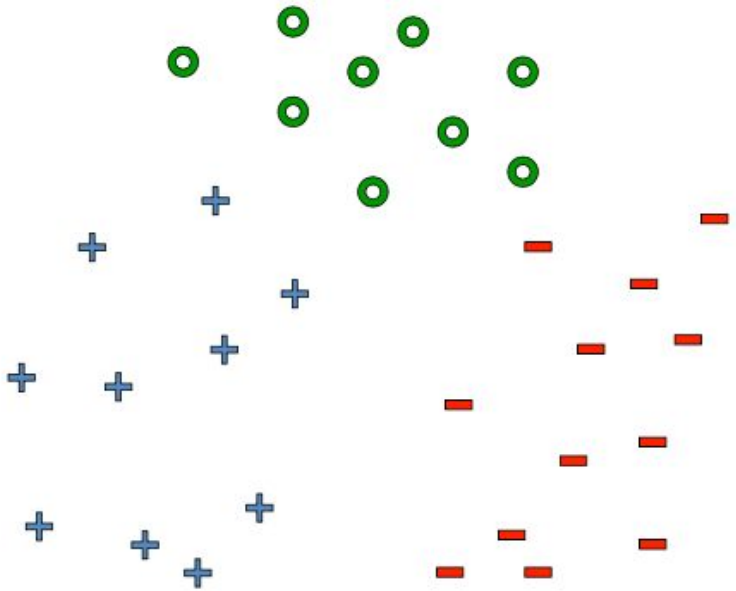


SVM en scikit-learn

Parámetro	Por omisión	Qué controla
`C`	`1.0`	el costo de cada violación (inverso de la regularización)
`kernel`	`"rbf"`	`"linear"`, `"poly"` o `"rbf"` (lámina 17)
`gamma`	`"scale"`	el ancho del RBF: $1/(D \cdot \mathrm{Var}(X))$
`degree`, `coef0`	`3`, `0.0`	el polinomial
`class_weight`	`None`	`"balanced"`: pesa las clases por su frecuencia (sesión 12)

- `support_vectors_`, `dual_coef_` ($\alpha_j y_j$), `intercept_` (b) y `coef_` (w, solo lineal); `decision_function` da $f(x)$.
- Sin escalar, `gamma="scale"` mezcla las varianzas de todas las columnas: en el vino, el F1 macro de validación cae de 0.569 a 0.376. El escalador va en el `Pipeline`.
- `probability=True` está deprecado en la versión 1.9; para probabilidades, `CalibratedClassifierCV(SVC(), ensemble=False)`.
- Entrenar `SVC` crece al menos con n^2: al duplicar n, el tiempo se multiplica casi por 4. `LinearSVC` crece casi en línea recta.

¿Qué pasa con varias clases?



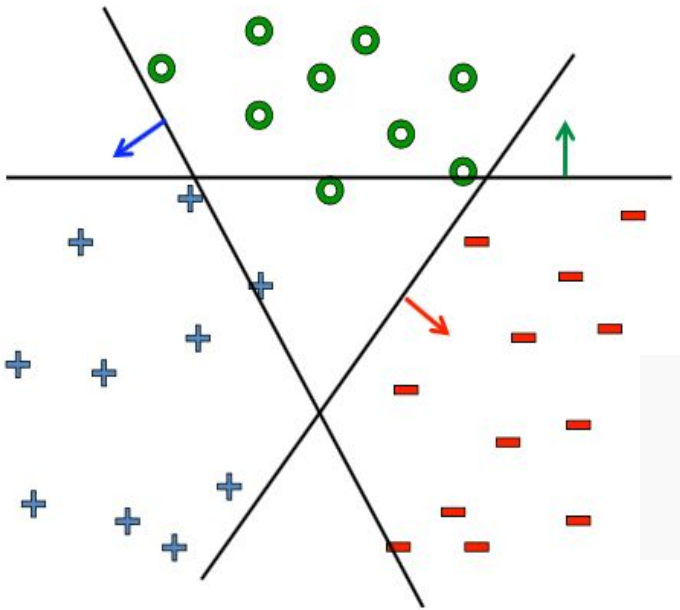
Solución a problemas multiclase

- Aprender 3 clasificadores por separado: Clase k vs el resto

$$(w_k, b_k)_{k=1,2,3}$$

$$y = arg\ \max_k\ w_k.x + b_k$$

- Pero es posible que los w_k no estén en la misma escala.
- Nota: *(aw).x + (ab)* también es una solución.



Uno contra uno

- **Uno contra el resto**: un clasificador por clase; gana el de mayor *f*. Lo usa `LinearSVC`.
- **Uno contra uno**: un clasificador por cada par de clases, $c(c-1)/2$ (45 con 10 clases); gana la clase con más votos. Lo usa `SVC`.
- En el vino, el mismo `LinearSVC` da 0.495 de F1 macro contra el resto y 0.575 uno contra uno: contra el resto, «alta» (14 % de los vinos) casi nunca gana.
- `decision_function_shape="ovr"`solo reacomoda la salida en una columna por clase.

Iris: una flor con pétalo de 4.9 × 1.6 cm

Par	*f*	Gana
setosa contra versicolor	−3.23	versicolor
setosa contra virginica	−1.22	virginica
versicolor contra virginica	+0.11	versicolor

Clase	Votos
versicolor	**2**
virginica	1
setosa	0

SVC(kernel="linear") con el largo y el ancho del pétalo. f > 0 vota por la primera clase del par. Predicción: versicolor.

SVM multiclase

Aprender a la vez los *c* conjuntos de pesos. Sin errores:

$$w^{(y_j)} \cdot x_j + b^{(y_j)} \geq w^{(y)} \cdot x_j + b^{(y)} + 1, \quad y \neq y_j$$

Con holguras:

$$\min_{w,\, b,\, \xi} \quad \frac{1}{2} \sum_{y} \|w^{(y)}\|^2 + C \sum_{j} \sum_{y \neq y_j} \xi_j^{(y)}$$

$$w^{(y_j)} \cdot x_j + b^{(y_j)} \geq w^{(y)} \cdot x_j + b^{(y)} + 1 - \xi_j^{(y)}, \quad \xi_j^{(y)} \geq 0$$

Predicción: $\hat{y} = \arg\max_{y} \; w^{(y)} \cdot x + b^{(y)}$

La optimización conjunta deja los $w^{(y)}$ en la misma escala.

`LinearSVC(multi_class="crammer_singer")` resuelve una parecida, con una holgura por ejemplo.

Caso de estudio: el SVM en los 14 días

Los días de la sesión 15: one-hot para outlook y z-scores para la temperatura y la humedad.

SVM lineal, C = 1	***w***
sunny	−0.87
overcast	+0.87
rain	0.00
temperatura (z)	−0.22
humedad (z)	−0.75
viento fuerte	−0.13
b	+0.83

- Se lee como el árbol de la sesión 13: overcast empuja a Sí; sunny y la humedad alta, a No. Margen: $1/\|w\| = 1/1.47 = 0.68$.
- 5 días quedan fuera del margen ($\alpha = 0$), 3 sobre él (8, 9 y 12) y 6 con $\alpha = C$; de esos, 4, 6 y 14 quedan mal clasificados.
- Día 15 (sunny, 81, 88, strong): $z = (81 - 73.57)/6.33 = 1.17$ y $z = (88 - 81.64)/9.91 = 0.64$. Así, $f = -0.87 - 0.22(1.17) - 0.75(0.64) - 0.13 + 0.83 = -0.90 \rightarrow$ No, su clase real.

Modelo	**Prueba**	**VS**
lineal, $C = 1$	11/14	9 de 14
RBF, $C = 1$ (por omisión)	11/14	13 de 14
RBF, $C = 10$	12/14	13 de 14

Elegir *C* y `gamma` sin mirar la prueba

Dejando uno fuera en los 14 días, sobre 80 combinaciones de kernel, *C* y γ:

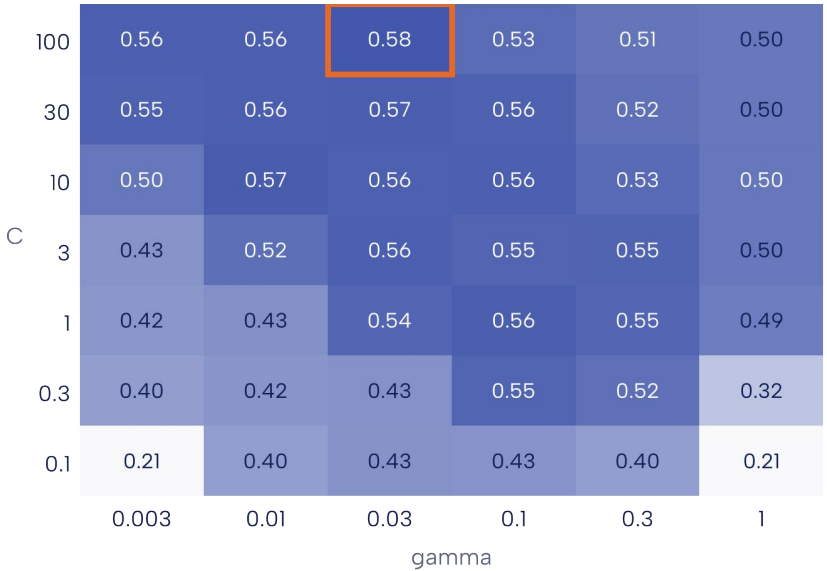
- gana el RBF con 10 de 14 (*C* = 3 y γ = 0.1, o *C* = 10 y γ = 0.03); en prueba, 11/14;
- 37 responden Sí siempre: empatan con la línea base (9 de 14);
- elegir con la prueba daría 13/14 (*C* = 100, γ = 0.01), pero esa combinación saca 7/14 dejando uno fuera.

La unidad en los mismos 14 días

Modelo	Aciertos
Árbol J48 (sesión 13)	12/14
Naive Bayes (sesión 14)	12/14
Regresión logística (sesión 11)	12/14
kNN, k = 5 (sesión 15)	10/14
SVM, *C* y γ dejando uno fuera	**11/14**
SVM elegido con la prueba	13/14

Salvo el elegido con la prueba, estos SVM fallan los días 18 y 27, cuyas etiquetas contradicen al árbol de la 13. Un día vale 7 puntos: ninguna diferencia es concluyente.

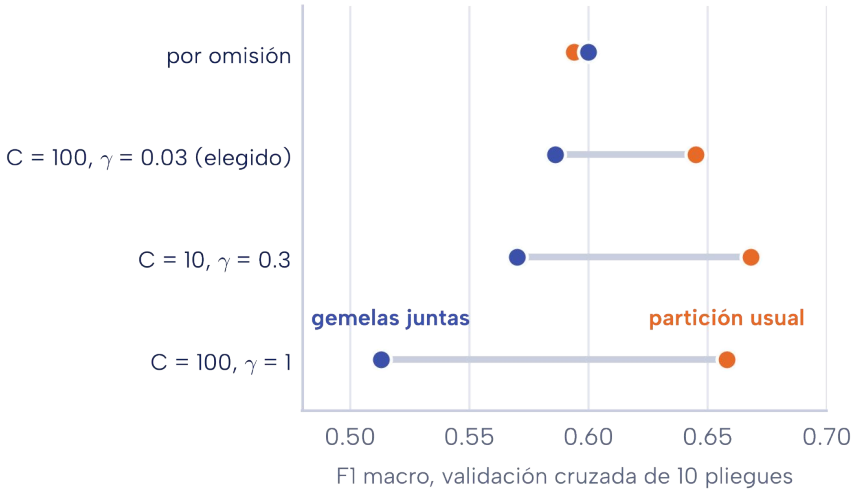
El vino: elegir *C* y gamma



F1 macro de validación con kernel RBF.
En naranja, la combinación elegida.

- Validación agrupada de 5 pliegues en los 1279 vinos de entrenamiento. Gana el RBF con $C = 100$ y $\gamma = 0.03$: 0.582 ± 0.027 (0.807 en entrenamiento). El mejor lineal: 0.555.
- En prueba, una sola vez: **0.576**. El SVC por omisión da 0.593: la búsqueda no gana. El mejor de 46 combinaciones sale optimista en validación.
- 909 de los 1279 vinos son VS (71 %): con clases que se traslapan, el SVM casi no resume.

Los duplicados y gamma



- El notebook 12 dijo que la SVM casi no cambia con las gemelas juntas (0.594 → 0.600) porque no memoriza. Solo vale con los valores por omisión.
- Con γ grande, cada vino de entrenamiento es su propia isla y la gemela decide, como en el kNN con pesos por distancia (sesión 15). Con $C = 100$ y $\gamma = 1$: 1.00 en entrenamiento y 0.50 en validación.
- La rejilla con la partición usual elige $C = 10$ y $\gamma = 0.3$: promete 0.663 y da 0.547 en prueba. La agrupada: 0.582 y 0.576.

La unidad 4 en una tabla

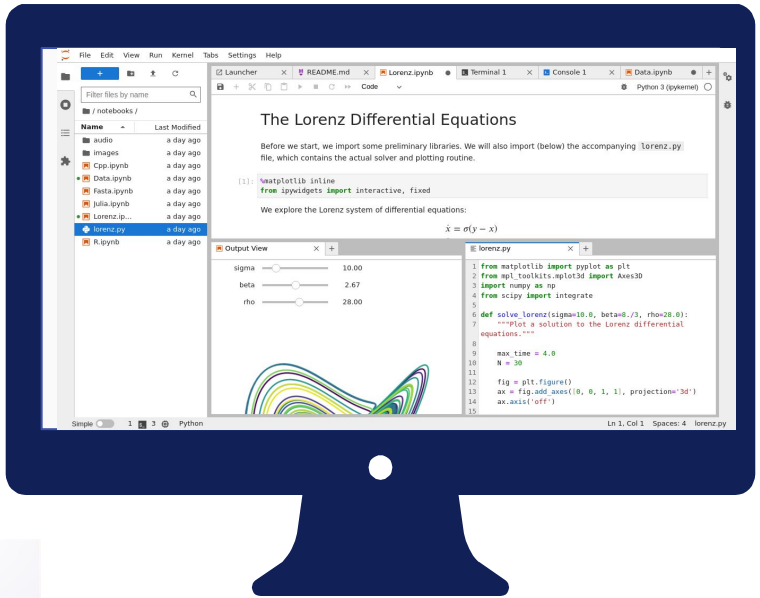
Modelo	Entrenar	Se ajusta	¿Escalar?	F1 vino	Log-loss	14 días
Regresión logística (11)	descenso de gradiente	C (aquí, ∞)	con penalización	0.573	0.754	12/14
Árbol de decisión (13)	crecer y podar	profundidad, hojas	no	0.551	3.133	12/14
Naive Bayes (14)	contar y promediar	suavizado	no	0.596	0.955	12/14
kNN (15)	guardar T	k, métrica, pesos	sí	0.584	0.770	10/14
SVM (16)	un QP: al menos n^2	C, kernel, γ	sí	**0.576**	0.800	**11/14**

En el vino, las diferencias de F1 no superan el ruido entre pliegues (0.02 a 0.05). Lo que separa a los modelos es su costo, si dan buenas probabilidades y si hay que escalar.

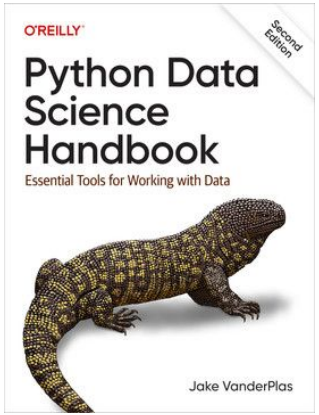
Resumiendo SVM

- **Objetivo**: la frontera con el mayor margen; solo los vectores de soporte la definen.
- **Primal y dual**: el dual depende de productos punto y escribe la decisión con los VS.
- **Kernels**: fronteras no lineales sin calcular Φ (lineal, polinomial, RBF).
- **Margen suave**: holguras ξ y la pérdida bisagra; C pesa los errores contra $\|w\|^2$.
- **Varias clases**: uno contra uno (`SVC`), uno contra el resto (`LinearSVC`) o conjunta.
- **Algoritmo**: QP convexo, con un único óptimo global; su costo crece al menos con n^2.
- **En la práctica**: escalar en el `Pipeline` y elegir C y γ con validación, agrupada si hay duplicados.

(Go to live notebook)



Extra Libro



GitHub

05.07-Support-Vector-Machines.ipynb

Gracias!

¿Alguna pregunta?

hussein@cicese.edu.mx



SCAN ME