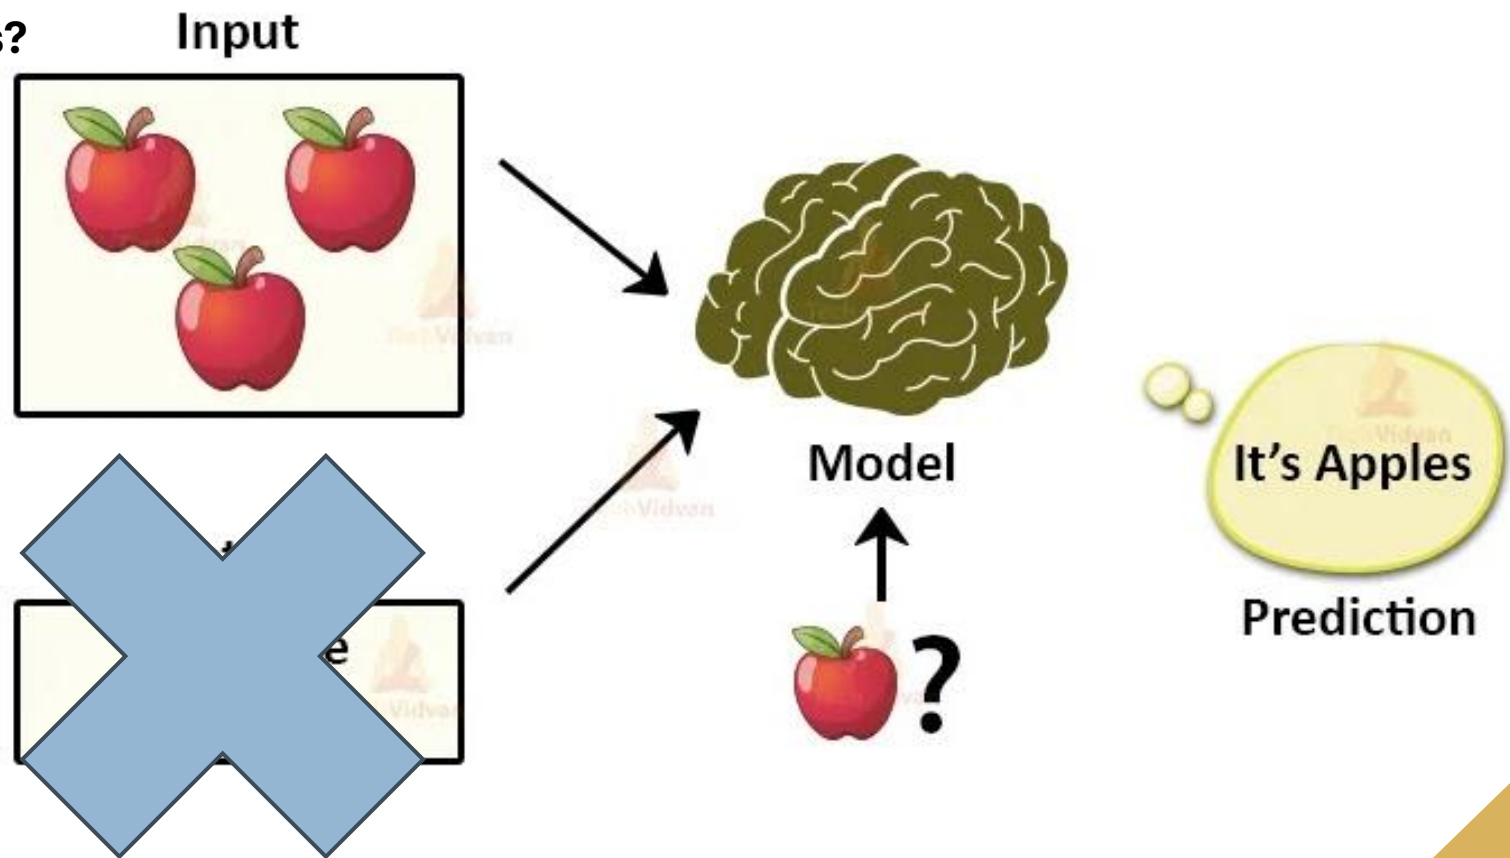
Aprendizaje no supervisado

Joan Raygoza

Supervised Learning in ML

¿Qué puedo hacer con esos datos?

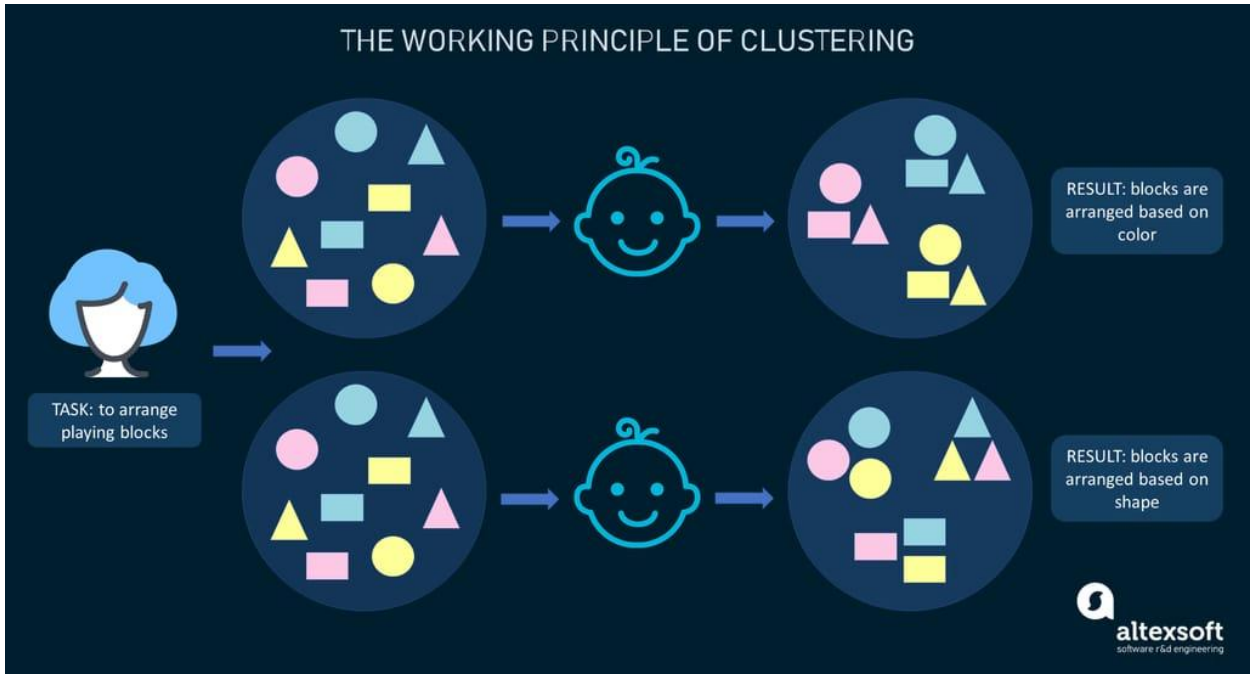


¿Qué es aprendizaje automático no supervisado?

- Es el conjunto de métodos que buscan **encontrar estructura**, **patrones**, **grupos**, o **representaciones** en los datos **sin etiquetas**.
- En supervisado: hay variable objetivo y (clase o valor).
- En no supervisado: solo tienes X (características/atributos).

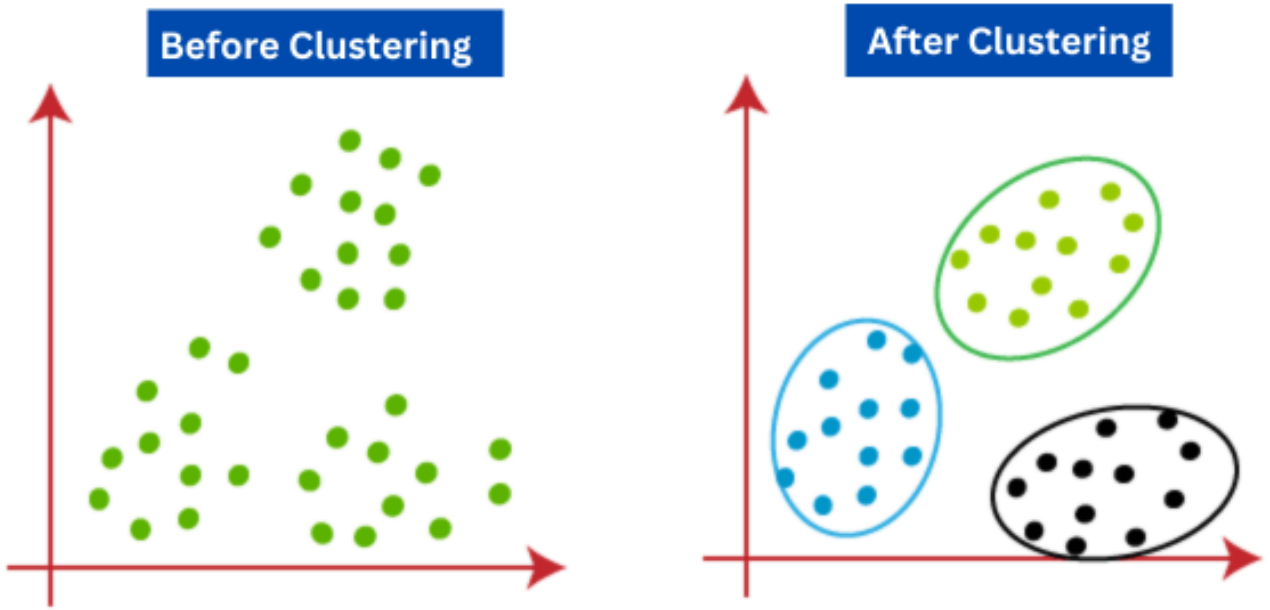
¿Qué se intenta aprender?

- Supervisado: aprender $f: X \rightarrow y$ (predecir).
- No supervisado: aprender **la estructura de X**:
  - grupos (clustering)
  - componentes/representaciones (reducción de dimensionalidad)
  - rarezas (anomalías)
  - asociaciones (reglas)



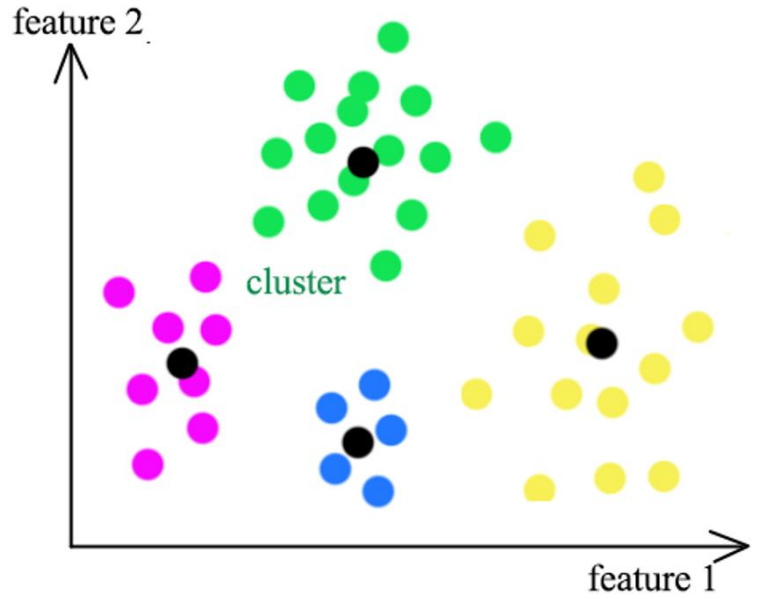
Clustering

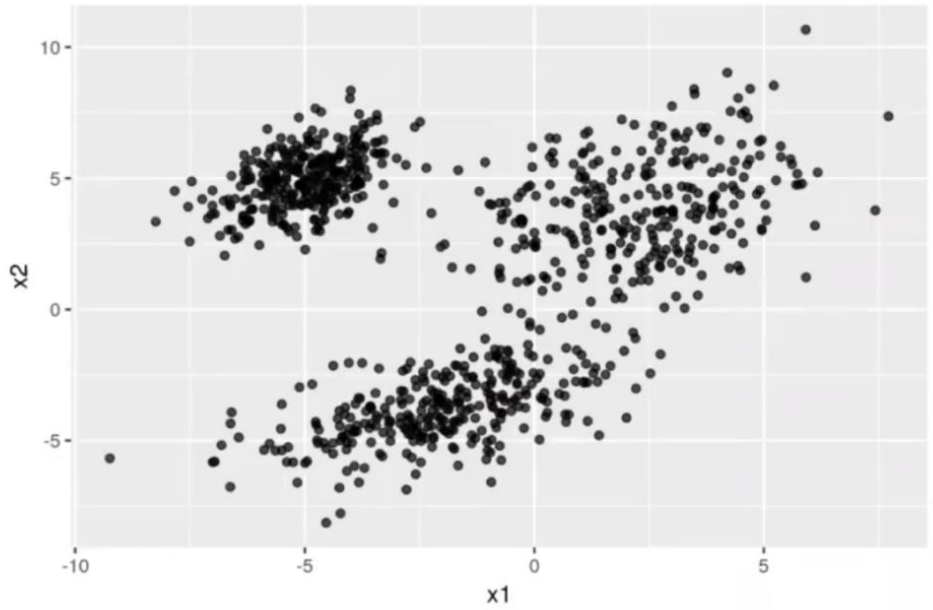
- **Clustering** es el proceso de **agrupar observaciones** de modo que:
  - objetos del mismo grupo sean **similares**
  - objetos de distintos grupos sean **diferentes**

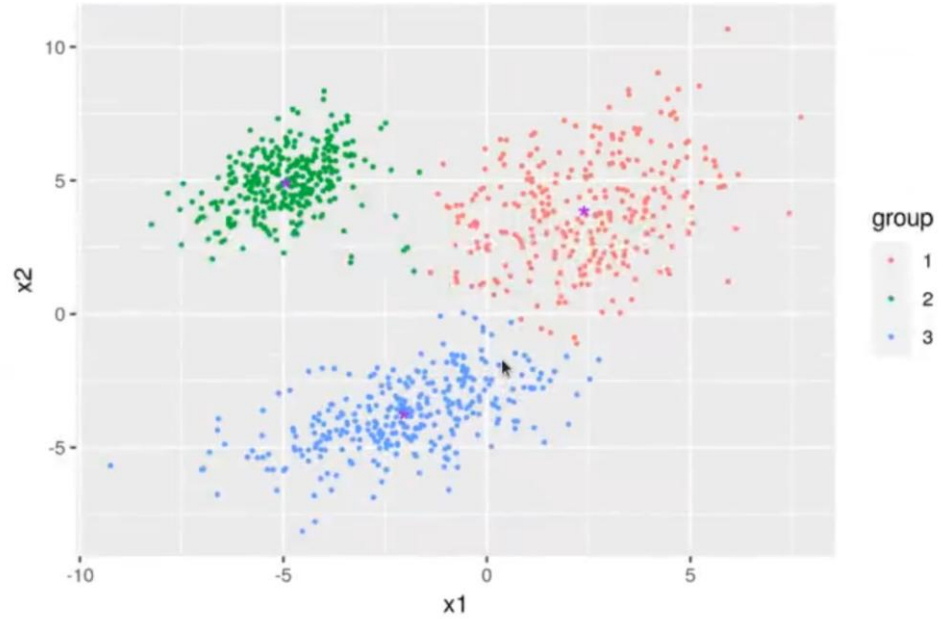


Clustering

- **Clustering = medir similitud + decidir cluster**
- Si tu noción de similitud es mala, el clustering será malo.
- Si escalas mal los datos, una variable domina.



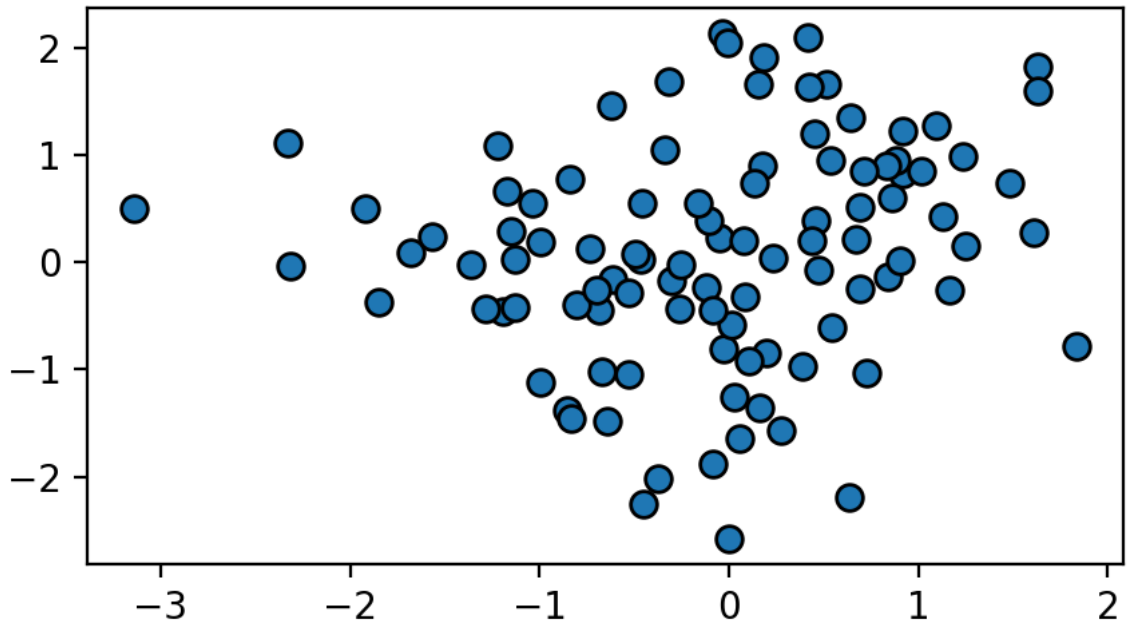




Ejemplo

Ejemplo

¿Qué pasa si los grupos no son claros o evidentes?



¿Qué puede considerarse un clúster?

- Un clúster puede definirse como:
  - Un conjunto compacto alrededor de un centro.
  - Una región de alta densidad separada por regiones de baja densidad.
  - Un componente conectado dentro de un grafo.
  - Una población generada por una distribución probabilística.
  - Un grupo al que las observaciones pertenecen en distintos grados.
  - Una separación que forma parte de una estructura jerárquica.
- La elección del algoritmo implica asumir una determinada definición de clúster.

Principales familias de algoritmos

Basados en centroides: K-means.

Jerárquicos: clustering aglomerativo y divisivo.

Basados en densidad: DBSCAN.

Basados en modelos probabilísticos: Gaussian Mixture Models.

Basados en grafos: Spectral Clustering.

Basados en lógica difusa: Fuzzy C-Means.

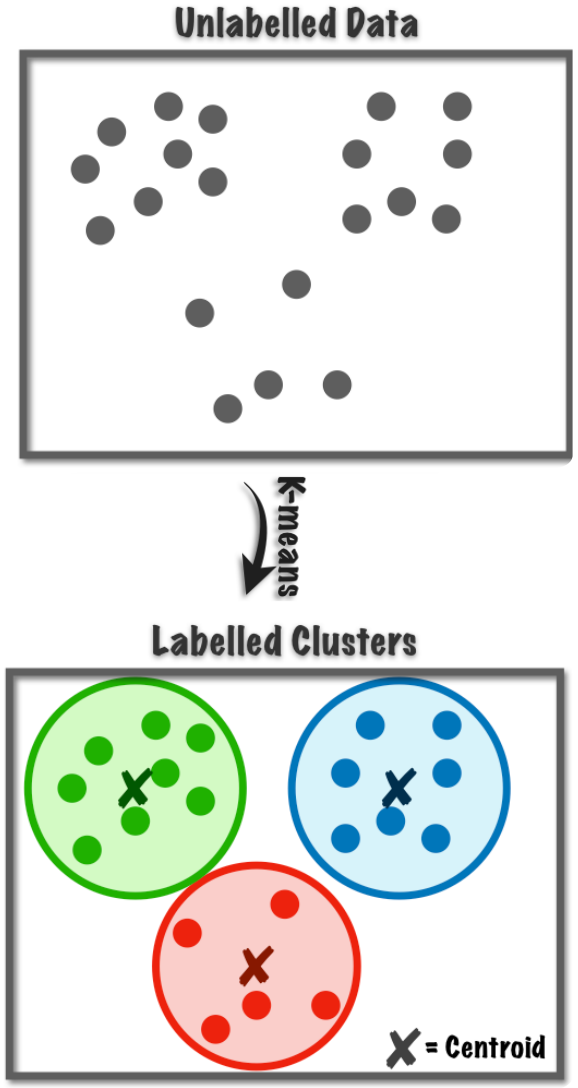
Cada familia puede producir resultados diferentes sobre el mismo conjunto de datos.

Similitud y distancia

- La agrupación depende de cómo se mide la similitud entre observaciones.
- Distancia euclidiana:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{l=1}^{p} (x_{il} - x_{jl})^2}$$

- Otras opciones:
  - Distancia Manhattan.
  - Distancia de Minkowski.
  - Distancia de Mahalanobis.
  - Similitud coseno.
  - Distancia de Jaccard para variables binarias.
  - Distancias específicas para secuencias, grafos o series temporales.
- Las variables deben escalarse cuando tienen unidades o rangos diferentes.



Clustering basado en centroides

- Cada clúster se representa mediante un punto central, despues cada observación se asigna al centro más cercano.
- **Algoritmos representativos:**
  - K-means.
  - K-medoids.
- Este enfoque funciona especialmente bien cuando los grupos son compactos, aproximadamente esféricos y de tamaño similar.

K-means: idea principal

- K-means divide n observaciones en K grupos:

$$C_1, C_2, \ldots, C_K$$

- Cada grupo se representa mediante su centroide:

$$\boldsymbol{\mu}_k = \frac{1}{|\ C_k\ |} \sum_{\mathbf{x}_i \in C_k} \mathbf{x}_i$$

- El centroide es el promedio de las observaciones asignadas al clúster.
- **Objetivo:**
  - Observaciones cercanas al mismo centroide.
  - Centroides suficientemente separados.
  - Baja dispersión dentro de cada grupo.

Función objetivo de K-means

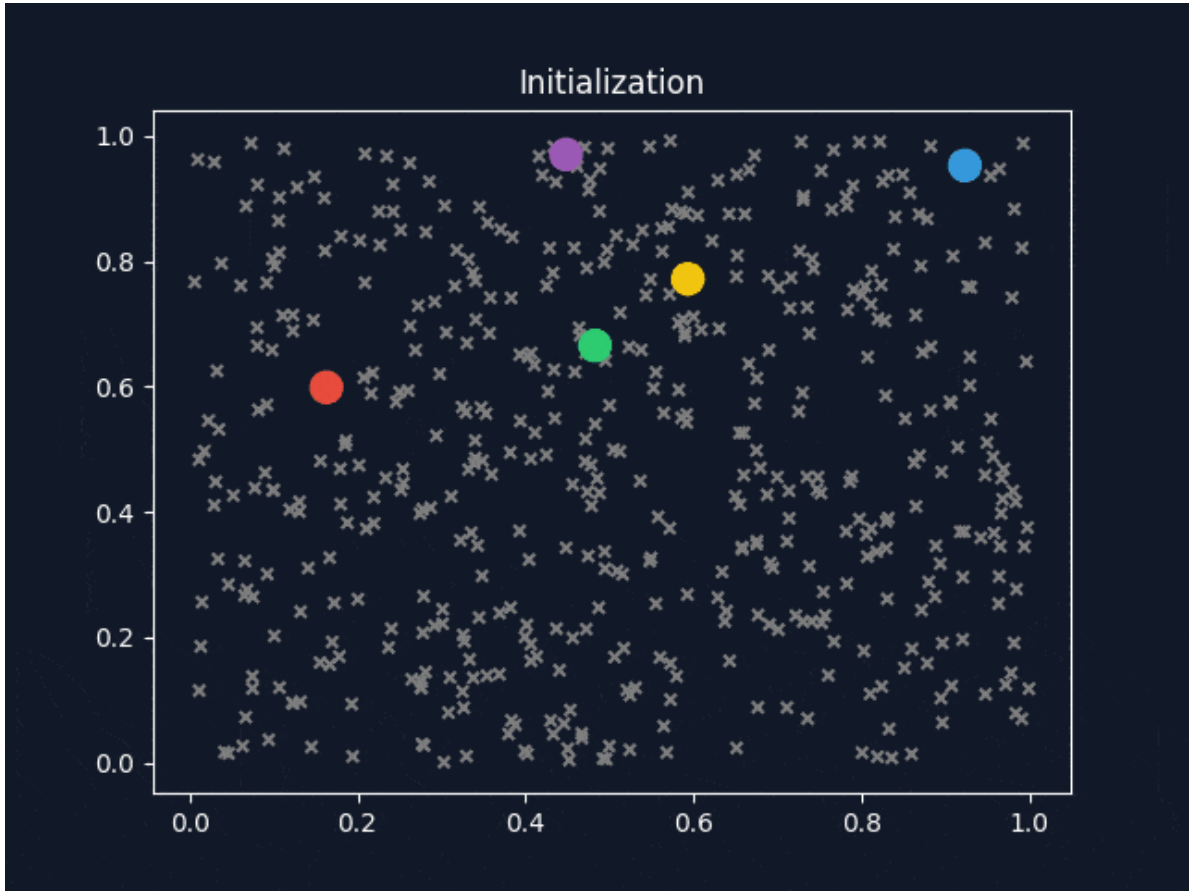
- K-means minimiza la suma de cuadrados dentro de los clústeres:

$$J = \sum_{k=1}^{K} \sum_{\mathbf{x}_i \in C_k} \| \mathbf{x}_i - \boldsymbol{\mu}_k \|^2$$

- También se conoce como **Inercia**.
- ¿Qué pasaría con la inercia si tenemos el mismo número de clusters que de puntos?
- Una menor inercia indica grupos más compactos, pero siempre disminuye al aumentar K.
- Por ello no puede utilizarse de manera aislada para seleccionar el número de clústeres.

Algoritmo de K-means

1. Seleccionar el número de clusters K.
2. Inicializar K centroides.
3. Asignar cada observación al centroide más cercano:
$$c_i = \arg\min_k \| \mathbf{x}_i - \boldsymbol{\mu}_k \|^2$$
4. Recalcular cada centroide utilizando la media del cluster.
5. Repetir la asignación y actualización hasta que:
    - Las asignaciones no cambien.
    - Los centroides apenas se desplacen.
    - Se alcance el número máximo de iteraciones.
6. El algoritmo converge, pero no necesariamente encuentra el óptimo global.

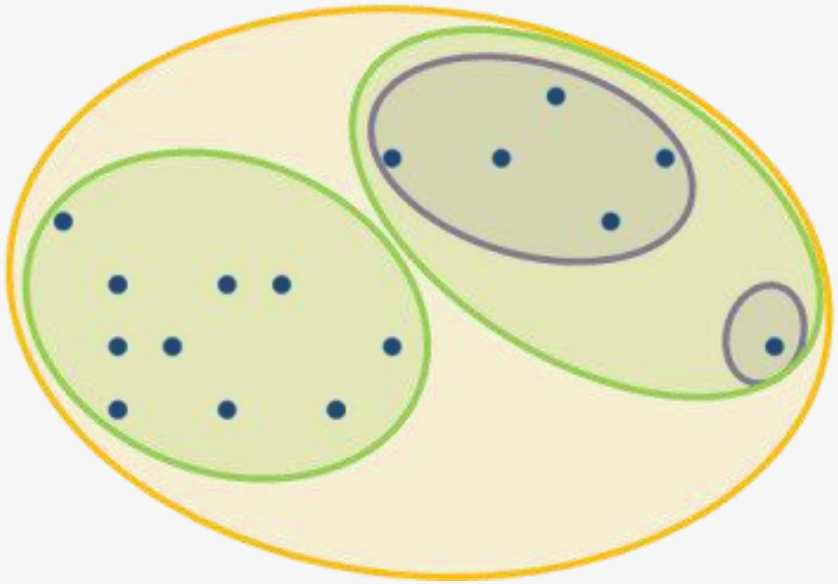


Ventajas y limitaciones de K-means

- **Ventajas**
  - Simple de entender e implementar.
  - Computacionalmente eficiente $O(kn)$.
  - Escalable a grandes conjuntos de datos.
  - Fácil asignación de nuevas observaciones.
  - Produce centroides interpretables.
- **Limitaciones**
  - Requiere especificar K.
  - Es sensible a la inicialización.
  - Es sensible a valores atípicos.
  - Depende del escalamiento.
  - Favorece clústeres esféricos, convexos y de tamaño semejante.

Fundamentos del clustering jerárquico

- El clustering jerárquico representa clusters anidados en diferentes niveles.
- Dos enfoques:
  - **Aglomerativo:** comienza con una observación por clúster y los fusiona.
  - **Divisivo:** comienza con todas las observaciones juntas y divide los clusters.
- La jerarquía se representa mediante un dendrograma.



Clustering aglomerativo

- **Procedimiento:**
  1. Cada observación comienza como un clúster independiente.
  2. Se calcula la distancia entre todos los clústeres.
  3. Se fusionan los dos clústeres más próximos.
  4. Se actualizan las distancias.
  5. Se repite hasta obtener un único clúster.
- Para n observaciones:
  - Se comienza con n clusters.
  - Después de cada fusión se reduce el número de clusters en uno.
  - Se realizan $n - 1$ fusiones.

Criterios de enlace

- La distancia entre clústeres puede definirse de diferentes formas.
- **Single linkage:**

$$d(A,B) = \min_{\mathbf{x}\in A,\mathbf{y}\in B} d(\mathbf{x},\mathbf{y})$$

- **Complete linkage:**

$$d(A,B) = \max_{\mathbf{x}\in A,\mathbf{y}\in B} d(\mathbf{x},\mathbf{y})$$

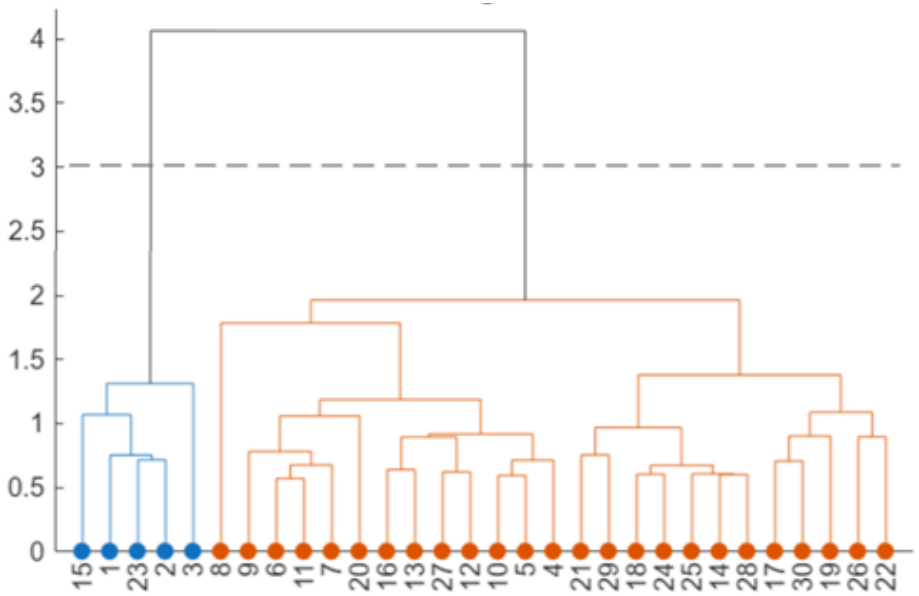
- **Average linkage:**

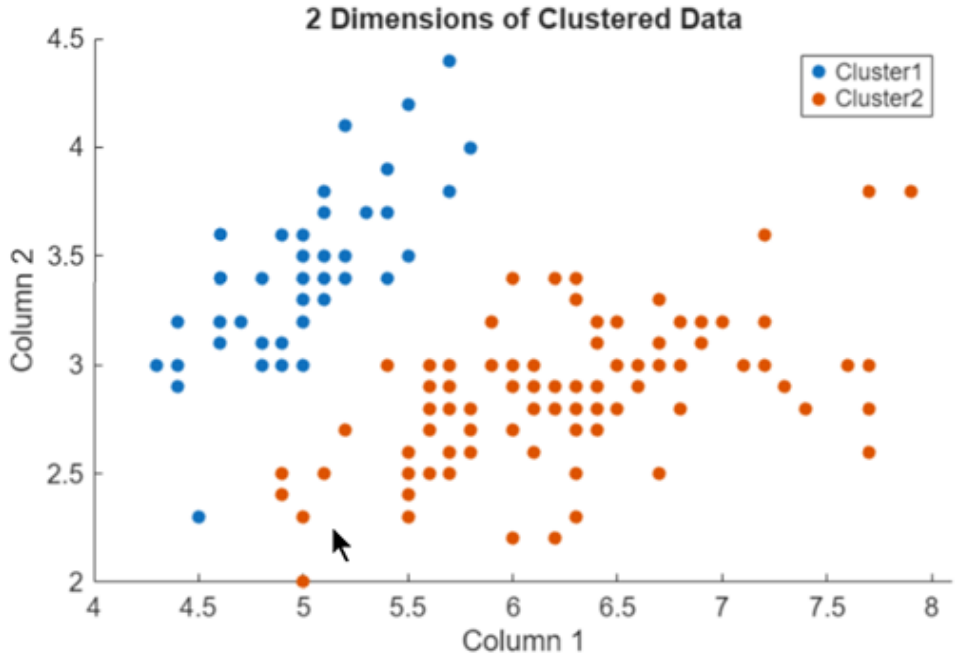
$$d(A,B) = \frac{1}{|A||B|}\sum_{\mathbf{x}\in A}\sum_{\mathbf{y}\in B} d(\mathbf{x},\mathbf{y})$$

- Cada criterio produce una geometría de agrupamiento diferente.

Clustering divisivo

- El enfoque divisivo sigue una estrategia de arriba hacia abajo:
  - Todas las observaciones comienzan en un único clúster.
  - Se selecciona un cluster para dividir.
  - Se divide utilizando un criterio de separación.
  - Se repite hasta alcanzar:
    - El número deseado de grupos.
    - Un tamaño mínimo.
    - Un umbral de heterogeneidad.
- **Posibles estrategias:**
  - Separar el grupo con mayor dispersión.
  - Utilizar K-means con $K = 2$ en cada división.
- Suele ser más costoso que el enfoque aglomerativo.





Interpretación del dendrograma

- El dendrograma muestra:
  - Las observaciones en las hojas.
  - Las fusiones en los nodos.
  - La distancia o disimilitud en la altura de las uniones.
- Para obtener K clusters:
  - Se realiza un corte horizontal.
  - Las ramas resultantes representan los clústeres.
- Una gran diferencia entre alturas consecutivas puede indicar una separación natural.

Ventajas y limitaciones del clustering jerárquico

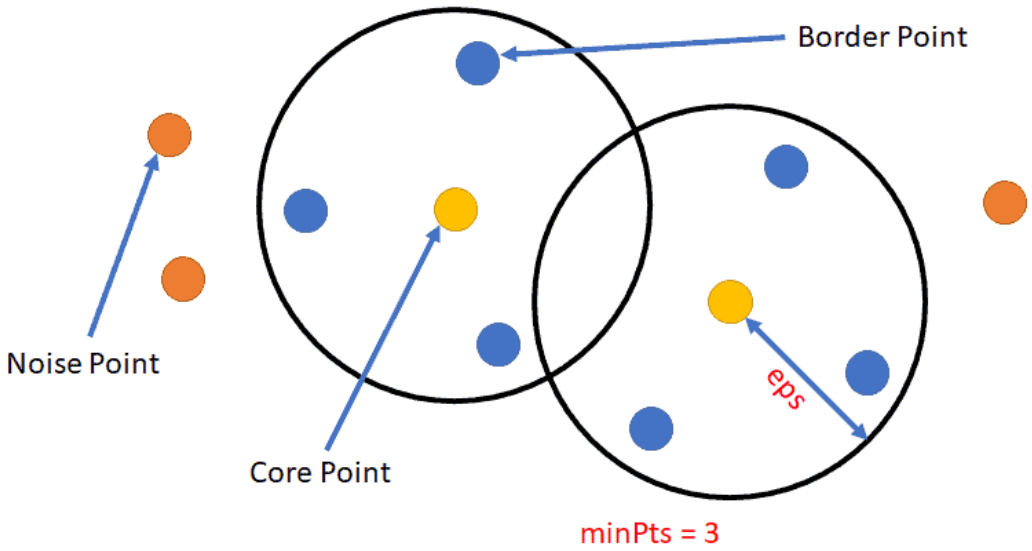
- **Ventajas**
  - No requiere definir inicialmente el número de clusters.
  - Proporciona una representación multiescala.
  - El dendrograma facilita la interpretación.
  - Permite utilizar diferentes distancias y enlaces.
  - Puede revelar subgrupos dentro de grupos mayores.
- **Limitaciones**
  - Mayor costo computacional y de memoria $O(n^2)$.
  - Las fusiones o divisiones tempranas normalmente no se corrigen.
  - Sensible al escalamiento y a valores atípicos.
  - El resultado depende del criterio de enlace.
  - El dendrograma se vuelve difícil de interpretar para conjuntos grandes.

Clustering basado en densidad

- Los métodos basados en densidad consideran un clúster como:
  - Una región con alta concentración de observaciones separada de otras regiones por zonas de baja densidad.
- Algoritmos representativos: DBSCAN, OPTICS y HDBSCAN.



DBSCAN: conceptos fundamentales



- DBSCAN utiliza dos parámetros:
  - ε: radio del vecindario.
  - min_samples: número mínimo de observaciones para considerar una región densa.
- Vecindario de una observación:

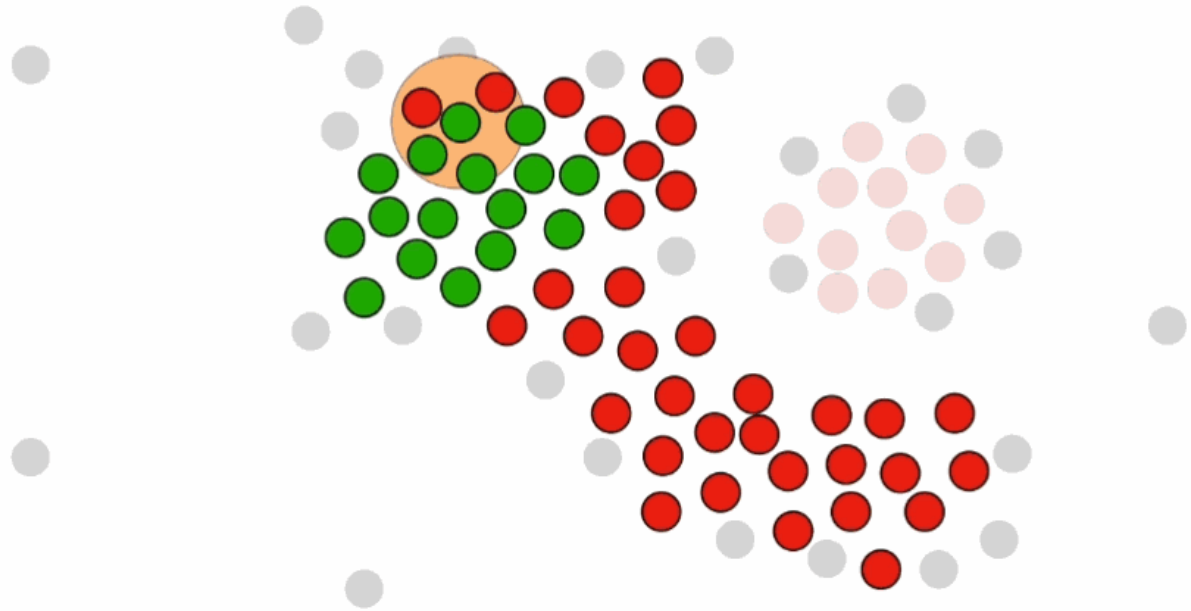
$$N_\varepsilon(\mathbf{x}_i) = \{\mathbf{x}_j : d(\mathbf{x}_i, \mathbf{x}_j) \leq \varepsilon\}$$

- Tipos de puntos:
  - **Núcleo:** tiene suficientes vecinos.
  - **Frontera:** está cerca de un núcleo, pero no tiene suficientes vecinos.
  - **Ruido:** no pertenece a una región densa.

Funcionamiento de DBSCAN

1. Seleccionar una observación no visitada.
2. Calcular su vecindario de radio ε.
3. Si es un punto núcleo, crear un nuevo clúster.
4. Expandir el clúster incluyendo puntos alcanzables por densidad.
5. Si no puede incorporarse a un grupo, marcarlo temporalmente como ruido.
6. Repetir hasta visitar todas las observaciones.

Un punto inicialmente marcado como ruido puede convertirse posteriormente en punto frontera.



Ventajas y limitaciones de DBSCAN

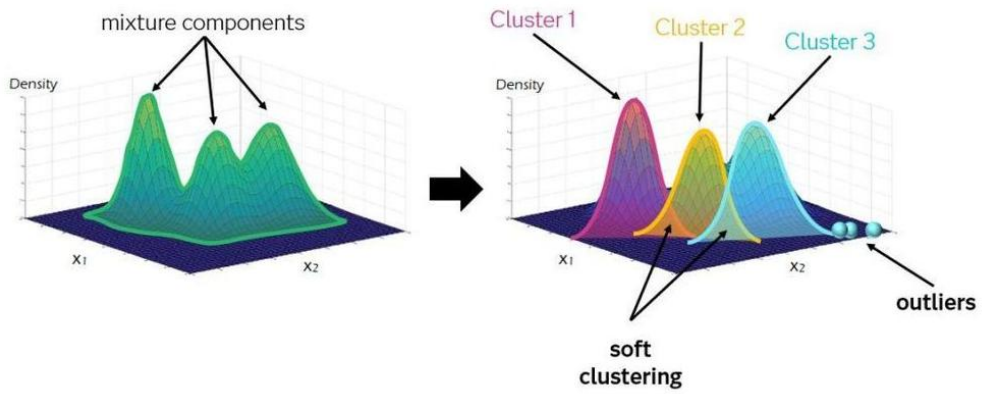
- **Ventajas**
  - No requiere especificar previamente el número de clústeres.
  - Puede identificar clústeres con formas arbitrarias y no convexas.
  - Detecta explícitamente observaciones consideradas ruido o valores atípicos.
- **Limitaciones**
  - Tiene dificultades cuando los clústeres presentan densidades muy diferentes.
  - Su desempeño disminuye en espacios de alta dimensionalidad debido a la pérdida de significado de las distancias.
  - Puede unir clústeres distintos si existe una cadena de puntos suficientemente densa entre ellos.
  - Puede clasificar como ruido grupos pequeños o poco densos.
  - No dispone de un mecanismo para asignar nuevas observaciones sin volver a ajustar el modelo.

Clustering basado en modelos probabilísticos: GMM

- Un GMM supone que los datos fueron generados por una mezcla de K distribuciones gaussianas:

$$p(\mathbf{x}) = \sum_{k=1}^{K} \pi_k \, \mathcal{N}(\mathbf{x}, | \, \boldsymbol{\mu}_k \boldsymbol{\Sigma}_k)$$

- Donde:
  - π_k: peso del componente.
  - $\boldsymbol{\mu}_k$: media.
  - $\boldsymbol{\Sigma}_k$: matriz de covarianza.
  - $\sum_k \pi_k = 1$.
- A diferencia de K-means, un GMM puede modelar clusters elípticos, orientados y con distinta dispersión.



Pertenencia probabilística

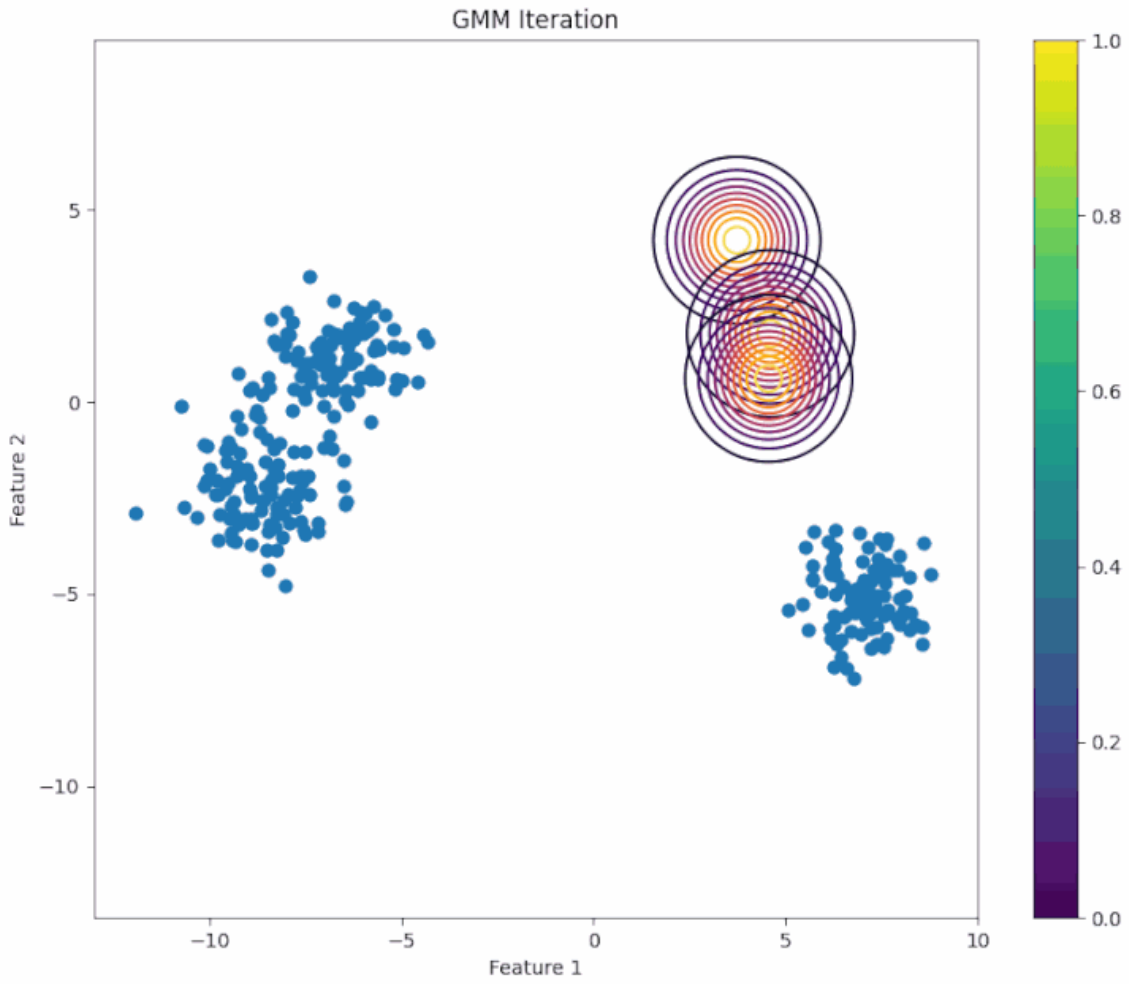
La probabilidad de que una observación pertenezca al cluster k es:

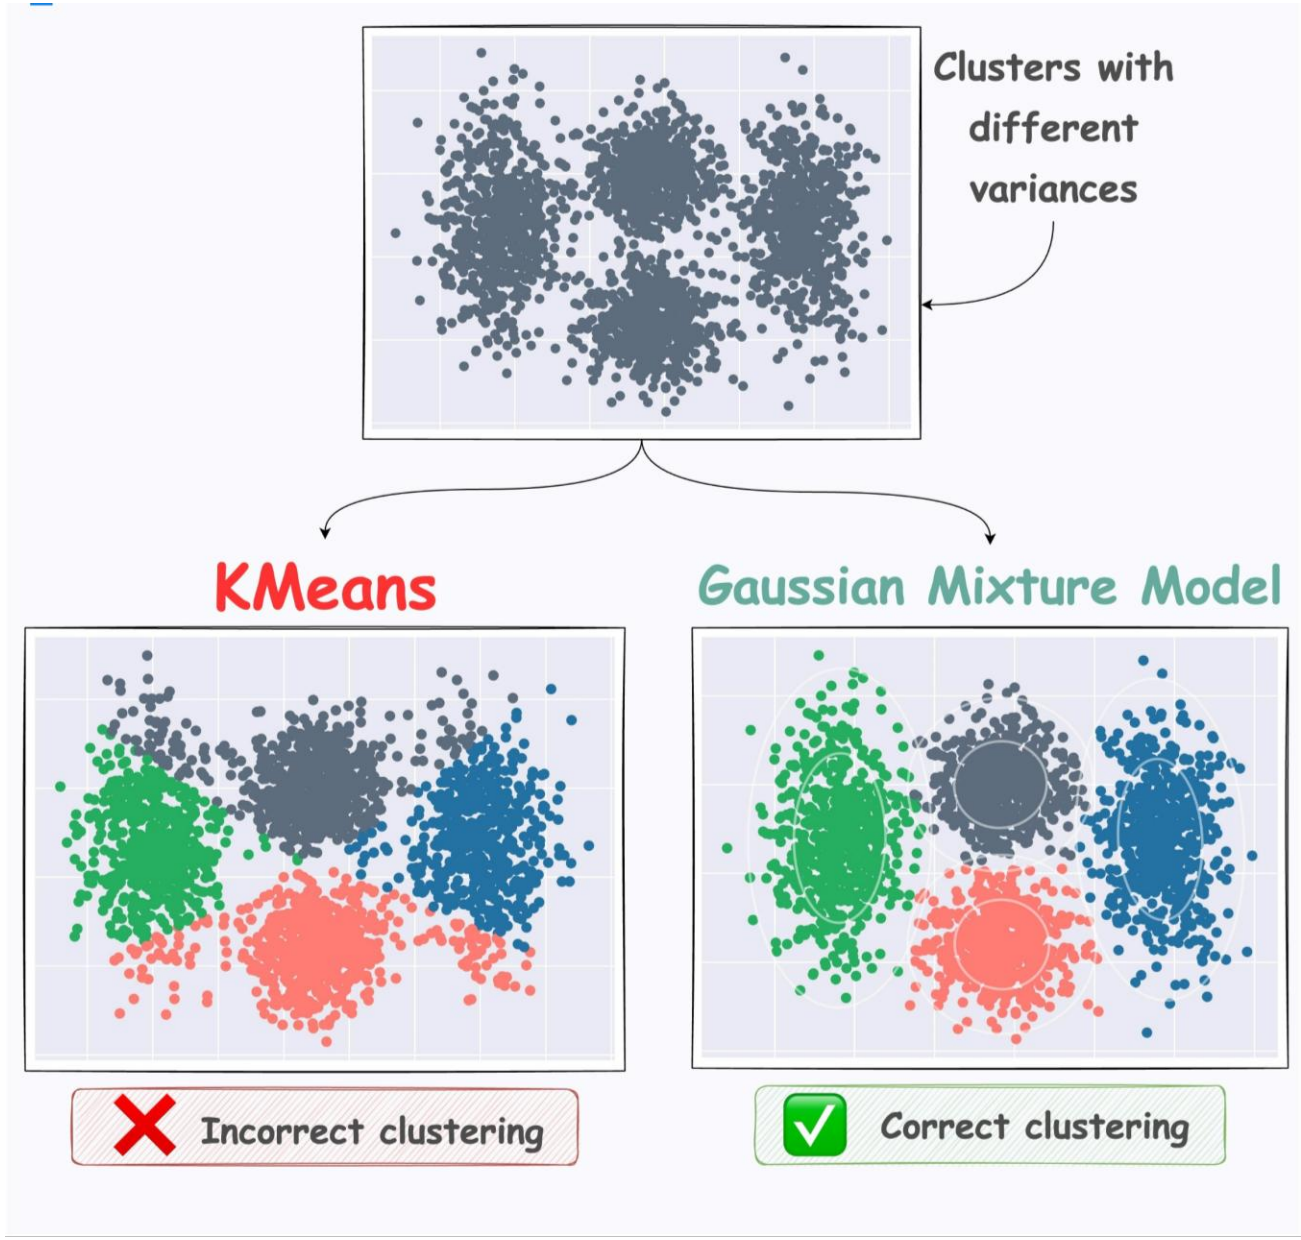
$$\gamma_{ik} = P(z_i = k \mid \mathbf{x}_i) = \frac{\pi_k \mathcal{N}(\mathbf{x}_i, \mid \boldsymbol{\mu}_k \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \, \mathcal{N}\left(\mathbf{x}_i, \mid \boldsymbol{\mu}_j \boldsymbol{\Sigma}_j\right)}$$

- Estas probabilidades se denominan **responsabilidades**.
- Ejemplo:

$$P(z_i = 1) = 0.70, P(z_i = 2) = 0.30$$

- La asignación final puede ser dura, seleccionando el componente con mayor probabilidad, o conservarse como una asignación probabilística.

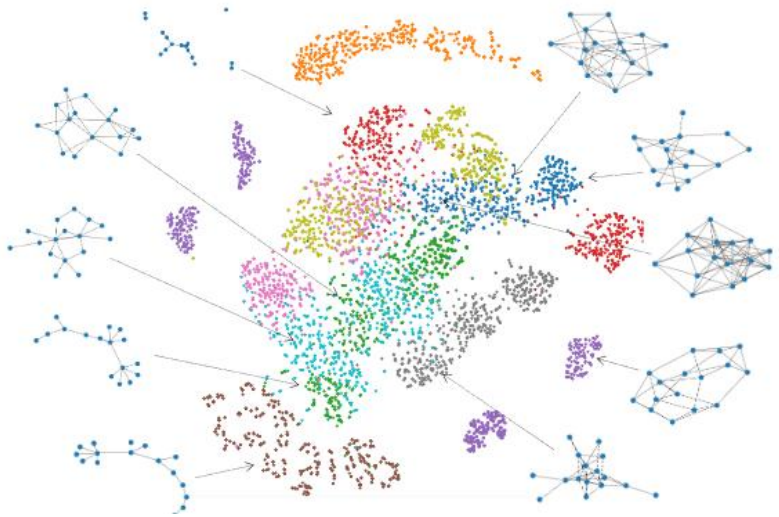

GMM Iteration
Feature 1
Feature 2
−10
−5
0
5
10
−10
−5
0
5
1.0
0.8
0.6
0.4
0.2
0.0


Clusters with different variances
KMeans
Gaussian Mixture Model
Incorrect clustering
Correct clustering

Ventajas y limitaciones de GMM

- **Ventajas**
  - Proporciona una pertenencia probabilística a cada clúster.
  - Puede modelar clústeres elípticos, orientados y con diferentes dispersiones.
  - Permite estimar la densidad de probabilidad de los datos.
- **Limitaciones**
  - Requiere especificar o seleccionar el número de clusters.
  - Supone que los datos son generados por una mezcla de distribuciones, normalmente gaussianas.
  - Puede fallar cuando los grupos tienen formas muy irregulares o no gaussianas.

Clustering basado en grafos

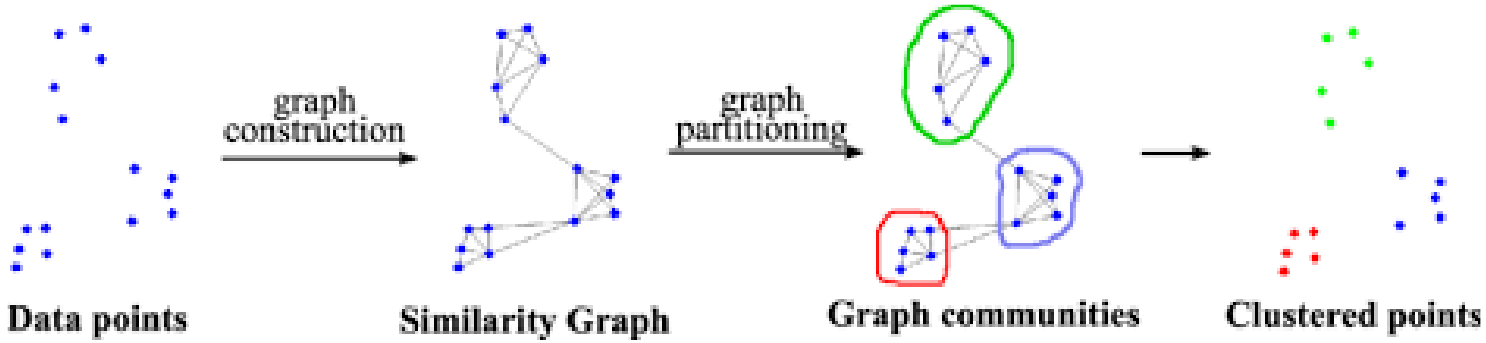


- Spectral Clustering representa los datos mediante un grafo:
  - Cada observación es un nodo.
  - Las aristas representan similitud.
  - Las aristas con mayor peso conectan observaciones más similares.
  - Una similitud frecuente es el kernel RBF:

$$w_{ij} = \exp\left(-\frac{\| \mathbf{x}_i - \mathbf{x}_j \|^2}{2\sigma^2}\right)$$

- También pueden construirse grafos mediante:
  - k vecinos más cercanos.
  - Vecindarios de radio ε.
- El objetivo es encontrar clusters con muchas conexiones internas y pocas conexiones externas.

Del grafo a los clústeres



- A partir de la matriz de similitud W, se construye la matriz de grado:

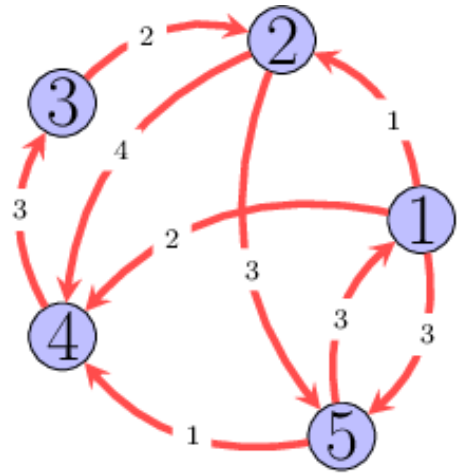
$$D_{ii} = \sum_j W_{ij}$$

- Laplaciano no normalizado:

$$L = D - W$$

- Procedimiento general:
  - Construir el grafo de similitud.
  - Calcular el Laplaciano.
  - Obtener los primeros K vectores propios.
  - Representar las observaciones en el espacio espectral.
  - Aplicar K-means sobre esa representación.

Ejemplo



(a) An example directed graph.

$$W = \begin{bmatrix} 0 & 0 & 0 & 0 & 3 \\ 1 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 \\ 2 & 4 & 0 & 0 & 1 \\ 3 & 3 & 0 & 0 & 0 \end{bmatrix}$$

(b) Weight matrix.

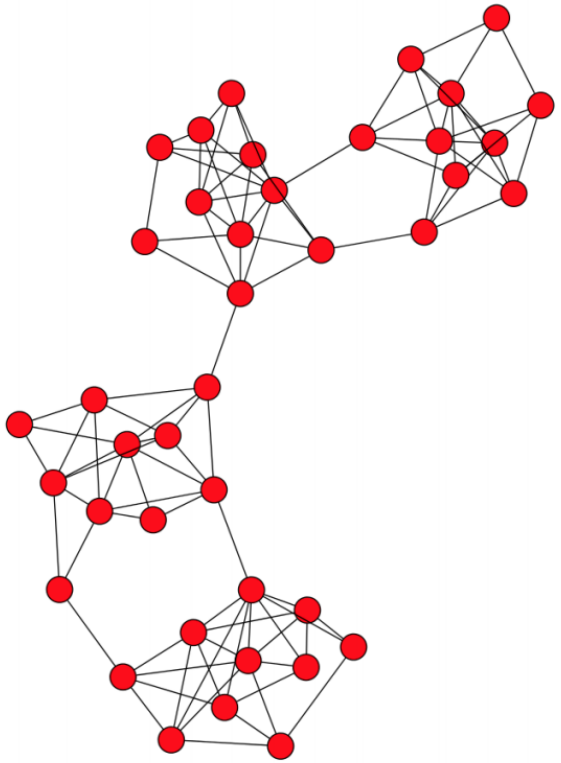
$$D_{in} = \begin{bmatrix} 3 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 7 & 0 \\ 0 & 0 & 0 & 0 & 6 \end{bmatrix}$$

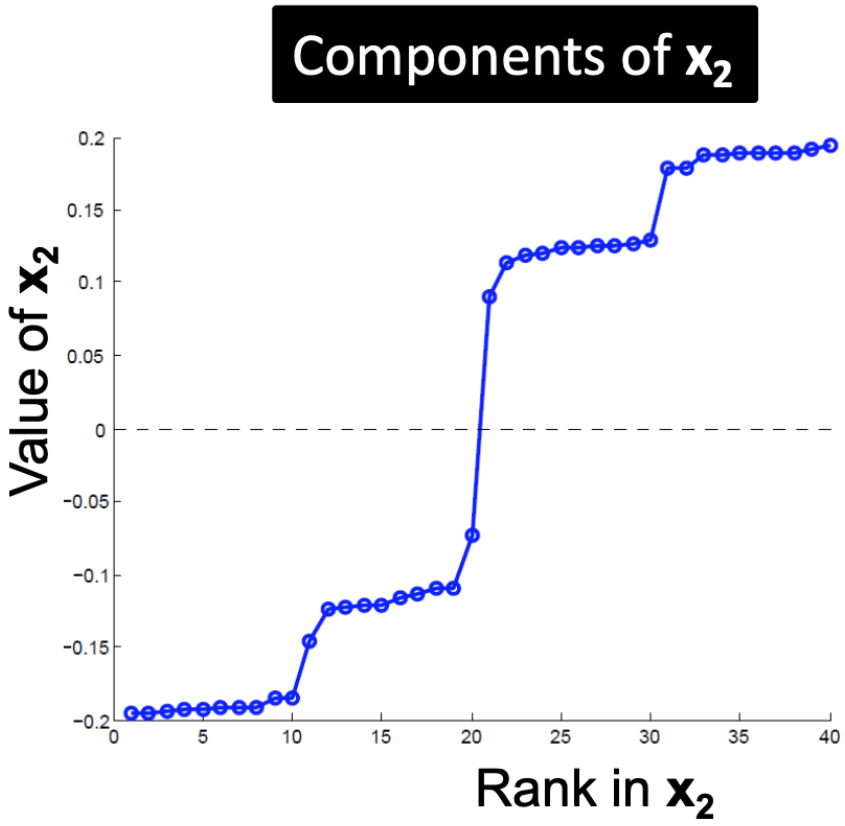
(c) In-degree matrix.

$$L = \begin{bmatrix} 3 & 0 & 0 & 0 & -3 \\ -1 & 3 & -2 & 0 & 0 \\ 0 & 0 & 3 & -3 & 0 \\ -2 & -4 & 0 & 7 & -1 \\ -3 & -3 & 0 & 0 & 6 \end{bmatrix}$$

(d) Laplacian matrix.

Fig. 1: A directed graph and the corresponding matrices.

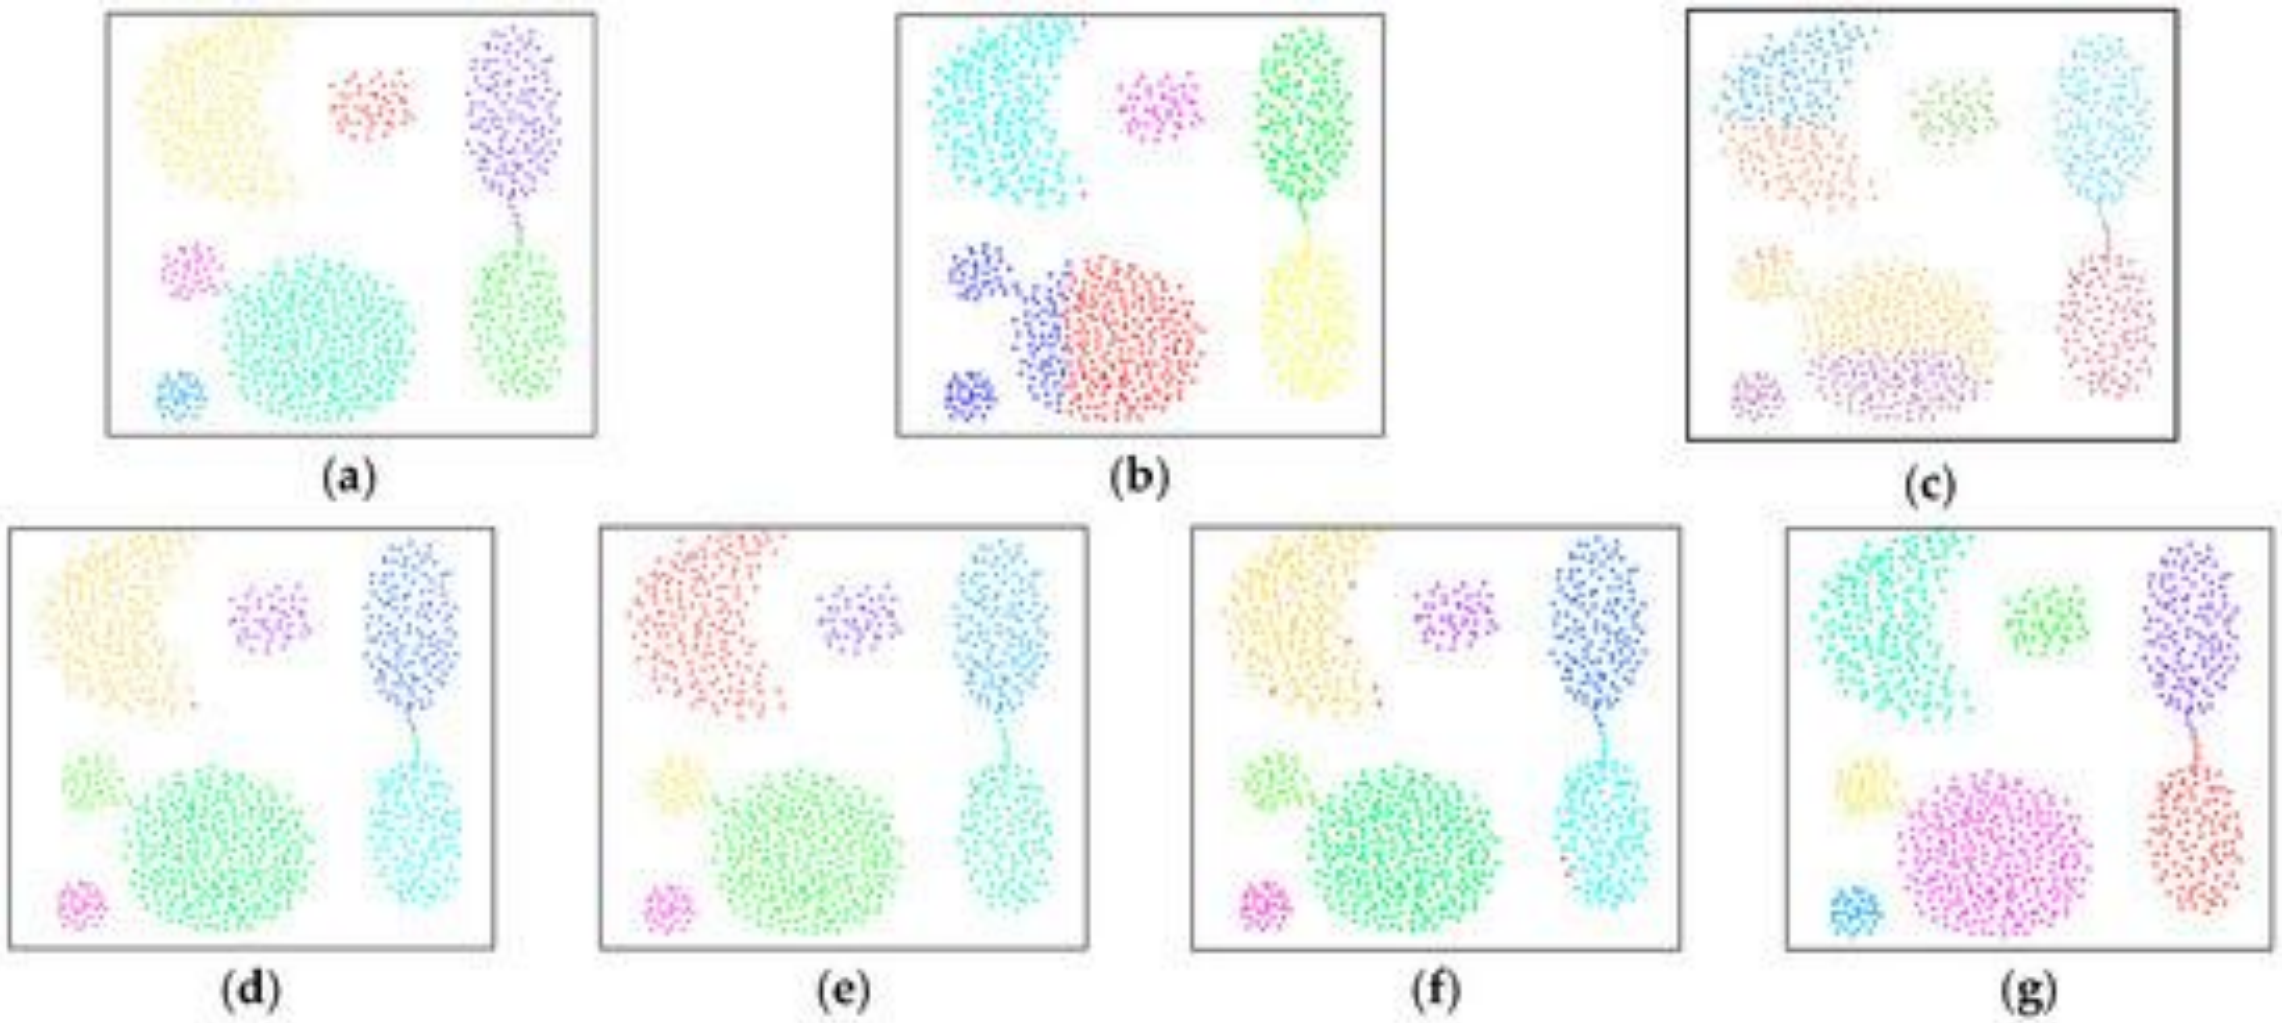



Components of x_2
Value of x_2
Rank in x_2
0.2
0.15
0.1
0.05
0
−0.05
−0.1
−0.15
−0.2
0
5
10
15
20
25
30
35
40

Ejemplo

Ventajas y limitaciones de spectral clustering

- **Ventajas**
  - Puede detectar clústeres no convexos y con formas complejas.
  - Es apropiado cuando los datos pueden representarse naturalmente mediante un grafo.
  - Puede trabajar directamente con una matriz de afinidad o similitud.
  - La transformación espectral puede hacer que los grupos sean más fáciles de separar.
- **Limitaciones**
  - Generalmente requiere especificar el número de clústeres.
  - Es sensible a la construcción de la matriz de afinidad.
  - La matriz de similitud puede requerir una gran cantidad de memoria.
  - La descomposición en valores y vectores propios es costosa para conjuntos de datos grandes.
  - Su interpretación es menos directa porque los clústeres se obtienen en un espacio espectral.



(**a**) original, (**b**) K-means, (**c**) GMM, (**d**) DBSCAN, (**e**) CURE (jerárquico), (**f**) Spectral Clustering, y (**g**) DTG.